

PRINCIPALES TÉCNICAS ESTADÍSTICAS

(VER 2: 2020-2021)



Emilio Letón y Elisa M. Molanes-López

01-OCT-2020

PRINCIPALES TÉCNICAS ESTADÍSTICAS

©Emilio Letón y Elisa M. Molanes-López

Madrid, ver 2: 2020-2021

Quedan rigurosamente prohibidas, sin la autorización escrita de los titulares del Copyright, bajo las sanciones establecidas en las leyes, la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la reprografía y el tratamiento informático, y la distribución de ejemplares de ella mediante alquiler o préstamo público.

ISBN electrónico: xxx.

Edición digital (epub): xxx.

Índice general

1. Conceptos básicos de inferencia estadística	3
1.1. Consideraciones previas	3
1.2. Intervalo de confianza	7
1.3. Contraste de hipótesis	8
2. Respuesta dicotómica	13
2.1. z de diferencia de dos proporciones	13
2.2. Exacta de Fisher	16
3. Respuesta continua	19
3.1. t de Student	19
3.2. ANOVA de un factor	22
4. Respuesta nominal	27
4.1. χ^2 de homogeneidad	27
5. Respuesta ordinal	31
5.1. U de Mann-Whitney	31
5.2. W de Wilcoxon	33
5.3. H de Kruskal-Wallis	36
Referencias	41
Glosario	43
Acerca de	45
Emilio Letón	45
Elisa M. Molanes-López	45

Índice de figuras

5.1. Box-Plot para los datos observados del esquema $O \leftarrow D$	33
5.2. Box-Plot para los datos observados del esquema $O \leftarrow N$	38
5.3. Emilio Letón	45
5.4. Elisa M. Molanes-López	45

Índice de tablas

1.1. Tabla con distintas clasificaciones según los tipos de variables	4
1.2. Datos genéricos de una variable dicotómica	4
1.3. Datos de 20 propociones muestrales	6
1.4. Simulaciones de 20 muestras para el IC de una proporción poblacional	9
1.5. Simulaciones de 20 muestras para el CH de una proporción poblacional	11
2.1. Datos genéricos del esquema $D \leftarrow D$	13
2.2. Datos observados del esquema $D \leftarrow D$	15
2.3. Tabla con datos genéricos del esquema $D \leftarrow D$	16
2.4. Datos observados del esquema $D \leftarrow D$	17
2.5. Tabla con datos observados del esquema $D \leftarrow D$	17
2.6. Tablas variando a' en el esquema $D \leftarrow D$	17
3.1. Datos genéricos del esquema $C \leftarrow D$	19
3.2. Datos observados del esquema $C \leftarrow D$	21
3.3. Datos genéricos del esquema $C \leftarrow N$	23
3.4. Tabla ANOVA con datos genéricos del esquema $C \leftarrow N$	23
3.5. Datos observados del esquema $C \leftarrow N$	24
3.6. Tabla ANOVA con datos observados del esquema $C \leftarrow N$	25
4.1. Datos genéricos del esquema $N \leftarrow N$	28
4.2. Tabla con datos genéricos del esquema $N \leftarrow N$	28
4.3. Tabla con datos observados del esquema $N \leftarrow N$	28
4.4. Tabla con datos esperados del esquema $N \leftarrow N$	29
5.1. Datos genéricos del esquema $O \leftarrow D$	31
5.2. Datos observados del esquema $O \leftarrow D$	32
5.3. Rangos para los datos observados del esquema $O \leftarrow D$	35
5.4. Datos genéricos del esquema $O \leftarrow N$	36
5.5. Datos observados del esquema $O \leftarrow D$	37
5.6. Rangos para los datos observados del esquema $O \leftarrow N$	39

Prefacio

Este material está diseñado con el paradigma del grupo de innovación docente miniXmodular de generar material en formato mini y modular, según se puede ver en la página web www.minixmodular.ia.uned.es, donde se introduce, entre otros, el concepto de mini-libro electrónico modular.

En este mini-libro se explican las principales técnicas estadísticas básicas que se utilizan en la práctica. Para ello, en primer lugar, se describen de forma resumida los conceptos básicos de inferencia estadística necesarios para entender los mini-capítulos siguientes. En dicho primer mini-capítulo se hace especial énfasis en los principales tipos de variables, así como los distintos propósitos de las mismas (respuesta o explicativa).

Con la ayuda del primer mini-capítulo se estructuran el resto atendiendo a distintos tipos de variable respuesta (dicotómica, continua, nominal y ordinal).

Para poder seguir este mini-libro es conveniente haber estudiado previamente una asignatura básica de grado de Estadística y tener asumidos los conceptos estadísticos básicos tratados en ella (ver, por ejemplo, Peña [2014] o Ramos et al. [2019]). Aunque se ha hecho un esfuerzo de síntesis en el primer mini-capítulo para nivelar conocimientos, no se puede condensar una asignatura de grado en unas pocas páginas. No obstante, en el glosario aparecen algunos de dichos conceptos.

Por último, conviene mencionar que a lo largo de este mini-libro se presenta código en el lenguaje R (R Core Team [2017]) para realizar los cálculos estadísticos. Existen numerosas páginas web y libros que introducen este lenguaje; dos referencias clásicas que combinan Estadística y R son Davies [2016] y García-Pérez [2010]. No obstante, conviene señalar que el código que se utiliza en este mini-libro es muy sencillo y autoexplicativo.

Mini-capítulo 1

Conceptos básicos de inferencia estadística

En este mini-capítulo se describen de forma resumida los conceptos básicos de inferencia estadística. En primer lugar, se realizan una serie de consideraciones previas y, a continuación, se tratan los conceptos básicos de intervalo de confianza y contraste de hipótesis.

1.1. Consideraciones previas

Antes de describir los conceptos básicos propiamente de la inferencia estadística, conviene tener presente una serie de consideraciones previas sobre los conceptos de población, muestra, casos, variables, datos, tipos de variables, clasificación de las variables, propósito de las variables, estadística descriptiva y cálculo de probabilidades.

Población, muestra, casos, variables y datos

Ante la necesidad de conocer un fenómeno concreto, hay que establecer, en primer lugar, una población (universo) de interés, que es un conjunto de elementos (individuos, pacientes, objetos, unidades experimentales, ordenadores, neumáticos, etc.) que poseen una o más características observables en común, que se denominan criterios de definición de la población.

En la práctica, el estudio de todos los elementos de la población es prácticamente inabordable o directamente inabordable, por lo que es habitual trabajar con un conjunto de elementos extraídos de la población, que se denomina muestra. Para que una muestra sirva para generalizar conclusiones a su población correspondiente, la muestra tiene que ser representativa de su población. Esto se consigue mediante un cálculo del tamaño muestral adecuado y un correcto procedimiento para su extracción aleatoria de la población.

Una vez definida la población y extraída la muestra, se recoge información de ésta susceptible de poderse organizar en filas (casos) y columnas (variables). A un nivel básico, se podría decir que los casos (individuos o unidades experimentales) son los elementos de la muestra sobre los que se recoge información y que variable es la forma de recoger una característica de interés de los casos (es decir, todo aquello que se recoja de un caso). Una variable puede tomar distintos valores (aleatorios) para cada caso; lo contrario a una variable es una constante (no varía). Los datos son los valores observados de las variables para cada caso: son las realizaciones de las variables para los casos.

Tipos, clasificación y propósito de las variables

Los valores que puede tomar cualquier variable constituyen los niveles de las variables. La naturaleza de estos niveles es lo que determina el tipo de variables. La importancia de distinguir apropiadamente los tipos de variables radica en que el uso correcto de las técnicas estadísticas está condicionado por la naturaleza de las variables. Los principales tipos de variables son:

- Dicotómica: tiene dos valores posibles. También se la conoce como binaria. Por ejemplo, la variable **Curación** (Sí/No), **Ejercicio físico** (Sí/No), **Género** (H/M), **Tratamiento** (A/B) o **Fumar** (Sí/No).
- Nominal: tiene varios valores posibles sin orden entre ellos. Por ejemplo, la variable **Tipo enfermedad** (A/B/C), **Hospital** (A/B/C/D), **Estado civil** (Casado/Soltero/Otros) o **Fumar tipo** (Cigarrillos/ Puros/ Otros/ No fuma).

- Ordinal: tiene varios valores posibles con un orden entre ellos. Por ejemplo, la variable **Tamaño tumor** (Pequeño/Mediano/Grande), **Horas semanales ejercicio físico** (0/más de 0 y menor o igual a 2/más de 2) o **Fumar nivel** (Consumo alto/Moderado/Nulo).
- Numérica discreta: tiene, en teoría, un número de valores discretos (enteros) posibles. Por ejemplo, la variable **Número cefaleas mes** (0/1/2/...), **Número hijos** (0/1/2/...) o **Número cigarrillos día** (0/1/2/...).
- Numérica continua o simplemente continua: tiene, en teoría, un número infinito de valores continuos posibles. Por ejemplo, la variable **Tensión arterial**, **Colesterol** o **Nicotina en sangre**.

En algunos textos aparecen recogidas distintas clasificaciones de las variables atendiendo a los tipos de las variables, según aparece en la tabla 1.1.

Tipo	Clasificación 1	Clasificación 2	Clasificación 3
Dicotómica	Cualitativa	Categórica	Discreta finita
Nominal	Cualitativa	Categórica	Discreta finita
Ordinal	Cualitativa	Categórica	Discreta finita
Numérica discreta	Cuantitativa	Numérica discreta	Discreta infinita
Continua	Cuantitativa	Continua	Continua

Tabla 1.1: Tabla con distintas clasificaciones según los tipos de variables

En la mayoría de los estudios suele haber variables explicativas y variables respuesta. Las variables respuesta (también llamadas dependientes, resultado u objetivo) son las variables que se pretende explicar o analizar. Las variables explicativas (también llamadas independientes) son las variables candidatas a servir de explicación de las variables respuesta. Un ejemplo de variable explicativa genérica puede ser **Tipo** (tipo de fármaco, tipo de motor, tipo de técnica pedagógica, etc.) y de variable respuesta genérica puede ser **Medida** (medida del éxito o no de un fármaco, medida del número de horas que funciona un motor hasta romperse, medida del grado de mejoría cuando se aplica una determinada técnica pedagógica, etc.). En el caso de dos variables X (explicativa) e Y (respuesta) se suele escribir de forma esquemática como $Y \leftarrow X$ para indicar que se está ante un modelo estadístico que establece que se está intentando explicar Y a través de X .

Estadística descriptiva

El propósito de la Estadística es conocer una población. Este propósito se realiza estudiando en primer lugar una muestra de ella a través de la estadística descriptiva y, gracias al cálculo de probabilidades, dando el salto a la población a través de la estadística inferencial.

El objetivo de la estadística descriptiva es procesar, describir, resumir la información recogida en la muestra a través de unos índices (medidas) que reciben el nombre de estadísticos y que se calculan a partir de los datos experimentales. Por ejemplo, en el caso de que se esté interesado en conocer el impacto de una enfermedad en una población, se podría hacer un estudio recogiendo una muestra de ella de n individuos y registrando si tienen o no la enfermedad. Este ejemplo correspondería a estudiar una variable dicotómica, dada por **Enfermedad** (Sí/No) y que se podría denotar por Y (1/0). En esta situación los datos experimentales tendrían el patrón dado en la tabla 1.2, donde el número de individuos 1 es r_1 , el número de individuos 0 es r_0 y el número total de individuos es $n = r_1 + r_0$.

Y
1
1
...
1
0
0
...
0

Tabla 1.2: Datos genéricos de una variable dicotómica

En este caso de una variable dicotómica, el estadístico descriptivo por excelencia es la proporción muestral dada por $\frac{r_1}{n}$ que es un número entre 0 y 1. En la práctica se suele presentar en forma de porcentaje multiplicando

por 100. En el contexto médico, a la proporción muestral de enfermedad se la denomina prevalencia muestral y representa la probabilidad muestral de estar enfermo.

Es interesante observar que si se denota en general por y_i al valor del individuo i en la variable Y , al haber codificado esta variable Y con 1/0, se tiene en este caso, que

$$\frac{r_1}{n} = \frac{1}{n} \sum_{i=1}^n y_i,$$

donde $\sum_{i=1}^n y_i$ indica $y_1 + \dots + y_n$, ya que $\sum_{i=1}^n y_i = \underbrace{1 + \dots + 1}_{r_1} + \underbrace{0 + \dots + 0}_{r_0} = r_1$, por lo que en este contexto la proporción muestral es la media muestral.

Así, si en una muestra de $n = 50$ unidades, hubiera $r_1 = 17$ con dicha enfermedad, la estadística descriptiva afirma que en dicha muestra el porcentaje de enfermedad es del 34 %. ¿ Y en la población? Esta es una pregunta que no puede responder la estadística descriptiva, hay que esperar a la estadística inferencial.

Cálculo de probabilidades

El cálculo de probabilidades es la parte más matemática de la Estadística y suministra las herramientas (por ejemplo, el teorema central del límite) para poder conocer la población a partir de una muestra representativa de ella (para poder pasar a lo general partiendo de lo concreto o particular). En este proceso es clave el concepto de parámetro y de distribución muestral de un estadístico.

En la Estadística clásica (también llamada frecuentista) se está interesado en conocer una población a través de un parámetro poblacional θ que es una constante desconocida y que se desea saber su valor. Así, por ejemplo, si se está interesado en conocer el impacto de una enfermedad en una población, sería interesante conocer el parámetro proporción poblacional de dicha enfermedad (en este caso, también denominada, prevalencia poblacional de enfermedad), que se podría denotar por la proporción poblacional π y que representa la probabilidad poblacional de enfermedad, es decir $\pi = P(Y = 1)$. Para conocer π (siempre que se pueda, existe el convenio de denotar con letras griegas a los parámetros poblacionales; en este caso conviene señalar que π no tiene nada que ver con el valor 3.14159265...) se cuenta con la ayuda de la proporción muestral, que se podría denotar por $\hat{\pi}$ dado por $\hat{\pi} = \frac{r_1}{n}$ (en otros textos se denota a la proporción muestral por p para hacer énfasis en que se utilizan letras latinas para los valores muestrales; en este mini-libro se prefiere la utilización del “gorro” $\hat{}$ o acento circunflejo para indicar que $\hat{\pi}$ es un valor estimado de π . Conviene mencionar que para los datos de la tabla 1.2 se puede calcular además de la proporción muestral $\hat{\pi} = \frac{r_1}{n}$, la desviación típica muestral dada por

$$\begin{aligned} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} &= \sqrt{\frac{1}{n} \left[\left(1 - \frac{r_1}{n}\right)^2 r_1 + \left(0 - \frac{r_1}{n}\right)^2 r_0 \right]} = \sqrt{\frac{1}{n} \frac{(n - r_1)^2}{n^2} r_1 + \frac{1}{n} \frac{r_1^2}{n^2} r_0} \\ &= \sqrt{\frac{1}{n} \frac{r_0^2}{n^2} r_1 + \frac{1}{n} \frac{r_1^2}{n^2} r_0} = \sqrt{\frac{r_0 r_1}{n} \left(\frac{r_0}{n^2} + \frac{r_1}{n^2} \right)} = \sqrt{\frac{r_0 r_1}{n} \frac{n}{n^2}} \\ &= \sqrt{\frac{r_1}{n} \left(1 - \frac{r_1}{n}\right)} = \sqrt{\hat{\pi}(1 - \hat{\pi})}. \end{aligned}$$

Desde un punto de vista formal (ver, por ejemplo Peña [2014] ó Ramos et al. [2019]), el marco teórico poblacional que está generando los datos experimentales de la tabla 1.2 es el que especifica que Y es una variable aleatoria (v.a.) Bernoulli, por lo que la media teórica de Y , que se denota por $E[Y]$ (esperanza matemática), viene dada por

$$E[Y] = 1 \cdot P(Y = 1) + 0 \cdot P(Y = 0) = 1 \cdot \pi + 0 \cdot (1 - \pi) = \pi,$$

la varianza teórica de Y , que se denota por $V[Y]$, viene dada por

$$V[Y] = E[(Y - E[Y])^2] = E[Y^2] - E^2[Y] = 1^2 \cdot P(Y = 1) + 0^2 \cdot P(Y = 0) - \pi^2 = \pi(1 - \pi)$$

y la desviación típica teórica de Y , que se denota por $D[Y]$, viene dada por

$$D[Y] = \sqrt{V[Y]} = \sqrt{\pi(1 - \pi)}.$$

Ahora se trata de extrapolar (pasar) de la muestra a la población, algo que a priori parece imposible. Esto sólo se consigue con el concepto de distribución muestral de un estadístico. La idea es la siguiente. En la muestra que se está analizando, la proporción muestral tiene un determinado valor, por ejemplo 0.34. Si se hubiese tomado otra muestra representativa, la proporción muestral tomaría seguramente otro valor, por ejmplo 0.56 y si se hubiese tomado otra, quizás 0.52, etc. Si este proceso de tomar muestras representativas se repitiese

$\hat{\Pi}$
0.34
0.56
0.52
0.48
0.52
0.48
0.36
0.34
0.40
0.30
0.44
0.30
0.34
0.34
0.38
0.36
0.48
0.52
0.40
0.44

Tabla 1.3: Datos de 20 proporciones muestrales

varias veces, se podría construir una columna de datos con los valores de todas las proporciones muestrales obtenidas, similar a la tabla 1.3 donde dichos valores varían de unos a otros (hay una cierta variabilidad). En la tabla 1.3 se ha nombrado a la columna con $\hat{\Pi}$ para indicar que se está ante una nueva variable aleatoria (por eso en mayúsculas) que es la variable aleatoria asociada al estadístico proporción muestral. Esta variable tendrá un histograma asociado (un modelo de probabilidad continuo asociado). Este histograma o modelo asociado, recibe el nombre de distribución muestral del estadístico proporción muestral. En este caso, el teorema central del límite afirma que tiene forma de campana de Gauss (es una v.a. Normal). Desde un punto de vista formal (ver, por ejemplo Peña [2014] ó Ramos et al. [2019]), si se considera Y_i la v.a. Y asociada al individuo i , se tiene que el estadístico $\hat{\Theta}$ dado por la v.a. proporción muestral $\hat{\Pi}$ es

$$\hat{\Theta} = \hat{\Pi} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

con lo que la media teórica de $\hat{\Pi}$ viene dada por

$$E[\hat{\Pi}] = E[\bar{Y}] = E\left[\frac{1}{n} \sum_{i=1}^n Y_i\right] = \frac{1}{n} E\left[\sum_{i=1}^n Y_i\right] = \frac{1}{n} n\pi = \pi$$

y, al ser las Y_i independientes, son incorreladas, por lo que la varianza teórica de $\hat{\Pi} = \bar{Y}$ viene dada por

$$V[\hat{\Pi}] = V[\bar{Y}] = V\left[\frac{1}{n} \sum_{i=1}^n Y_i\right] = \frac{1}{n^2} V\left[\sum_{i=1}^n Y_i\right] \stackrel{incorr.}{=} \frac{1}{n^2} n\pi(1-\pi) = \pi(1-\pi)\frac{1}{n}.$$

La raíz cuadrada de la varianza teórica del estadístico proporción muestral $\hat{\Pi}$ se denomina error estándar del estadístico proporción muestral, $EE[\hat{\Pi}]$, y representa una medida de la dispersión del estadístico proporción muestral. Su expresión viene dada por

$$EE[\hat{\Pi}] = \sqrt{V[\hat{\Pi}]} = \sqrt{\pi(1-\pi)\frac{1}{n}}.$$

Con estos elementos y la ayuda de la estadística inferencial se puede inferir qué ocurre con el parámetro proporción poblacional π , dando el salto de la muestra a la población. Dentro de la estadística inferencial se distingue la inferencia mediante un intervalo de confianza (IC) y la inferencia mediante un contraste de hipótesis (CH).

1.2. Intervalo de confianza

A un nivel intuitivo el IC de un parámetro poblacional θ proporciona (infiere) un rango plausible de valores para dicho parámetro a nivel poblacional. En el caso del parámetro poblacional π su IC viene dado por

$$IC(1 - \alpha) \%(\pi) = \left(E[\hat{\Pi}] - z_{1-\alpha/2} EE[\hat{\Pi}], E[\hat{\Pi}] + z_{1-\alpha/2} EE[\hat{\Pi}] \right),$$

donde $1 - \alpha$ representa la confianza que se tiene en que dicho intervalo cubra de verdad al parámetro poblacional. Usualmente, se toma $\alpha = 0.05$ con lo que la confianza habitual es del 95 %, aunque en ocasiones también se utiliza $\alpha = 0.01$ y por tanto una confianza del 99 %. El valor $z_{1-\alpha/2}$ representa el valor de la abscisa en la curva de una densidad normal tipificada que deja a la izquierda de su valor un área de $1 - \alpha/2$ y a la derecha de su valor un área de $\alpha/2$. Este valor $z_{1-\alpha/2}$ se encuentra tabulado, de forma que para $\alpha = 0.05$ es $z_{1-0.05/2} = 1.96$ y para $\alpha = 0.01$ es $z_{1-0.01/2} = 2.58$. En la expresión anterior del IC para π aparecen los términos $E[\hat{\Pi}] = \pi$ y $EE[\hat{\Pi}] = \sqrt{\pi(1-\pi)\frac{1}{n}}$, que al depender de π son desconocidos y se estiman por $\hat{E}[\hat{\Pi}] = \hat{\pi} = \frac{r_1}{n}$ y $\hat{EE}[\hat{\Pi}] = \sqrt{\hat{\pi}(1-\hat{\pi})\frac{1}{n}} = \sqrt{\frac{r_1}{n}\left(1 - \frac{r_1}{n}\right)\frac{1}{n}}$, respectivamente.

El nivel de confianza, si se expresa en tanto por ciento, está comprendido entre 0 y 100. Técnicamente, no se puede decir, si se trabaja por ejemplo con un 95 % de confianza, que el parámetro está en el IC95 % con una probabilidad del 95 %, sino que si se repitiese el estudio 100 veces con 100 muestras distintas y se construyesen 100 IC95 % utilizando la fórmula anterior, un 95 % de ellos cubrirían realmente al parámetro desconocido. En la práctica, sólo se realizará un estudio y sólo se construirá un IC95 % y nunca se sabrá si el parámetro está o no está en él, pero al menos se tendrá la seguridad de que el método de construcción del intervalo se realiza con una confianza dada. Dicho de otra forma, los IC no calculan la probabilidad de que θ esté comprendido entre dos valores porque el parámetro no es una v.a., es una constante (desconocida, pero constante y está o no está en el IC). Ahora bien, dado que los extremos del IC son v.a., sí se puede hablar de la probabilidad de que dichos valores cubran a θ .

Otro concepto importante en el intervalo de confianza, es la imprecisión que está asociada a la anchura del IC y que viene dada en las mismas unidades en las que se mida el parámetro que se pretende estimar. Existe un símil algo poético en el que se considera que el centro de una diana es el parámetro desconocido y un lanzador de hacha es la estadística inferencial. En dicho símil, la confianza está representada por la habilidad del lanzador del hacha y la imprecisión por la longitud del filo del hacha.

Sobre los conceptos que intervienen en un IC, se tiene que:

- Una mayor confianza conlleva una mayor imprecisión, ya que, por ejemplo, para $\alpha = 0.05$ es $z_{1-0.05/2} = 1.96$ y para $\alpha = 0.01$ es $z_{1-0.01/2} = 2.58$, lo que se traduce en un IC más ancho.
- Un mayor tamaño muestral conlleva una mayor precisión, es decir un IC más estrecho.
- Si se quisiera tener una confianza del 100 %, el IC100 % sería todo el rango posible de valores que puede tomar θ . Por ejemplo si θ es una proporción π , el IC100 % sería todo el intervalo $[0, 1]$ con una imprecisión máxima.
- Si se quisiera tener confianza nula, $\alpha = 0$, el IC0 % sería la estimación puntual del parámetro dada por el valor del estadístico muestral correspondiente, con una precisión máxima, pero generabilidad nula a la población.

Por último, cabe señalar como recomendación práctica, que el cálculo del IC para una proporción según la fórmula dada requiere que el valor $n\hat{\pi}$ sea mayor que 5 lo que, intuitivamente, corresponde a un tamaño muestral lo suficientemente grande y una proporción no demasiado extrema.

Ejemplo

1. Se desea estimar por IC el verdadero valor de una proporción poblacional. Después de tomar una muestra representativa de $n = 50$, se observa que en dicha muestra 17 individuos presentan la característica de interés. ¿Cuál es el IC95 %?

SOLUCIÓN:

El IC95 %(π) viene dado por

$$\begin{aligned} IC95 \%(\pi) &= \left(\hat{\pi} \mp 1.96 \sqrt{\hat{\pi}(1-\hat{\pi})\frac{1}{n}} \right) \\ &= \left(\frac{r_1}{n} \mp 1.96 \sqrt{\frac{r_1}{n}\left(1 - \frac{r_1}{n}\right)\frac{1}{n}} \right) = \left(\frac{17}{50} \mp 1.96 \sqrt{\frac{17}{50}\left(1 - \frac{17}{50}\right)\frac{1}{50}} \right) = (0.21, 0.47). \end{aligned}$$

2. Se pide ilustrar con R el concepto de intervalo de confianza mediante simulaciones. Para ello se supone conocida la proporción poblacional, por ejemplo, se supone $\pi = 0.40$, pero se procede como si no se supiese. Se toman 20 muestras de dicha población, cada una de tamaño 50, y se construyen 20 $IC95\%$ observando empíricamente cuántos cubren al verdadero parámetro poblacional.

SOLUCIÓN:

En primer lugar, se muestra la sintaxis en R para la generación de una muestra de tamaño 50 de una población con proporción poblacional $\pi = 0.40$ y del cálculo del $IC95\%$.

```
rm(list=ls())

muestra=1*(runif(50,0,1)<0.40)
muestra

pi_muestral=sum(muestra)/50
pi_muestral

IC95inf=pi_muestral-1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95inf

IC95sup=pi_muestral+1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95sup
```

Dicha sintaxis produce un resultado distinto cada vez que se ejecuta. A la hora de escribir este mini-capítulo se obtuvo

$$\begin{aligned}\hat{\pi} &= 0.34 \\ IC95\%(\pi) &= (0.21, 0.47).\end{aligned}$$

En este caso, se observa que el $IC95\%(\pi)$ cubre al verdadero parámetro poblacional $\pi = 0.40$ (era de esperar, ya que sólo 5 de cada 100 veces, o si se prefiere 1 de cada 20 no lo cubriría).

En segundo lugar, se muestra la sintaxis en R para la generación de 19 muestras de tamaño 50 de la misma población con proporción poblacional $\pi = 0.40$ y del cálculo del $IC95\%$ para cada muestra. En esta ocasión se utiliza una sintaxis más compacta:

```
rm(list=ls())

pi_muestral=replicate(19,sum(1*(runif(50,0,1)<0.40))/50)
pi_muestral

IC95inf=pi_muestral-1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95inf

IC95sup=pi_muestral+1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95sup
```

Dicha sintaxis produce un resultado distinto cada vez que se ejecuta. A la hora de escribir este mini-capítulo y, teniendo en cuenta la primera muestra, se obtuvieron los valores dados en la tabla 1.4.

En la tabla 1.4 se observa que hay un IC (el segundo) de los 20 dado por (0.42, 0.70) que NO cubre al verdadero parámetro poblacional. Si esa segunda muestra fuera la muestra obtenida en el estudio, el IC no cumpliría su misión y NADIE lo sabría.

Además, con la ayuda de la tabla 1.4 se puede comprobar que la media muestral de todas las proporciones muestrales es 0.414 muy similar al valor teórico dado por $E[\hat{\Pi}] = \pi = 0.40$ y que la desviación típica muestral de todas las proporciones muestrales es 0.079, muy similar al valor teórico dado por $D[\hat{\Pi}] = \sqrt{V[\hat{\Pi}]} = \sqrt{\pi(1-\pi)/50} = 0.069$.

1.3. Contraste de hipótesis

A un nivel intuitivo el CH permite tomar (inferir) una decisión acerca de las poblaciones en base a lo que se ha observado en la muestra. Se puede decir también, que cuantifica si el azar puede explicar o no lo observado en la muestra. En definitiva, si se puede inferir que lo observado en la muestra también ocurre en la población.

pi_muestral	IC95inf	IC95sup
0.34	0.21	0.47
0.56	0.42	0.70
0.52	0.38	0.66
0.48	0.34	0.62
0.52	0.38	0.66
0.48	0.34	0.62
0.36	0.23	0.49
0.34	0.21	0.47
0.40	0.26	0.54
0.30	0.17	0.43
0.44	0.30	0.58
0.30	0.17	0.43
0.34	0.21	0.47
0.34	0.21	0.47
0.38	0.25	0.51
0.36	0.23	0.49
0.48	0.34	0.62
0.52	0.38	0.66
0.40	0.26	0.54
0.44	0.30	0.58

Tabla 1.4: Simulaciones de 20 muestras para el IC de una proporción poblacional

En el CH intervienen dos hipótesis que se enfrentan entre sí: la hipótesis nula H_0 (usualmente de igualdad: no hay diferencias) y la hipótesis alternativa H_1 (usualmente de no igualdad: sí hay diferencias). Se trata de decidir, en base a la construcción de un estadístico de contraste experimental (basado en la muestra) entre esas dos hipótesis. En dicha decisión, existen dos posibles riesgos:

- El riesgo α (o error de tipo I) que parece cuando se rechaza la H_0 siendo ésta verdadera. Sería en plan intuitivo “pasarse de listo”: decir que hay diferencias cuando en realidad no las hay. En términos técnicos $\alpha = P(H_1|H_0)$, es decir α es la $P(\text{concluir } H_1 | \text{en realidad es cierta } H_0)$.
- El riesgo β (o error de tipo II) que parece cuando no se rechaza la H_0 siendo ésta falsa. Sería en plan intuitivo “ser cegato ante la realidad”: no ver que hay diferencias cuando en realidad las hay. En términos técnicos $\beta = P(H_0|H_1)$, es decir β es la $P(\text{aceptar } H_0 | \text{en realidad es cierta } H_1)$. Al valor $1 - \beta$ se le llama potencia del CH.

Estos riesgos que se admiten que siempre van a existir al tomar una decisión, se intentan controlar fijando unos valores asumibles. Para el caso de α se considera 0.05 que es el valor usual del nivel de significación, a partir del cual se va a decretar la existencia de diferencias estadísticamente significativas. Para el caso de β se suele considerar 0.10, que es el valor que corresponde a una potencia del 90 %. Estos valores asumidos por α y β intervienen en las fórmulas del cálculo del tamaño muestral. A la hora de la decisión, se asocia al estadístico de contraste un valor llamado p -valor, que cuantifica el peso del azar, tomando valores entre 0 y 1. Si dicho p -valor es menor que el nivel de significación, se rechaza H_0 (se decreta la existencia de diferencias estadísticamente significativas, ya que el peso del azar es pequeño y el azar no puede explicar las diferencias muestrales observadas) y se concluye H_1 , en caso contrario no se rechaza H_0 , se dice que no hay evidencia suficiente para rechazar H_0 (se decreta que no hay diferencias estadísticamente significativas, ya que el peso del azar es grande y el azar sí puede explicar las diferencias muestrales observadas) y en la práctica se “acepta” H_0 .

Para fijar ideas, se presenta el CH para el parámetro proporción poblacional π dado por

$$\begin{aligned} H_0 : \pi &= \pi_t \\ H_1 : \pi &\neq \pi_t \end{aligned}$$

donde se trata de decidir si en la población, el parámetro proporción poblacional π toma un valor concreto π_t teórico de referencia o si no lo toma. En este caso, el estadístico de contraste “experimental”, z_{exp} , está dado por

$$z_{exp} = \frac{\frac{r_1}{n} - \pi_t}{\sqrt{\pi_t(1 - \pi_t)\frac{1}{n}}}.$$

y que se demuestra, utilizando el teorema central del límite, que sigue una $N(0,1)$. Se observa que en el numerador del estadístico de contraste aparece la proporción muestral y que en el denominador aparece la cuantificación de la variabilidad de la proporción muestral. En concreto, el denominador representa la estimación de $EE[\hat{\Pi}] = \sqrt{\pi(1-\pi)\frac{1}{n}}$ bajo la hipótesis nula (con lo que $\pi = \pi_t$), que se podría denotar por $\widehat{EE}_0[\hat{\Pi}] = \sqrt{\pi_t(1-\pi_t)\frac{1}{n}}$.

Asociado al estadístico de contraste z_{exp} estaría el p -valor que es $p\text{-valor} = P(Z < -|z_{exp}|) + P(Z > |z_{exp}|) = 2P(Z > |z_{exp}|)$ con $Z \sim N(0,1)$. Por lo tanto, si $p\text{-valor} < \alpha$ (de forma equivalente, si $|z_{exp}| > z_{1-\alpha/2}$) se rechaza H_0 . El hecho de que aparezcan dos sumandos en el cálculo del p -valor obedece a que el CH descrito es bilateral en el sentido de que en la H_1 el valor del parámetro poblacional puede estar al lado izquierdo de π_t o al lado derecho.

Existen versiones unilaterales del CH anterior. Así, por un lado el CH dado por

$$\begin{aligned} H_0 : \pi &\geq \pi_t \\ H_1 : \pi &< \pi_t \end{aligned}$$

con el mismo estadístico de contraste z_{exp} , pero con $p\text{-valor} = P(Z < z_{exp})$ y el CH dado por

$$\begin{aligned} H_0 : \pi &\leq \pi_t \\ H_1 : \pi &> \pi_t \end{aligned}$$

con el mismo estadístico de contraste z_{exp} , pero con $p\text{-valor} = P(Z > z_{exp})$.

Es importante notar que, en ningún caso, el p -valor representa la probabilidad de que la H_0 sea correcta, sino la probabilidad de que siendo correcta la H_0 se presente un resultado del estadístico de contraste más extremo que el observado en la dirección que marca la H_1 . Por último, el hecho de denotar con el subíndice *exp* al estadístico de contraste experimental es con motivos pedagógicos para hacer hincapié en que depende de los datos experimentales, pero no es necesario explicitarlo por norma.

Como recomendación práctica, la asunción del test z de una proporción es que el valor $n\hat{\pi}$ sea mayor que 5 lo que, intuitivamente, corresponde a un tamaño muestral lo suficientemente grande y una proporción no demasiado extrema.

Ejemplo

1. Se desea contrastar si el verdadero valor de una proporción poblacional es 0.40. Después de tomar una muestra representativa de $n = 50$, se observa que en dicha muestra 17 individuos presentan la característica observada. ¿Cuál es la decisión en relación al CH bilateral sobre el valor teórico?

SOLUCIÓN:

El CH planteado es

$$\begin{aligned} H_0 : \pi &= .40 \\ H_1 : \pi &\neq .40 \end{aligned}$$

con estadístico de contraste dado por

$$z = \frac{\frac{17}{50} - 0.40}{\sqrt{0.40(1-0.40)\frac{1}{50}}} = -0.8660.$$

que tiene asociado un $p\text{-valor} = 2 \cdot (1 - \text{pnorm}(\text{abs}(-0.8660))) = 0.3865$. Dado que el p -valor es mayor que el nivel de significación habitual de 0.05, se concluye que no hay motivos para rechazar H_0 , que el valor observado para la proporción muestral de 0.34 no es estadísticamente distinto de forma significativa que el valor de referencia de 0.40, que el azar puede explicar la diferencia observada entre 0.34 y 0.40.

2. Se pide ilustrar con R el concepto de contraste de hipótesis mediante simulaciones. Para ello se supone conocida la proporción poblacional, por ejemplo se supone $\pi = 0.40$, pero se procede como si no se supiese. Se toman 20 muestras de dicha población, cada una de tamaño 50, y se construyen 20 CH con valor de referencia precisamente el valor de 0.40, observando empíricamente cuántos de ellos rechazan H_0 de forma incorrecta.

pi_muestral	z	p-valor
0.34	-0.8660	0.3865
0.56	2.3094	0.0209
0.52	1.7321	0.0833
0.48	1.1547	0.2482
0.52	1.7321	0.0833
0.48	1.1547	0.2482
0.36	-0.5774	0.5637
0.34	-0.8660	0.3865
0.40	0.0000	1.0000
0.30	-1.4434	0.1489
0.44	0.5774	0.5637
0.30	-1.4434	0.1489
0.34	-0.8660	0.3865
0.34	-0.8660	0.3865
0.38	-0.2886	0.7728
0.36	-0.5774	0.5637
0.48	1.1547	0.2482
0.52	1.7321	0.0833
0.40	0.0000	1.0000
0.44	0.5774	0.5637

Tabla 1.5: Simulaciones de 20 muestras para el CH de una proporción poblacional

SOLUCIÓN:

Aprovechando el ejercicio de simulación de los IC, se construye la tabla 1.5 pero con las columnas de z y del p -valor.

En la tabla 1.5 se observa que hay un CH (el segundo) de los 20, con p -valor=0.0209 y que, por tanto, rechaza de forma incorrecta la H_0 . Hay que recordar que los datos estaban simulados con 0.40 como verdadero parámetro poblacional. Es importante notar la equivalencia entre CH e IC, aunque dicha equivalencia no es total porque difieren en la forma de estimación del EE .

Mini-capítulo 2

Respuesta dicotómica

En este mini-capítulo se contemplan el test z de diferencia de dos proporciones y el test exacto de Fisher, que están enmarcados en el esquema $D \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y dicotómica a través de la variable explicativa X dicotómica.

Esta situación se da, por ejemplo, cuando se quiere estudiar si la curación de una enfermedad está influida por el hecho de dar un tratamiento u otro. Para ello se realiza un estudio en n individuos a los que se les suministra el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2 en la v.a. tratamiento) a n_2 individuos con $n = n_1 + n_2$ y se observa quién se cura (codificándolo con 1 en la variable respuesta) y quién no (codificándolo con 0 en la variable respuesta). En esta situación los datos experimentales tendrán el patrón dado en la tabla 2.1, donde el número de individuos con perfil $Y = 1$ y $X = 1$ es a_1 , con perfil $Y = 0$ y $X = 1$ es $n_1 - a_1$, con perfil $Y = 1$ y $X = 2$ es a_2 y con perfil $Y = 0$ y $X = 2$ es $n_2 - a_2$.

Y	X
1	1
...	...
1	1
0	1
...	...
0	1
1	2
...	...
1	2
0	2
...	...
0	2

Tabla 2.1: Datos genéricos del esquema $D \leftarrow D$

La pregunta de si X influye en Y se traduce en comparar la proporción poblacional de curaciones con el tratamiento 1 (que se denota por π_1) y la proporción poblacional de curaciones con el tratamiento 2 (que se denota por π_2).

2.1. z de diferencia de dos proporciones

El test z de diferencia de dos proporciones está enmarcado en el esquema $D \leftarrow D$ y está indicado en tamaños muestrales grandes. En este caso, el parámetro poblacional θ de interés es la diferencia de proporciones poblacionales, entre π_1 y π_2 (es decir, $\theta = \pi_1 - \pi_2$). Para ello se considera el estadístico $\hat{\Theta}$ dado por la v.a. $\hat{\Pi}_1 - \hat{\Pi}_2$ (es decir, $\hat{\Theta} = \hat{\Pi}_1 - \hat{\Pi}_2$), siendo $\hat{\Pi}_1$ y $\hat{\Pi}_2$ las proporciones muestrales entendidas como v.a. ya que variarán de muestra a muestra. Es sabido (utilizando el teorema central del límite) que $\hat{\Pi}_1$ y $\hat{\Pi}_2$ siguen sendas distribuciones normales y, por lo tanto, será normal la diferencia $\hat{\Pi}_1 - \hat{\Pi}_2$. Además, es fácil ver que la media teórica de $\hat{\Pi}_1 - \hat{\Pi}_2$ está dada por

$$E[\hat{\Pi}_1 - \hat{\Pi}_2] = E[\hat{\Pi}_1] - E[\hat{\Pi}_2] = \pi_1 - \pi_2$$

y la varianza teórica de $\hat{\Pi}_1 - \hat{\Pi}_2$ está dada por

$$V[\hat{\Pi}_1 - \hat{\Pi}_2] = V[\hat{\Pi}_1] + V[\hat{\Pi}_2] - 2Cov(\hat{\Pi}_1, \hat{\Pi}_2) = \frac{\pi_1(1 - \pi_1)}{n_1} + \frac{\pi_2(1 - \pi_2)}{n_2},$$

ya que independencia implica incorrelación que equivale a covarianza nula, con lo que el error estándar de $\hat{\Pi}_1 - \hat{\Pi}_2$ es

$$EE[\hat{\Pi}_1 - \hat{\Pi}_2] = \sqrt{\frac{\pi_1(1 - \pi_1)}{n_1} + \frac{\pi_2(1 - \pi_2)}{n_2}}.$$

Con la información anterior se define un nuevo estadístico dado por

$$\frac{\hat{\Pi}_1 - \hat{\Pi}_2 - E[\hat{\Pi}_1 - \hat{\Pi}_2]}{EE[\hat{\Pi}_1 - \hat{\Pi}_2]} = \frac{\hat{\Pi}_1 - \hat{\Pi}_2 - (\pi_1 - \pi_2)}{\sqrt{\pi_1(1 - \pi_1)\frac{1}{n_1} + \pi_2(1 - \pi_2)\frac{1}{n_2}}}$$

que sigue una $N(0, 1)$ y que servirá para construir un intervalo de confianza y un contraste de hipótesis para $\pi_1 - \pi_2$.

En el caso del intervalo de confianza hay que estimar $EE[\hat{\Pi}_1 - \hat{\Pi}_2]$ a través de

$$\widehat{EE}[\hat{\Pi}_1 - \hat{\Pi}_2] = \sqrt{\hat{\pi}_1(1 - \hat{\pi}_1)\frac{1}{n_1} + \hat{\pi}_2(1 - \hat{\pi}_2)\frac{1}{n_2}}$$

con $\hat{\pi}_1 = \frac{a_1}{n_1}$ y $\hat{\pi}_2 = \frac{a_2}{n_2}$, con lo que el intervalo de confianza al $(1 - \alpha)\%$ está dado por

$$\begin{aligned} IC(1 - \alpha)\%(\pi_1 - \pi_2) &= \left(\hat{\pi}_1 - \hat{\pi}_2 \mp z_{1-\alpha/2} \sqrt{\hat{\pi}_1(1 - \hat{\pi}_1)\frac{1}{n_1} + \hat{\pi}_2(1 - \hat{\pi}_2)\frac{1}{n_2}} \right) \\ &= \left(\frac{a_1}{n_1} - \frac{a_2}{n_2} \mp z_{1-\alpha/2} \sqrt{\frac{a_1}{n_1} \left(1 - \frac{a_1}{n_1}\right) \frac{1}{n_1} + \frac{a_2}{n_2} \left(1 - \frac{a_2}{n_2}\right) \frac{1}{n_2}} \right). \end{aligned}$$

En el caso del contraste de hipótesis

$$\begin{aligned} H_0 : \pi_1 - \pi_2 &= 0 \\ H_1 : \pi_1 - \pi_2 &\neq 0 \end{aligned}$$

hay que estimar $EE[\hat{\Pi}_1 - \hat{\Pi}_2]$ bajo H_0 (con lo que $\pi_1 = \pi_2$ y se suponen igual a un valor común π_c que se estima por $\hat{\pi}_c = \frac{n_1\hat{\pi}_1 + n_2\hat{\pi}_2}{n_1 + n_2} = \frac{a_1 + a_2}{n_1 + n_2}$) a través de

$$\begin{aligned} \widehat{EE}_0[\hat{\Pi}_1 - \hat{\Pi}_2] &= \sqrt{\hat{\pi}_c(1 - \hat{\pi}_c)\frac{1}{n_1} + \hat{\pi}_c(1 - \hat{\pi}_c)\frac{1}{n_2}} \\ &= \sqrt{\hat{\pi}_c(1 - \hat{\pi}_c)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} = \sqrt{\frac{a_1 + a_2}{n_1 + n_2} \left(1 - \frac{a_1 + a_2}{n_1 + n_2}\right) \left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \end{aligned}$$

y el contraste de hipótesis al nivel de significación α se realiza con

$$z = \frac{\frac{a_1}{n_1} - \frac{a_2}{n_2}}{\sqrt{\frac{a_1 + a_2}{n_1 + n_2} \left(1 - \frac{a_1 + a_2}{n_1 + n_2}\right) \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

tomando la decisión de que si $|z| > z_{1-\alpha/2}$ se rechaza la H_0 .

Como recomendación práctica, las asunciones del test z de diferencia de dos proporciones son que todos los valores $n_1\hat{\pi}_1$, $n_1(1 - \hat{\pi}_1)$, $n_2\hat{\pi}_2$ y $n_2(1 - \hat{\pi}_2)$, sean mayores que 5 lo que, intuitivamente, corresponde a tamaños muestrales suficientemente grandes y proporciones no demasiado extremas.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta dicotómica. Han participado en el estudio 90 individuos. Los datos experimentales se dan en la tabla 2.2, donde el número de individuos con perfil $rta = 1$ y $exp = 1$ es 8, con perfil $rta = 1$ y $exp = 2$ es 14, con perfil $rta = 0$ y $exp = 1$ es 42 y con perfil $rta = 0$ y $exp = 2$ es 26.

SOLUCIÓN:

<i>rta</i>	<i>exp</i>
1	1
...	...
1	1
1	2
...	...
1	2
0	1
...	...
0	1
0	2
...	...
0	2

Tabla 2.2: Datos observados del esquema $D \leftarrow D$

En primer lugar se muestran los cálculos detallados para el intervalo de confianza al 95 % dado por

$$\begin{aligned}
 IC_{95\%}(\pi_1 - \pi_2) &= \left(\frac{8}{50} - \frac{14}{40} \mp 1.96 \sqrt{\frac{8}{50} \left(1 - \frac{8}{50}\right) \frac{1}{50} + \frac{14}{40} \left(1 - \frac{14}{40}\right) \frac{1}{40}} \right) \\
 &= (0.16 - 0.35 \mp 1.96 \cdot 0.0915) \\
 &= (-0.3694, -0.0106)
 \end{aligned}$$

y para el contraste de hipótesis dado por

$$z = \frac{\frac{8}{50} - \frac{14}{40}}{\sqrt{\frac{8+14}{50+40} \left(1 - \frac{8+14}{50+40}\right) \left(\frac{1}{50} + \frac{1}{40}\right)}} = -2.0841$$

con lo que al ser $|z| = 2.0841 > 1.96$ se rechaza la hipótesis nula de igualdad de proporciones y se concluye que la variable explicativa influye en la variable respuesta de forma significativa con un p -valor = $2 \cdot (1 - pnorm(abs(-2.0841))) = 0.0371$.

En segundo lugar se muestra la sintaxis en R para el cálculo del IC y del p -valor del test z de diferencia de dos proporciones. Si se supone que los datos sin agrupar están en el fichero `d_d_1.txt` la sintaxis es

```
rm(list=ls())

datos=read.table('d_d_1.txt',header=T)
attach(datos)

tabla=table(-rta,exp); tabla

ind1=which(exp==1);
ind2=which(exp==2);
ind11=which(rta==1 & exp==1);
ind12=which(rta==1 & exp==2);
a1=length(rta[ind11]); a1
a2=length(rta[ind12]); a2
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2

alfa=0.05
pi1=a1/n1
pi2=a2/n2

ee=sqrt(pi1*(1-pi1)*(1/n1)+pi2*(1-pi2)*(1/n2)); ee

ic1=pi1-pi2-qnorm(1-alfa/2)*ee; ic1
ic2=pi1-pi2+qnorm(1-alfa/2)*ee; ic2
```

```

pit=(a1+a2)/(n1+n2); pit

ee0=sqrt(pit*(1-pit)*(1/n1+1/n2))
z=(pi1-pi2)/ee0; z
z*z

p_valor= 2*(1-pnorm(abs(z))); p_valor

a=c(a1,a2); a
n=c(n1,n2); n
prop.test(a,n,correct=F)

```

y si se supone que se introducen los datos agrupados directamente hay que sustituir las primeras líneas de la sintaxis anterior por

```

rm(list=ls())

a1=8; n1=50
a2=14; n2=40

```

2.2. Exacta de Fisher

El test exacto de Fisher está enmarcado en el esquema $D \leftarrow D$ y está indicado en tamaños muestrales pequeños donde no se cumplen las asunciones del test z de diferencia de dos proporciones. A partir de los datos experimentales se construye la tabla de datos cruzados genérica dada en la tabla 2.3.

	$X = 1$	$X = 2$	
$Y = 1$	a	b	$r_1 = a + b$
$Y = 0$	c	d	$r_2 = c + d$
	n_1	n_2	n

Tabla 2.3: Tabla con datos genéricos del esquema $D \leftarrow D$

A partir de la tabla 2.3, se construyen todas las tablas posibles 2x2 con celdas a' , b' , c' y d' siendo:

- $0 \leq a' \leq \min\{n_1, r_1\}$.
- $b' = r_1 - a'$.
- $c' = n_1 - a'$.
- $d' = r_2 - c'$.

A continuación, a partir de dichas tablas, se calcula

$$p_{a'} = \frac{r_1!r_2!n_1!n_2!}{n!a'!b'!c'!d'!}$$

donde $x!$ indica el factorial de x que se calcula como $x \cdot (x-1) \cdot (x-2) \cdot \dots \cdot 1$ (por ejemplo, $5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$). Por último el p -valor viene dado por

$$p\text{-valor} = \sum_{p_{a'} \leq p_a} p_{a'}.$$

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta dicotómica. Han participado en el estudio 42 individuos. Los datos experimentales se dan en la tabla 2.4, donde el número de individuos con perfil $rta = 1$ y $exp = 1$ es 4, con perfil $rta = 1$ y $exp = 2$ es 1, con perfil $rta = 0$ y $exp = 1$ es 16 y con perfil $rta = 0$ y $exp = 2$ es 21.

SOLUCIÓN:

<i>rta</i>	<i>exp</i>
1	1
...	...
1	1
1	2
...	...
1	2
0	1
...	...
0	1
0	2
...	...
0	2

Tabla 2.4: Datos observados del esquema $D \leftarrow D$

	<i>exp</i> = 1	<i>exp</i> = 2	
<i>rta</i> = 1	4	1	5
<i>rta</i> = 0	16	21	37
	20	22	42

Tabla 2.5: Tabla con datos observados del esquema $D \leftarrow D$

<i>a'</i>	<i>b'</i>	<i>c'</i>	<i>d'</i>	<i>n</i>	<i>p_{a'}</i>
0	5	20	17	42	0.0310
1	4	19	18	42	0.1720
2	3	18	19	42	0.3440
3	2	17	20	42	0.3096
4	1	16	21	42	0.1253
5	0	15	22	42	0.0182

Tabla 2.6: Tablas variando a' en el esquema $D \leftarrow D$

En primer lugar se muestran los cálculos intermedios detallados que toman por base la tabla de datos cruzados dada en la tabla 2.5 y que sirven para construir la tabla 2.6.

Utilizando la tabla 2.6, el cálculo del p -valor es

$$p\text{-valor} = \sum_{p_{a'} \leq p_a} p_{a'} = \sum_{p_{a'} \leq 0.1253} p_{a'} = 0.1253 + 0.0182 + 0.0310 = 0.1745 > 0.05,$$

por lo que no hay evidencia para concluir que la variable explicativa influya en la variable respuesta de forma significativa.

En segundo lugar se muestra la sintaxis en R para el cálculo del p -valor del test exacto de Fisher. Si se supone que los datos sin agrupar están en el fichero `d_d_2.txt` la sintaxis es

```
rm(list=ls())

datos=read.table('d_d_2.txt',header=T)
attach(datos)

tabla=table(rta,exp)

fisher.test(x=tabla,alternative="two.sided")
```

y si se supone que se introducen los datos agrupados directamente la sintaxis es

```
rm(list=ls())
```

```
tabla <- matrix(c(4,1,16,21),ncol=2,byrow=TRUE)
colnames(tabla) <- c("exp=1","exp=2")
rownames(tabla) <- c("rta=1","rta=0")
tabla <- as.table(tabla); tabla
fisher.test(x=tabla,alternative="two.sided")
```

Mini-capítulo 3

Respuesta continua

En este mini-capítulo se contemplan el test t de Student y el test ANOVA de un factor (ANOVA significa “Analysis of variance”; a veces, por ejemplo en Peña [2014], se traduce por ADEVA). El test t de Student está enmarcado en el esquema $C \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y continua a través de la variable explicativa X dicotómica y el test ANOVA de un factor está enmarcado en el esquema $C \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y continua a través de la variable explicativa X nominal.

3.1. t de Student

El test t de Student de diferencia de dos medias está enmarcado en el esquema $C \leftarrow D$ y está indicado para variables Y normales en cada categoría de la variable dicotómica X . Esta situación se da, por ejemplo, cuando se quiere estudiar si una variable bioquímica está influida por el hecho de recibir un tipo u otro de tratamiento. Para ello se realiza un estudio en n individuos a los que se les asigna el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2) a n_2 individuos con $n = n_1 + n_2$ y se observa qué valor continuo tienen en una determinada variable bioquímica. En esta situación los datos experimentales tendrán el aspecto dado en la tabla 3.1, donde el número de individuos con $X = 1$ es n_1 y con $X = 2$ es n_2 .

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2

Tabla 3.1: Datos genéricos del esquema $C \leftarrow D$

La pregunta de si X influye en Y se traduce en comparar la media poblacional de la variable bioquímica con la dieta 1 (que se denota por μ_1) y la media poblacional de la variable bioquímica con la dieta 2 (que se denota por μ_2). En este caso, el parámetro poblacional θ de interés es la diferencia de medias poblacionales, entre μ_1 y μ_2 (es decir, $\theta = \mu_1 - \mu_2$). Para ello se considera el estadístico $\hat{\Theta}$ dado por la v.a. $\bar{Y}_1 - \bar{Y}_2$ (es decir, $\hat{\Theta} = \bar{Y}_1 - \bar{Y}_2$), siendo $\bar{Y}_1$ y $\bar{Y}_2$ las medias muestrales entendidas como v.a. ya que variarán de muestra a muestra. Es sabido (utilizando que combinación lineal de normales es normal) que $\bar{Y}_1$ y $\bar{Y}_2$ siguen sendas distribuciones normales y, por lo tanto, será normal la diferencia $\bar{Y}_1 - \bar{Y}_2$. Además, es fácil ver que la media teórica de $\bar{Y}_1 - \bar{Y}_2$ está dada por

$$E[\bar{Y}_1 - \bar{Y}_2] = E[\bar{Y}_1] - E[\bar{Y}_2] = \mu_1 - \mu_2$$

y la varianza teórica de $\bar{Y}_1 - \bar{Y}_2$ está dada por

$$V[\bar{Y}_1 - \bar{Y}_2] = V[\bar{Y}_1] + V[\bar{Y}_2] - 2Cov(\bar{Y}_1, \bar{Y}_2) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2},$$

ya que independencia implica incorrelación que equivale a covarianza nula, con lo que el error estándar de

$\bar{Y}_1 - \bar{Y}_2$ es

$$EE[\bar{Y}_1 - \bar{Y}_2] = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}.$$

Con la información anterior se define un nuevo estadístico dado por

$$\frac{\bar{Y}_1 - \bar{Y}_2 - E[\bar{Y}_1 - \bar{Y}_2]}{EE[\bar{Y}_1 - \bar{Y}_2]} = \frac{\bar{Y}_1 - \bar{Y}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

que sigue una $N(0, 1)$ y que servirá para construir un intervalo de confianza y un contraste de hipótesis para $\mu_1 - \mu_2$.

En el caso del intervalo de confianza hay que estimar $EE[\bar{Y}_1 - \bar{Y}_2]$. Hay dos situaciones posibles:

- Que se pueda asumir $\sigma_1^2 = \sigma_2^2$ (homocedasticidad), en cuyo caso se suponen igual a un valor común σ_c^2 y que se estima por

$$\hat{s}_c^2 = \frac{(n_1 - 1)\hat{s}_1^2 + (n_2 - 1)\hat{s}_2^2}{(n_1 - 1) + (n_2 - 1)},$$

con $\hat{s}_1^2$ y $\hat{s}_2^2$ las cuasivarianzas muestrales en cada grupo. En este supuesto

$$\widehat{EE}[\bar{Y}_1 - \bar{Y}_2] = \sqrt{\hat{s}_c^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

y el intervalo de confianza al $(1 - \alpha)\%$ está dado por

$$IC(1 - \alpha)\%(\mu_1 - \mu_2) = \left(\hat{y}_1 - \hat{y}_2 \mp t_{1-\alpha/2, n_1+n_2-2} \sqrt{\hat{s}_c^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right).$$

- Que no se pueda asumir $\sigma_1^2 = \sigma_2^2$ (heterocedasticidad). En este supuesto

$$\widehat{EE}[\bar{Y}_1 - \bar{Y}_2] = \sqrt{\frac{\hat{s}_1^2}{n_1} + \frac{\hat{s}_2^2}{n_2}}$$

y el intervalo de confianza al $(1 - \alpha)\%$ está dado por

$$IC(1 - \alpha)\%(\mu_1 - \mu_2) = \left(\hat{y}_1 - \hat{y}_2 \mp t_{1-\alpha/2, gl} \sqrt{\frac{\hat{s}_1^2}{n_1} + \frac{\hat{s}_2^2}{n_2}} \right),$$

con

$$gl = \frac{\widehat{EE}^4[\bar{Y}_1 - \bar{Y}_2]}{\frac{1}{n_1-1} \widehat{EE}^4[\bar{Y}_1] + \frac{1}{n_2-1} \widehat{EE}^4[\bar{Y}_2]}.$$

En el caso del contraste de hipótesis

$$\begin{aligned} H_0 : \mu_1 - \mu_2 &= 0 \\ H_1 : \mu_1 - \mu_2 &\neq 0 \end{aligned}$$

hay que considerar también los supuestos de homocedasticidad y heterocedasticidad.

- En el caso de homocedasticidad, la estimación de $EE[\bar{Y}_1 - \bar{Y}_2]$ bajo H_0 dada por $\widehat{EE}_0[\bar{Y}_1 - \bar{Y}_2]$ coincide con $\widehat{EE}[\bar{Y}_1 - \bar{Y}_2] = \sqrt{\hat{s}_c^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$ y el contraste de hipótesis al nivel de significación α se realiza con

$$t = \frac{\bar{y}_1 - \bar{y}_2}{\sqrt{\hat{s}_c^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

tomando la decisión de que si $|t| > t_{1-\alpha/2, n_1+n_2-2}$ se rechaza la H_0 .

- En el caso de heterocedasticidad, la estimación de $EE[\bar{Y}_1 - \bar{Y}_2]$ bajo H_0 dada por $\widehat{EE}_0[\bar{Y}_1 - \bar{Y}_2]$ coincide con $\widehat{EE}[\bar{Y}_1 - \bar{Y}_2] = \sqrt{\frac{\hat{s}_1^2}{n_1} + \frac{\hat{s}_2^2}{n_2}}$ y el contraste de hipótesis al nivel de significación α se realiza con

$$t = \frac{\bar{y}_1 - \bar{y}_2}{\sqrt{\frac{\hat{s}_1^2}{n_1} + \frac{\hat{s}_2^2}{n_2}}}$$

tomando la decisión de que si $|t| > t_{1-\alpha/2, gl}$ se rechaza la H_0 , siendo

$$gl = \frac{\widehat{EE}^4[\bar{Y}_1 - \bar{Y}_2]}{\frac{1}{n_1-1} \widehat{EE}^4[\bar{Y}_1] + \frac{1}{n_2-1} \widehat{EE}^4[\bar{Y}_2]}$$

Por último, como recomendaciones prácticas, conviene explicitar que las asunciones en la t de Student de normalidad se contrastan con el test de Shapiro-Wilk y la de homocedasticidad con el test de Levene.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta continua. Han participado en el estudio 17 individuos. Los datos experimentales se dan en la tabla 3.2. ¿Influye la variable explicativa en la variable respuesta?

<i>rta</i>	<i>exp</i>
15	1
15	1
25	1
25	1
25	1
33	1
43	1
15	2
16	2
16	2
25	2
28	2
28	2
28	2
28	2
35	2
43	2

Tabla 3.2: Datos observados del esquema $C \leftarrow D$

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica básica de los datos con la sintaxis siguiente

```
rm(list=ls())

datos=read.table('c_d_1.txt',header=T)
attach(datos)

ind1=which(exp==1)
ind2=which(exp==2)
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2
tapply(rta,exp,mean)
tapply(rta,exp,sd)
```

que proporcionan los estadísticos:

$$n_1 = 7 \quad ; \quad n_2 = 10$$

$$\bar{y}_1 = \frac{1}{n_1} \sum_{i_1=1}^{n_1} y_{i_1} = \frac{181}{7} = 25.8571 \quad ; \quad \bar{y}_2 = \frac{1}{n_2} \sum_{i_2=1}^{n_2} y_{i_2} = \frac{262}{10} = 26.2000$$

$$\hat{s}_1 = \sqrt{\frac{1}{n_1 - 1} \sum_{i_1=1}^{n_1} (y_{i_1} - \bar{y}_1)^2} = 9.8561 \quad ; \quad \hat{s}_2 = \sqrt{\frac{1}{n_2 - 1} \sum_{i_2=1}^{n_2} (y_{i_2} - \bar{y}_2)^2} = 8.8669$$

En segundo lugar se contrasta la normalidad y la homocedasticidad de la variable respuesta en cada grupo con la sintaxis siguiente

```
shapiro.test(rta[ind1])
shapiro.test(rta[ind2])

library(lawstat)
levene.test(rta,exp,location="mean")
```

que proporciona, en cuanto a la normalidad, para el grupo 1 un p -valor=0.3300 y para el grupo 2 un p -valor=0.2268, por lo que se asume normalidad de la respuesta en cada grupo, y en cuanto a la homocedasticidad, un p -valor=0.8982 por lo que se asume homocedasticidad.

Por último, dado que se cumplen las condiciones de aplicabilidad de la t de Student, se calcula el estadístico de contraste y su p -valor asociado con la sintaxis

```
t.test(rta[ind1],rta[ind2],var.equal=TRUE)
```

que proporciona,

$$t = \frac{\bar{y}_1 - \bar{y}_2}{\sqrt{\hat{s}_c^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} = \frac{25.8571 - 26.2000}{\sqrt{86.0305 \left(\frac{1}{7} + \frac{1}{10} \right)}} = -0.0750,$$

con $gl = 7 + 10 - 2 = 15$ y un p -valor asociado de $= 2 \cdot (1 - pt(abs(-0.0750), n1 + n2 - 2)) = 0.9412 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de medias con lo que la variable explicativa no influye en la respuesta (no hay diferencias estadísticamente significativas entre $\bar{y}_1 = 25.8571$ y $\bar{y}_2 = 26.2000$).

3.2. ANOVA de un factor

El test ANOVA de un factor está enmarcado en el esquema $C \leftarrow N$ y está indicado para variables Y normales con igual varianza (homocedasticidad) en cada categoría de la variable nominal X . La situación de $C \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si la variable pérdida de peso (medida en g) está influida por el hecho de recibir un tipo u otro de dieta. Para ello se realiza un estudio en n individuos a los que se les asigna la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificada con 2) a n_2 individuos o la dieta 3 (codificada con 3) a n_3 individuos con $n = n_1 + n_2 + n_3$ y se observa qué valor tienen en la variable pérdida de peso. En esta situación, los datos experimentales tendrán el aspecto dado en la tabla 3.3, donde el número de individuos con $X = 1$ es n_1 , con $X = 2$ es n_2 y con $X = 3$ es n_3 .

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

$$H_1 : \text{Alguna } \mu_i \text{ distinta}$$

El ANOVA de un factor se basa en el cálculo de la tabla ANOVA que se muestra en la tabla 3.4, siendo SCE la suma de cuadrados explicada (por la variable explicativa), SCR la suma de cuadrados residual (la que queda sin explicar por la variable explicativa), SCT la suma de cuadrados total, GLE los grados de libertad de la parte explicada, GLR los grados de libertad de la parte residual, GLT los grados de libertad total, CME el cuadrado medio explicado, CMR el cuadrado medio residual y CMT el cuadrado medio total que se calculan

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2
y_{31}	3
$\dots$	$\dots$
y_{3n_3}	3

Tabla 3.3: Datos genéricos del esquema $C \leftarrow N$

como

$$\begin{aligned}
SCE &= \sum_{m=1}^r n_m (\bar{y}_{m.} - \bar{y}_{..})^2 \\
SCR &= \sum_{m=1}^r \sum_{i=1}^{n_m} (\bar{y}_{mi} - \bar{y}_{m.})^2 \\
SCT &= \sum_{m=1}^r \sum_{i=1}^{n_m} (\bar{y}_{mi} - \bar{y}_{..})^2 = SCE + SCR \\
GLE &= r - 1 \\
GLR &= n - r \\
GLT &= GLE + GLR \\
CME &= \frac{SCE}{GLE} \\
CMR &= \frac{SCR}{GLR} \\
F &= \frac{CME}{CMRE}
\end{aligned}$$

con $\bar{y}_{m.}$ la media muestral de la variable respuesta en el grupo $m = 1, \dots, r$ e $\bar{y}_{..}$ la media muestral global de la variable respuesta sin tener en cuenta los grupos.

	GL	SC	CM	F	p -valor
Explicada	GLE	SCE	CME	F	asociado a F
Residual	GLR	SCR	CMR		
Total	GLT	SCT			

Tabla 3.4: Tabla ANOVA con datos genéricos del esquema $C \leftarrow N$

Por último, como recomendaciones prácticas, conviene explicitar que las asunciones en el ANOVA de un factor de normalidad se contrastan con el test de Shapiro-Wilk y la de homocedasticidad con el test de Levene.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta continua. Han participado en el estudio 22 individuos. Los datos experimentales se dan en la tabla 3.5. ¿Influye la variable explicativa en la variable respuesta?

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica básica de los datos con la sintaxis siguiente

```
rm(list=ls())
```

```
datos=read.table('c_n_1.txt',header=T)
attach(datos)
```

<i>rta</i>	<i>exp</i>
15	1
15	1
25	1
25	1
25	1
33	1
43	1
15	2
16	2
16	2
25	2
28	2
28	2
28	2
28	2
35	2
43	2
13	3
15	3
25	3
25	3
35	3

Tabla 3.5: Datos observados del esquema $C \leftarrow N$

```
ind1=which(exp==1);
ind2=which(exp==2);
ind3=which(exp==3);
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2
n3=length(rta[ind3]); n3
tapply(rta,exp,mean); tapply(rta,exp,sd)
```

que proporcionan los estadísticos:

$$n_1 = 7; n_2 = 10; n_3 = 5$$

$$\bar{y}_1 = 25.8571; \bar{y}_2 = 26.2000; \bar{y}_3 = 22.6000$$

$$\hat{s}_1 = 9.8561; \hat{s}_2 = 8.8669; \hat{s}_3 = 8.8769$$

En segundo lugar se contrasta la normalidad y la homocedasticidad de la variable respuesta en cada grupo con la sintaxis siguiente

```
shapiro.test(rta[ind1]); shapiro.test(rta[ind2]); shapiro.test(rta[ind3])

library(lawstat)
levene.test(rta,exp,location="mean")
```

que proporciona, en cuanto a la normalidad, para el grupo 1 un p -valor=0.3300, para el grupo 2 un p -valor=0.2268 y para el grupo 3 un p -valor=0.5347, por lo que se asume normalidad de la respuesta en cada grupo, y en cuanto a la homocedasticidad, un p -valor=0.9891 por lo que se asume homocedasticidad.

Por último, dado que se cumplen las condiciones de aplicabilidad del ANOVA de un factor, se calcula el estadístico de contraste y su p -valor asociado con la sintaxis

```
summary(aov(rta~factor(exp)))
```

que proporciona, la tabla 3.6.

	<i>GL</i>	<i>SC</i>	<i>CM</i>	<i>F</i>	<i>p</i> -valor
Explicada	2	46.7065	23.3532	0.2763	0.7616
Residual	19	1605.6571	84.5083		
Total	21	1652.3636			

Tabla 3.6: Tabla ANOVA con datos observados del esquema $C \leftarrow N$

El cálculo de los valores de la tabla 3.6 es el siguiente:

$$\begin{aligned}
SCE &= \sum_{m=1}^r n_m (\bar{y}_{m.} - \bar{y}_{..})^2 \\
&= 7(25.8571 - 25.2727)^2 + 10(26.200 - 25.2727)^2 + 5(22.6 - 25.2727)^2 \\
&= 46.7065 \\
SCR &= \sum_{m=1}^r \sum_{i=1}^{n_m} (\bar{y}_{mi} - \bar{y}_{m.})^2 = 1605.6571 \\
SCT &= \sum_{m=1}^r \sum_{i=1}^{n_m} (\bar{y}_{mi} - \bar{y}_{..})^2 = 1652.3636 = SCE + SCR \\
GLE &= r - 1 = 2 \\
GLR &= n - r = 22 - 3 = 19 \\
GLT &= n - 1 = 21 = GLE + GLR \\
CME &= \frac{SCE}{GLE} = 23.3532 \\
CMR &= \frac{SCR}{GLR} = 84.5083 \\
F &= \frac{CME}{CMRE} = 0.2763
\end{aligned}$$

con un p -valor asociado de $1 - pf(0.2763, 2, 19) = 0.7616 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de medias con lo que la variable explicativa no influye en la respuesta (no hay diferencias estadísticamente significativas entre $\bar{y}_1 = 25.8571$, $\bar{y}_2 = 26.2000$ y $\bar{y}_3 = 22.6000$).

Mini-capítulo 4

Respuesta nominal

En este mini-capítulo se contempla el test χ^2 de homogeneidad que está enmarcado en el esquema $N \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y nominal a través de la variable explicativa X nominal.

4.1. χ^2 de homogeneidad

El test χ^2 de homogeneidad está enmarcado en el esquema $N \leftarrow N$. La situación de $N \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si distintos tipos de efectos adversos están influidos por distintos tipos de dieta. Para ello se realiza un estudio en n individuos a los que se les asigna, por ejemplo, la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificada con 2), la dieta 3 (codificada con 3) a n_3 individuos, con $n = n_1 + n_2 + n_3$ y se observa qué tipo de efecto adverso presenta (por ejemplo, 1, 2, 3 ó 4). En esta situación los datos experimentales tendrán el patrón dado en la tabla 4.1, donde el número de individuos con perfil $Y = 1$ y $X = 1$ es n_{11} , con perfil $Y = 1$ y $X = 2$ es n_{12} , con perfil $Y = 1$ y $X = 3$ es n_{13} , con perfil $Y = 2$ y $X = 1$ es n_{21} , con perfil $Y = 2$ y $X = 2$ es n_{22} , con perfil $Y = 2$ y $X = 3$ es n_{23} , con perfil $Y = 3$ y $X = 1$ es n_{31} , con perfil $Y = 3$ y $X = 2$ es n_{32} , con perfil $Y = 3$ y $X = 3$ es n_{33} , con perfil $Y = 4$ y $X = 1$ es n_{41} , con perfil $Y = 4$ y $X = 2$ es n_{42} y con perfil $Y = 4$ y $X = 3$ es n_{43} .

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : \text{No diferencia en los grupos}$$

$$H_1 : \text{Sí diferencia en los grupos}$$

A partir de los datos experimentales se construye la tabla de datos cruzados genérica dada en la tabla 4.2, donde r_i es la suma por filas y c_j es la suma por columnas.

La expresión para el cálculo del test χ^2 de Pearson, publicada en 1900, viene dada por

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

que sigue una $\chi^2_{(r-1)(c-1)}$ donde e_{ij} son las frecuencias esperadas bajo H_0 y que se calculan como

$$e_{ij} = \frac{r_i}{n} \frac{c_j}{n} n = \frac{r_i c_j}{n}.$$

Por último, como recomendación práctica, conviene explicitar las asunciones del test χ^2 de homogeneidad que son que todos los valores de las frecuencias esperadas e_{ij} , sean mayores que 5, que intuitivamente corresponde a tamaños muestrales grandes. Así mismo, hay que señalar que numéricamente el test χ^2 de homogeneidad también se usa en el marco de asociación entre dos variables nominales donde ninguna de ellas hace el papel de variable explicativa, en ese caso se le denomina χ^2 de independencia.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta nominal. Han participado en el estudio 100 individuos. Los datos experimentales corresponden al esquema dado en la tabla 4.1 y se muestran ya tabulados en la tabla 4.3. ¿Influye la variable explicativa en la variable respuesta?

SOLUCIÓN:

Y	X
1	1
...	...
1	1
1	2
...	...
1	2
1	3
...	...
1	3
2	1
...	...
2	1
2	2
...	...
2	2
2	3
...	...
2	3
3	1
...	...
3	1
3	2
...	...
3	2
3	3
...	...
3	3
4	1
...	...
4	1
4	2
...	...
4	2
4	3
...	...
4	3

Tabla 4.1: Datos genéricos del esquema $N \leftarrow N$

	$X = 1$	$X = 2$	$X = 3$	
$Y = 1$	n_{11}	n_{12}	n_{13}	r_1
$Y = 2$	n_{21}	n_{22}	n_{23}	r_2
$Y = 3$	n_{31}	n_{32}	n_{33}	r_3
$Y = 4$	n_{41}	n_{42}	n_{43}	r_4
	c_1	c_2	c_3	n

Tabla 4.2: Tabla con datos genéricos del esquema $N \leftarrow N$

	$X = 1$	$X = 2$	$X = 3$	
$Y = 1$	3	10	14	27
$Y = 2$	10	10	14	34
$Y = 3$	6	10	3	19
$Y = 4$	14	3	3	20
	33	33	34	100

Tabla 4.3: Tabla con datos observados del esquema $N \leftarrow N$

En primer lugar se muestra la tabla 4.4 con los datos esperados. A partir de esta tabla se calcula

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - e_{ij})^2}{e_{ij}} = 23.8325$$

con un p -valor asociado de $1 - pchisq(23.8325, 6) = 0.0006 < 0.05$, por lo que sí hay evidencia suficiente para rechazar la H_0 con lo que se concluye que la variable explicativa sí influye en la respuesta (hay diferencias estadísticamente significativas entre los valores observados y los esperados bajo homogeneidad de no diferencia entre grupos).

	$X = 1$	$X = 2$	$X = 3$	
$Y = 1$	8.91	8.91	9.18	27
$Y = 2$	11.22	11.22	11.56	34
$Y = 3$	6.27	6.27	6.46	19
$Y = 4$	6.6	6.6	6.8	20
	33	33	34	100

Tabla 4.4: Tabla con datos esperados del esquema $N \leftarrow N$

En segundo lugar se muestra la sintaxis en R para el cálculo del χ^2 . Si se supone que los datos sin agrupar están en el fichero `n_n_1.txt` la sintaxis es

```
rm(list=ls())

datos=read.table('n_n_1.txt',header=T)
attach(datos)

tabla=table(rta,exp); tabla
chisq.test(tabla)\$expected

chisq.test(tabla)
```

y si se supone que se introducen los datos agrupados directamente la sintaxis es

```
rm(list=ls())

tabla <- matrix(c(3,10,14,10,10,14,6,10,3,14,3,3),ncol=3,byrow=TRUE)
colnames(tabla) <- c("exp=1","exp=2","exp=3")
rownames(tabla) <- c("rta=1","rta=2","rta=3","rta=4")
tabla <- as.table(tabla); tabla
chisq.test(tabla)\$expected
```


Mini-capítulo 5

Respuesta ordinal

En este mini-capítulo se contemplan el test U de Mann-Whitney, el test W de Wilcoxon y el test H de Kruskal-Wallis. El test U de Mann-Whitney y el test W de Wilcoxon están enmarcados en el esquema $O \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y ordinal a través de la variable explicativa X dicotómica y el test H de Kruskal-Wallis está enmarcado en el esquema $O \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y ordinal a través de la variable explicativa X nominal.

5.1. U de Mann-Whitney

El test U de Mann-Whitney está enmarcado en el esquema $O \leftarrow D$, aunque también se puede usar en el esquema $C \leftarrow D$ donde no se cumpla la asunción de que la variable Y sea normal en cada categoría de la variable dicotómica X . La situación de $O \leftarrow D$ se da, por ejemplo, cuando se quiere estudiar si la variable grado de mejoría (codificada por ejemplo con 1 si algo, 2 bastante, 3 casi total y 4 total) está influida por el hecho de recibir un tratamiento u otro. Para ello se realiza un estudio en n individuos a los que se les asigna el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2 en la variable tratamiento) a n_2 individuos con $n = n_1 + n_2$ y se observa qué valor ordinal tienen en la variable grado de mejoría. En esta situación los datos experimentales tendrán el aspecto dado en la tabla 5.1, donde el número de individuos con $X = 1$ es n_1 y con $X = 2$ es n_2 .

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2

Tabla 5.1: Datos genéricos del esquema $O \leftarrow D$

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : F_1 = F_2$$

$$H_1 : F_1 \neq F_2$$

siendo F_1 y F_2 las funciones de distribución de la variable respuesta para el grupo 1 y el grupo 2, respectivamente.

La expresión para el cálculo de la U de Mann-Whitney, publicada en 1947, viene dada por $U_{Y_1 Y_2}$ o por $U_{Y_2 Y_1}$ donde

$$U_{Y_1 Y_2} = \#\{y_{1i_1} < y_{2i_2}\}$$

$$U_{Y_2 Y_1} = \#\{y_{2i_2} < y_{1i_1}\},$$

siendo y_{1i_1} los valores de la variable respuesta para el grupo 1, $i_1 = 1, \dots, n_1$, e y_{2i_2} los valores de la variable respuesta para el grupo 2, $i_2 = 1, \dots, n_2$, y donde la notación $\#\{ \}$ representa el número de pares que verifica la condición entre llaves, teniendo en cuenta que cualquier par con $y_{1i} = y_{2i}$ suma $\frac{1}{2}$ en el cálculo de $U_{Y_1 Y_2}$ o de $U_{Y_2 Y_1}$. Es fácil ver que $U_{Y_1 Y_2} + U_{Y_2 Y_1} = n_1 n_2$.

Para llevar a cabo el contraste requerido se construye el estadístico de contraste

$$z = \frac{U_{Y_1 Y_2} - \widehat{E}[U_{Y_1 Y_2}]}{\widehat{EE}[U_{Y_1 Y_2}]} = \frac{U_{Y_2 Y_1} - \widehat{E}[U_{Y_2 Y_1}]}{\widehat{EE}[U_{Y_2 Y_1}]}$$

que sigue una $N(0, 1)$, siendo

$$\widehat{E}[U_{Y_1 Y_2}] = \widehat{E}[U_{Y_2 Y_1}] = \frac{1}{2} n_1 n_2$$

$$\widehat{EE}[U_{Y_1 Y_2}] = \widehat{EE}[U_{Y_2 Y_1}] = \sqrt{\frac{1}{12} \frac{n_1 n_2}{n(n-1)} \left(n^3 - n - \sum_{j=1}^k (d_j^3 - d_j) \right)},$$

con d_j el número de empates en $j = 1, \dots, k$ siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta ordinal. Han participado en el estudio 17 individuos. Los datos experimentales se dan en la tabla 5.2. ¿Influye la variable explicativa en la variable respuesta?

<i>rta</i>	<i>exp</i>
1	1
1	1
3	1
3	1
3	1
5	1
7	1
1	2
2	2
2	2
3	2
4	2
4	2
4	2
4	2
6	2
7	2

Tabla 5.2: Datos observados del esquema $O \leftarrow D$

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica y gráfica básica de los datos con la sintaxis siguiente

```
rm(list=ls())

datos=read.table('o_d_1.txt',header=T)
attach(datos)

ind1=which(exp==1)
ind2=which(exp==2)
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2

tapply(rta,exp,median); tapply(rta,exp,IQR)

boxplot(rta[ind1],rta[ind2],names=c("1","2"),col=(c("white","gray")),
xlab="Grupo 1 (white), Grupo 2 (gray)", ylab="Rta")
```

que proporcionan los estadísticos:

$$n_1 = 7 \quad ; \quad n_2 = 10$$

$$\text{mediana } (y)_1 = 3 \quad ; \quad \text{mediana } (y)_2 = 4$$

$$\text{rango intercuartílico } (y)_1 = 2.0000 \quad ; \quad \text{rango intercuartílico } (y)_2 = 1.7500$$

y el gráfico de Box-Plot dado en la figura 5.1.




Figura 5.1: Box-Plot para los datos observados del esquema $O \leftarrow D$

A continuación se muestran los cálculos detallados de la U de Mann-Whitney:

$$\begin{aligned}
 U_{Y_1 Y_2} &= \left(\frac{1}{2} + 9\right) + \left(\frac{1}{2} + 9\right) + \left(\frac{1}{2} + 6\right) + \left(\frac{1}{2} + 6\right) \\
 &\quad + \left(\frac{1}{2} + 6\right) + (2) + \left(\frac{1}{2}\right) = 41 \\
 U_{Y_2 Y_1} &= \left(\frac{1}{2} + \frac{1}{2} + 5\right) + (5) + (5) + \left(\frac{3}{2} + 2\right) + (2) + (2) \\
 &\quad + (2) + (2) + (1) + \left(\frac{1}{2}\right) = 29 \\
 U_{Y_1 Y_2} + U_{Y_2 Y_1} &= 70 = n_1 n_2 \\
 \widehat{E}[U_{Y_1 Y_2}] &= \widehat{E}[U_{Y_2 Y_1}] = \frac{1}{2} n_1 n_2 = \frac{1}{2} \cdot 70 = 35 \\
 \sum_{j=1}^k (d_j^3 - d_j) &= (3^3 - 3) + (2^3 - 2) + (4^3 - 4) + (4^3 - 4) + (2^3 - 2) = 156 \\
 \widehat{EE}[U_{Y_1 Y_2}] &= \widehat{EE}[U_{Y_2 Y_1}] = \sqrt{\frac{1}{12} \frac{n_1 n_2}{n(n-1)} \left(n^3 - n - \sum_{j=1}^k (d_j^3 - d_j) \right)} \\
 &= \sqrt{\frac{1}{12} \frac{70}{17 \cdot 16} (17^3 - 17 - 156)} = \sqrt{101.6544} = 10.0824 \\
 z &= \frac{U_{Y_2 Y_1} - \widehat{E}[U_{Y_2 Y_1}]}{\widehat{EE}[U_{Y_2 Y_1}]} = \frac{29 - 35}{10.0824} = -0.5951
 \end{aligned}$$

Dichos cálculos se realizan con la sintaxis

```
wilcox.test(rta[ind1], rta[ind2], correct=FALSE)
```

que proporciona, $U_{Y_2 Y_1} = 29$ y un p -valor asociado igual a $2 \cdot (1 - \text{pnorm}(\text{abs}(-0.5951))) = 0.5518 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

5.2. W de Wilcoxon

El test W de Wilcoxon está enmarcado en el esquema $O \leftarrow D$, al igual que el test U de Mann-Whitney, por lo que los datos experimentales tendrán el aspecto anterior dado en la tabla 5.1. Conviene remarcar que ambos tests son además equivalentes.

Como en el test de U de Mann-Whitney, la pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$\begin{aligned} H_0 : F_1 &= F_2 \\ H_1 : F_1 &\neq F_2 \end{aligned}$$

siendo F_1 y F_2 las funciones de distribución de la variable respuesta para el grupo 1 y el grupo 2, respectivamente.

La expresión para el cálculo de la W de Mann-Whitney, publicada en 1945, viene dada por W_1 o por W_2 con

$$W_1 = \sum_{\text{grupo}_1} \text{Rangos}$$

$$W_2 = \sum_{\text{grupo}_2} \text{Rangos},$$

donde los rangos se calculan en relación a la muestra conjunta y en el caso de empates como promedios de los órdenes de las observaciones empatadas. Es fácil ver que $W_1 + W_2 = \frac{1}{2}n(n+1)$.

Para llevar a cabo el contraste requerido se construye el estadístico de contraste

$$z = \frac{W_1 - \widehat{E}[W_1]}{\widehat{EE}[W_1]} = \frac{W_2 - \widehat{E}[W_2]}{\widehat{EE}[W_2]}$$

que sigue una $N(0, 1)$, siendo

$$\widehat{E}[W_1] = \frac{1}{2}n_1(n+1)$$

$$\widehat{E}[W_2] = \frac{1}{2}n_2(n+1)$$

$$\widehat{EE}[W_1] = \widehat{EE}[W_2] = \sqrt{\frac{1}{12} \frac{n_1 n_2}{n(n-1)} \left(n^3 - n - \sum_{j=1}^k (d_j^3 - d_j) \right)},$$

con d_j el número de empates en $j = 1, \dots, k$ siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta ordinal. Han participado en el estudio 17 individuos. Los datos experimentales son los mismos que se utilizaron en el test U de Mann-Whitney y se dan en la tabla 5.2. ¿Influye la variable explicativa en la variable respuesta?

SOLUCIÓN:

La estadística descriptiva numérica y gráfica básica de los datos es la que se mostró en el test U de Mann-Whitney. Los cálculos detallados del test W de Wilcoxon se basan en rangos por lo que como paso previo se asigna a cada observación un rango según el orden que ocupe dicha observación en el cómputo total de datos, asignando el rango medio en caso de empates, según se muestra en la tabla 5.3.

<i>rta</i>	<i>exp</i>	<i>Rango(rta)</i>
1	1	$\frac{1+2+3}{3} = 2$
1	1	$\frac{1+2+3}{3} = 2$
3	1	$\frac{6+7+8+9}{4} = 7.5$
3	1	$\frac{6+7+8+9}{4} = 7.5$
3	1	$\frac{6+7+8+9}{4} = 7.5$
5	1	14
7	1	$\frac{16+17}{2} = 16.5$
1	2	$\frac{1+2+3}{3} = 2$
2	2	$\frac{4+5}{2} = 4.5$
2	2	$\frac{4+5}{2} = 4.5$
3	2	$\frac{6+7+8+9}{4} = 7.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
6	2	15
7	2	$\frac{16+17}{2} = 16.5$

Tabla 5.3: Rangos para los datos observados del esquema $O \leftarrow D$

A partir de estos rangos, se calculan los valores siguientes:

$$\begin{aligned}
W_1 &= \sum_{\text{grupo}_1} \text{Rangos} = 2 + 2 + 7.5 + 7.5 + 7.5 + 14 + 16.5 = 57 \\
W_2 &= \sum_{\text{grupo}_2} \text{Rangos} = 2 + 4.5 + 4.5 + 7.5 + 11.5 + 11.5 + 11.5 + 11.5 + 16.5 \\
&= 96 \\
W_1 + W_2 &= 153 = \frac{1}{2}n(n+1) \\
\widehat{E}[W_1] &= \frac{1}{2}n_1(n+1) = \frac{1}{2} \cdot 7 \cdot 18 = 63 \\
\widehat{E}[W_2] &= \frac{1}{2}n_2(n+1) = \frac{1}{2} \cdot 10 \cdot 18 = 90 \\
\sum_{j=1}^k (d_j^3 - d_j) &= (3^3 - 3) + (2^3 - 2) + (4^3 - 4) + (4^3 - 4) + (2^3 - 2) = 156 \\
\widehat{EE}[W_1] &= \widehat{EE}[W_2] = \sqrt{\frac{1}{12} \frac{n_1 n_2}{n(n-1)} \left(n^3 - n - \sum_{j=1}^k (d_j^3 - d_j) \right)} \\
&= \sqrt{\frac{1}{12} \frac{70}{17 \cdot 16} (17^3 - 17 - 156)} = \sqrt{101.6544} = 10.0824 \\
z &= \frac{W_1 - \widehat{E}[W_1]}{\widehat{EE}[W_1]} = \frac{57 - 63}{10.0824} = -0.5951
\end{aligned}$$

Dichos cálculos se realizan con la sintaxis

```
wilcox.test(rta[ind1], rta[ind2], correct=FALSE)
```

que no proporciona el test de Wilcoxon, sino su equivalente de U de Mann-Whitney, con un p -valor igual a $2 \cdot (1 - pnorm(abs(-0.5951))) = 0.5518 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

5.3. H de Kruskal-Wallis

El test H de Kruskal-Wallis está enmarcado en el esquema $O \leftarrow N$, aunque también se puede usar en el esquema $C \leftarrow N$ donde no se cumpla la asunción de que la variable Y sea normal en cada categoría de la variable dicotómica X . La situación de $O \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si la variable grado de pérdida de peso (codificada por ejemplo con 1 si se ha perdido entre 0-5 kilos, 2 si 5-10, 3 si 10-15 y 4 si > 15) está influida por el hecho de recibir un tipo u otro de dieta. Para ello se realiza un estudio en n individuos a los que se les asigna la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificado con 2) a n_2 individuos o la dieta 3 (codificada con 3) a n_3 individuos con $n = n_1 + n_2 + n_3$ y se observa qué valor ordinal tienen en la variable grado de pérdida de peso. En esta situación, los datos experimentales tendrán el aspecto dado en la tabla 5.4, donde el número de individuos con $X = 1$ es n_1 , con $X = 2$ es n_2 y con $X = 3$ es n_3 .

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2
y_{31}	3
$\dots$	$\dots$
y_{3n_3}	3

Tabla 5.4: Datos genéricos del esquema $O \leftarrow N$

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$\begin{aligned} H_0 : F_1 &= F_2 = F_3 \\ H_1 : &\text{Alguna } F_i \text{ distinta} \end{aligned}$$

siendo F_1 , F_2 y F_3 las funciones de distribución de la variable respuesta para el grupo 1, el grupo 2 y el grupo 3, respectivamente.

La expresión para el cálculo de la H de Kruskal-Wallis, publicada en 1952, viene dada por

$$H = \frac{\frac{12}{n(n+1)} \sum_{m=1}^r \frac{1}{n_m} (R_m - \widehat{E}[R_m])^2}{1 - \frac{\sum_{j=1}^k (d_j^3 - d_j)}{n^3 - n}}$$

que sigue una χ_{r-1}^2 , siendo

$$R_m = \sum_{\text{grupo}_m} \text{Rangos}, \quad \widehat{E}[R_m] = \frac{n_m(n+1)}{2}$$

con $m = 1, \dots, r$ indicando el grupo y d_j el número de empates en $j = 1, \dots, k$ siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta ordinal. Han participado en el estudio 22 individuos. Los datos experimentales se dan en la tabla 5.5. ¿Influye la variable explicativa en la variable respuesta?

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica y gráfica básica de los datos con la sintaxis siguiente

<i>rta</i>	<i>exp</i>
2	1
2	1
4	1
4	1
4	1
6	1
8	1
2	2
3	2
3	2
4	2
5	2
5	2
5	2
5	2
7	2
8	2
1	3
2	3
4	3
4	3
7	3

Tabla 5.5: Datos observados del esquema $O \leftarrow D$

```
rm(list=ls())

datos=read.table('o_n_1.txt',header=T)
attach(datos)

ind1=which(exp==1);
ind2=which(exp==2);
ind3=which(exp==3);
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2
n3=length(rta[ind3]); n3
tapply(rta,exp,median); tapply(rta,exp,IQR)

boxplot(rta[ind1],rta[ind2],rta[ind3],names=c("1","2","3"),
col=c("white","gray80","gray50")),
xlab="Grupo 1 (white), Grupo 2 (gray80), Grupo 3 (gray50)", ylab="Rta")
```

que proporcionan los estadísticos:

$$\begin{aligned}
n_1 &= 7 \quad ; \quad n_2 = 10 \quad ; \quad n_3 = 5 \\
\text{mediana } (y)_1 &= 4 \quad ; \quad \text{mediana } (y)_2 = 5 \quad ; \quad \text{mediana } (y)_3 = 4 \\
\text{rango inter. } (y)_1 &= 2.0000 \quad ; \quad \text{rango inter. } (y)_2 = 1.7500 \quad ; \quad \text{rango inter. } (y)_3 = 2.0000
\end{aligned}$$

y el gráfico de Box-Plot dado en la figura 5.2.

Los cálculos detallados del test H de Kruskal-Wallis se basan en rangos por lo que como paso previo se asigna a cada observación un rango según el orden que ocupe dicha observación en el cómputo total de datos, asignando el rango medio en caso de empates, según se muestra en la tabla 5.6.




Figura 5.2: Box-Plot para los datos observados del esquema $O \leftarrow N$

A partir de estos rangos, se calculan los valores siguientes:

$$\begin{aligned}
 R_1 &= \sum_{grupo_1} Rangos = 78 \\
 R_2 &= \sum_{grupo_2} Rangos = 130 \\
 R_3 &= \sum_{grupo_3} Rangos = 45 \\
 \hat{E}[R_1] &= \frac{1}{2}n_1(n+1) = \frac{1}{2} \cdot 7 \cdot 23 = 80.50 \\
 \hat{E}[R_2] &= \frac{1}{2}n_2(n+1) = \frac{1}{2} \cdot 10 \cdot 23 = 115.00 \\
 \hat{E}[R_3] &= \frac{1}{2}n_3(n+1) = \frac{1}{2} \cdot 5 \cdot 23 = 57.50 \\
 \sum_{j=1}^k (d_j^3 - d_j) &= (4^3 - 4) + (2^3 - 2) + (6^3 - 6) + (4^3 - 4) \\
 &\quad + (2^3 - 2) + (2^3 - 2) = 348 \\
 H &= \frac{\frac{12}{22 \cdot 23} \left(\frac{1}{7}(78 - 80.50)^2 + \frac{1}{10}(130 - 115.00)^2 + \frac{1}{5}(45 - 57.50)^2 \right)}{1 - \frac{348}{22^3 - 22}} \\
 &= 1.3398
 \end{aligned}$$

Dichos cálculos se realizan con la sintaxis

`kruskal.test(rta~exp)`

que proporciona, $H = 1.3398$ con $gl = r - 1 = 3 - 1 = 2$ y un p -valor asociado igual a $1 - pchisq(1.3398, 2) = 0.5118 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

<i>rta</i>	<i>exp</i>	<i>Rango(rta)</i>
2	1	$\frac{2+3+4+5}{4} = 3.5$
2	1	$\frac{2+3+4+5}{4} = 3.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
6	1	18
8	1	$\frac{21+22}{2} = 21.5$
2	2	$\frac{2+3+4+5}{4} = 3.5$
3	2	$\frac{6+7}{2} = 6.5$
3	2	$\frac{6+7}{2} = 6.5$
4	2	$\frac{8+9+10+11+12+13}{6} = 10.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
7	2	$\frac{19+20}{2} = 19.5$
8	2	$\frac{21+22}{2} = 21.5$
1	3	1
2	3	$\frac{2+3+4+5}{4} = 3.5$
4	3	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	3	$\frac{8+9+10+11+12+13}{6} = 10.5$
7	3	$\frac{19+20}{2} = 19.5$

Tabla 5.6: Rangos para los datos observados del esquema $O \leftarrow N$

Referencias

- T.M. Davies. *The Book of R: A First course in programming and statistics*. No Starch Press, 2016.
- A. García-Pérez. *Estadística básica con R*. Universidad Nacional de Educación a Distancia (UNED), Madrid, 2010.
- D. Peña. *Fundamentos de Estadística*. Alianza editorial, Madrid, 2014.
- R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2017. URL <https://www.R-project.org/>.
- E. Ramos, R. Vélez, and V. Hernández. *Modelos probabilísticos y optimización*. Sanz y Torres, Madrid, 2019.

Glosario

Distribución: el término distribución es sinónimo de modelo, así si se dice que una variable aleatoria sigue una distribución Bernoulli, se quiere decir que su modelo es Bernoulli. Se usa la palabra distribución en referencia a que el concepto función de distribución es común tanto para las variables aleatorias discretas como continuas.

Esperanza matemática: la esperanza matemática de una variable aleatoria Y se define, siempre que se conozca el modelo o distribución de Y , y se denota por $E[Y]$. Para variables aleatorias discretas, siempre y cuando $\sum_{y_i} \text{abs}(y_i)p(y_i) < \infty$, se define $E[Y] = \sum_{y_i} y_i p(y_i)$. Para variables aleatorias continuas, siempre y cuando $\int_{-\infty}^{+\infty} \text{abs}(y)f(y)dy < \infty$, se define $E[Y] = \int_{-\infty}^{+\infty} yf(y)dy$. En muchos libros de texto no se especifican las condiciones de convergencia, pero son necesarias. Por ejemplo el modelo o distribución de Cauchy no la verifica y esa es la razón teórica por la que el modelo de Cauchy no tiene definida su esperanza matemática. Este aspecto se puede comprobar simulando la distribución de Cauchy y viendo el comportamiento errático de su media muestral.

Teorema central del límite: existen varias formulaciones de este teorema. Una de la más sencilla es la siguiente. Si Y_i son variables aleatorias independientes idénticamente distribuidas (v.a.i.i.d) con media y varianza finita, entonces $\bar{Y}$ sigue una distribución Normal para n suficientemente grande. Los parámetros de dicha normal son muy fáciles de calcular a través de las propiedades teóricas de la esperanza y de la varianza. Este teorema no se puede aplicar a la Cauchy ya que ésta no tiene esperanza matemática definida. Sin embargo, es posible determinar la distribución de la media muestral de Cauchy, que sorprendentemente sigue siendo Cauchy.

Variables explicativas: también llamadas independientes, son las variables candidatas a servir de explicación de las variables respuesta.

Variables respuesta: también llamadas dependientes, resultado u objetivo, son las variables que se pretende explicar o analizar.

Acerca de

Emilio Letón



Figura 5.3: Emilio Letón

Emilio Letón nace en Madrid en 1966. Es Licenciado en Matemáticas por la UCM en 1989 y doctor en Matemáticas en la misma universidad en 2002. En la actualidad es profesor contratado doctor de la UNED en el departamento de Inteligencia Artificial, al que se incorporó en 2009. Anteriormente fue profesor del departamento de Estadística de la UC3M durante 5 años. Asimismo, ha trabajado durante 15 años en departamentos de Planificación y Estadística dentro del sector bancario y de la industria farmacéutica. Sus líneas de investigación incluyen el Análisis de Supervivencia, tests no paramétricos, PLS, Meta-Análisis, Bioestadística y B-Learning. Ha participado en más de 30 proyectos de innovación docente (siendo coordinador en más de 10 de ellos) colaborando con distintas universidades: UNED, UC3M, UCM y UPM. Ha recibido 1 premio en excelencia en publicaciones científicas (UC3M) y 5 premios en excelencia docente (1 en UC3M, 3 en UNED y 1 en OCW Consortium). En @emilioleton se pueden encontrar sus tweets y su página web personal con información ampliada de su curriculum. <https://twitter.com/emilioleton>

Elisa M. Molanes-López



Figura 5.4: Elisa M. Molanes-López

Elisa M. Molanes López nace en Vigo en 1976. Se licencia en Matemáticas por la Universidad de Santiago de Compostela en 2000 y consigue el grado de doctora, con acreditación europea, por la Universidad de A Coruña en 2007. Entre 2003 y 2007, al amparo de una beca FPI, realiza varias estancias de investigación

en las siguientes universidades extranjeras: Universiteit Hasselt (Bélgica), Université Catholique de Louvain (Bélgica) y The University of Texas (EE.UU.). Durante 8 años, entre 2007 y 2015, es profesora visitante en el departamento de Estadística de la Universidad Carlos III de Madrid. En la actualidad es profesora contratada doctora en la Unidad Departamental de Bioestadística de la Universidad Complutense de Madrid, a la que se incorporó en 2015. Durante su etapa docente ha participado en 10 proyectos de innovación docente. En diciembre de 2013, recibe un accésit a la mejor práctica docente en los Premios del Consejo Social de la UNED por su participación en el MOOC "Mini-videos docentes modulares: un elemento crítico en el diseño de un MOOC", y en abril de 2014, el OpenCourseWare Consortium le otorga un premio de excelencia por su participación en el curso OCW "Mini-videos docentes modulares para diseñar un MOOC". Sus líneas de investigación incluyen la estadística no paramétrica, el análisis de supervivencia, las curvas ROC y las funciones cópula. En la página web personal de Elisa M. Molanes-López, se puede encontrar información más detallada. <https://elisamariamolanes.wixsite.com/emolanes>