

Memoria Práctica 1

David García Curbelo

6 de noviembre de 2024

Índice

1. Introducción	3
2. Técnicas	6
3. Resultados	7
4. Conclusiones	8

1. Introducción

La creciente disponibilidad de datos y el avance de las técnicas computacionales han permitido el desarrollo de una amplia variedad de algoritmos de aprendizaje supervisado: desde algoritmos clásicos hasta estructuras mucho más complejas como las redes neuronales. Cada uno de ellos presenta sus ventajas y desventajas, variando incluso su efectividad en función del contexto en el que se aplique. Es por ello que la selección del modelo adecuado para un problema a estudiar se convierte en una tarea crítica y de gran relevancia, especialmente en aplicaciones donde su correcta selección puede tener un impacto significativo en la toma de decisiones posterior. Sin embargo, el proceso de seleccionar el mejor entre varios algoritmos no es una tarea trivial; involucra la evaluación precisa de su rendimiento, así como una comprensión profunda de los datos y del comportamiento de los modelos en diversos escenarios.

En respuesta a estos desafíos, se han desarrollado diversas metodologías para evaluar y seleccionar modelos de manera robusta. Una de las propuestas más simple y conocida es la propuesta por McNemar, donde propone una comparación directa entre dos modelos en un mismo conjunto de datos, permitiendo evaluar si las diferencias en las tasas de error son estadísticamente significativas [4]. Este enfoque es particularmente útil en contextos donde los datos de prueba están emparejados y la comparación simple de la medida de evaluación no es suficiente. La simplicidad y precisión de este test lo ha convertido en un recurso fundamental para validar mejoras en clasificadores, al proporcionar un método sólido para evaluar la diferencia de rendimiento en un mismo contexto experimental.

Existen también algunas variaciones al test de McNemar. Una de las más usadas es el estudio de la diferencia entre los ratios de error de cada modelo. Basado en la tabla de contingencia que se genera en el test anterior (calculada mediante la evaluación sobre el conjunto de testeo), podemos calcular el ratio de error por muestra para cada modelo, y evaluar si la diferencia de estos errores es significativa. Estos ratios generan dos variables aleatorias que presentan cada una una distribución binomial, donde la diferencia de ambos ratios puede ser aproximada a una normal [5]. Esto presenta ciertas ventajas con respecto al test de McNemar, ya que para variaciones muy bajas entre los errores cometidos por cada modelo, este enfoque permite ser más preciso ante estas pequeñas variaciones. Sin embargo, el test asume independencia entre las dos variables aleatorias, a pesar de que no siempre contemos con esa premisa.

Además, en las perspectivas anteriores, la evaluación sobre un único conjunto de datos puede proporcionarnos una visión sesgada sobre la decisión

del modelo seleccionado. Es por ello que los resultados de Bouckaert hacen énfasis en la necesidad de asegurar que los resultados obtenidos en un conjunto de datos puedan ser reproducibles en experimentos futuros. Su enfoque destaca la importancia de emplear técnicas de validación que sean capaces de obtener estimaciones confiables del rendimiento esperado de los clasificadores [1]. La replicabilidad, en este sentido, se convierte en un criterio crucial: no es suficiente que un modelo ofrezca un rendimiento superior en un único conjunto de prueba; debe ser capaz de mantener este rendimiento de manera consistente en distintos conjuntos de datos. Esto plantea un cambio de paradigma que reconoce el papel de la estabilidad estadística en la selección de modelos, apuntando a mejorar la confiabilidad de los experimentos de aprendizaje automático.

Sin embargo, de forma habitual contamos sólo con datos reducidos y provenientes de una cantidad limitada de fuentes. Es por ello que, ante este paradigma, surgen varias alternativas que pretenden afrontar el problema mediante un remuestreo aleatorio de los datos. Con esta técnica se pretende generar múltiples subconjuntos de entrenamiento y prueba, mitigando el sesgo de la partición generado por los enfoques previos y consiguiendo una mayor fiabilidad de la evaluación. Una de las vías más sencillas ante este paradigma es el t -test para muestras pareadas, lo cual es mucho más robusto que una prueba simple de t -test, ya que considera la variabilidad entre particiones aleatorias de datos.

Otro enfoque muy interesante y reconocido es la validación cruzada para k particiones en muestras pareadas, que proporciona una perspectiva robusta para comparar los modelos en múltiples divisiones del conjunto de datos. Este método permite obtener estimaciones de rendimiento medio y evaluar si las diferencias observadas entre modelos son estadísticamente significativas. Sin embargo, una de sus limitaciones radica en la asunción de independencia entre las particiones, lo cual no siempre se cumple, especialmente en conjuntos de datos pequeños o altamente correlacionados. Esta dependencia puede resultar en una subestimación de la varianza y llevar a conclusiones erróneas sobre la significancia de las diferencias entre los modelos. Además, la técnica puede ser computacionalmente costosa cuando se utilizan modelos complejos o conjuntos grandes de datos, ya que requiere múltiples ejecuciones de entrenamiento y evaluación.

Un enfoque más particular, manteniendo la perspectiva de replicabilidad, es el dado por Dietterich, el cual propone la introducción de ciertas pruebas que mitiguen el riesgo de obtener resultados falsamente significativos [3]. Su propuesta del *5x2 cross-validation t-test* (que abordaremos en el siguiente punto) responde a la necesidad de un método que controle tanto la varianza como el sesgo en los resultados experimentales. Al implementar múltiples par-

ticiones y combinarlas con pruebas t de diferencia de medias, se proporciona así una metodología que reduce el riesgo de errores tipo I (falsos positivos) en la comparación de algoritmos. Sin embargo, este alto nivel de particiones y de cálculos requiere consecuentemente una alta demanda computacional, que dependiendo de el tamaño de los datos disponibles puede suponer un impedimento sustancial. Además, ante situaciones donde la distribución del error no es normal los resultados pueden perder fiabilidad y por tanto un decaimiento del rendimiento real.

En entornos donde los datos no cumplen estas suposiciones de normalidad, otra línea de abordaje incluye el uso de pruebas no paramétricas, como el test de Friedman y el test de Wilcoxon [2], que no asumen normalidad en la distribución de los errores de los clasificadores. Estas pruebas ofrecen una robustez mayor frente a distribuciones complejas y datos dependientes, siendo útiles cuando se necesita comparar múltiples modelos de forma simultánea o cuando los datos presentan sesgos estructurales. Pero, a pesar de su robustez, es necesario aplicar técnicas de corrección de significancia, tales como Bonferroni y Holm. Estas correcciones son realizadas para evitar el riesgo de errores tipo I, especialmente en comparaciones múltiples, que pueden llevar a la selección de un modelo aparentemente superior pero en realidad insustancial. El problema que presentan estas correcciones es que puede reducir la sensibilidad de las pruebas, dificultando la detección de diferencias reales entre modelos.

En conjunto, estas metodologías han contribuido significativamente a establecer un marco de trabajo para la selección de modelos, ofreciendo herramientas más robustas y adaptativas frente a la variabilidad y la incertidumbre de los datos. Sin embargo, los retos permanecen y el campo sigue evolucionando, buscando constantemente métodos que mejoren la replicabilidad y la capacidad de generalización de los modelos, a la vez que optimizan el proceso de selección en aplicaciones de alta demanda computacional y de datos.

2. Técnicas

Se propone la aplicación de dos técnicas de selección de algoritmos al conjunto de datos *Iris* para la evaluación de dos modelos de clasificación: *Näive Bayes* y *K Nearest Neighbors* para $k = 3$. Se aplicarán los test de McNemar y el *5x2 cross-validation t-test* para comparar ambos modelos. Debido a que los datos etiquetados sobre la clase *Setosa* son claramente separables, realizaremos el estudio sobre las dos etiquetas restantes, que sí presentan solapamiento de distribuciones y resultará más interesante para este estudio.

El test de McNemar nos proporciona para nuestro caso de uso una alta simplicidad de implementación, en el que con escasos cálculos podemos tomar una decisión fundamentada. Sin embargo, presenta ciertas limitaciones (que en este estudio se verán reflejadas) para afrontar problemas de evaluación con pocos datos, como es nuestro caso actual. Al necesitar un conjunto de testeo, se realizará una división arbitraria, lo que sesgará el resultado posterior del test. Dependiendo de cómo dividamos estos conjuntos, puede provocar que para dos situaciones similares, aceptemos o rechacemos la hipótesis nula, lo que hace inestable el test para casos con tan pocos datos.

Por otro lado, el test *5x2 cross-validation t-test* es un test que hace uso de todos los datos, lo que lo hace a priori más robusto que otros enfoques. Además, conseguimos reducir la varianza de la estimación realizada, lo que nos proporciona una mayor precisión de la estimación. Sin embargo, se trata de un test bastante conservador, que podría no distinguir pequeñas diferencias de rendimiento entre modelos. Sumado a ésto, la división arbitraria sigue manteniendo el problema de dividir conjuntos que no tienen por qué ser independientes, aún siendo un requerimiento del mismo. Además, este test presenta una demanda computacional muy alta en comparación con el test de McNemar, que puede llegar a ser (no necesariamente en nuestro caso) un inconveniente a la hora de decidir cómo afrontar el presente problema.




Figura 1: Distribuciones de los datos seleccionados. En naranja Versicolor y en verde Virginica para las cuatro características.

3. Resultados

Para la comparación de los modelos entrenados se ha seleccionado como medida de rendimiento la precisión (accuracy). Esta medida es adecuada para este conjunto de datos, dado que las clases están equilibradas, permitiendo una interpretación directa de la capacidad de cada modelo para clasificar correctamente las especies de Iris. Además, para ambos test vamos a establecer un nivel de significancia $\alpha = 0,05$ para estudiar la aceptación o rechazo de la hipótesis nula H_0 de igualdad de rendimiento entre ambos modelos.

Para la aplicación del test de McNemar se ha construido una matriz de confusión para los resultados de predicción de ambos modelos, donde se identifican los casos de falsos positivos y falsos negativos para un conjunto de test del 30 % con división estratificada. Con ello, calculamos el estadístico de McNemar χ^2 para su tabla de contingencia:

	<i>Acierto</i> ₁	<i>Error</i> ₁
<i>Acierto</i> ₂	25	2
<i>Error</i> ₂	1	2

$$\chi^2 = \frac{(b - c)^2}{b + c} = \frac{1}{3} \quad (1)$$

donde b son los errores de KNN que Naive Bayes clasificó correctamente, y c son los errores de Näive Bayes que KNN clasificó correctamente¹. Tomando este valor del estadístico para un grado de libertad, obtenemos un valor de $p \simeq 0,56 > \alpha$, por lo que no podemos rechazar la hipótesis nula de que las tasas de error de ambos modelos son estadísticamente iguales mediante el uso de este test.

En la aplicación del *test 5x2 cross-validation t-test*, hemos realizado 5 fragmentaciones aleatorias de 50/50 en los datos (también de forma estratificada), entrenado las instancias de modelos y calculado el estadístico $\hat{t}$ con los resultados obtenidos en cada una de las particiones. Obtenemos lo siguiente:

$$\hat{t} = \frac{p_1^{(1)}}{\frac{1}{5} \sum_{i=1}^5 s_i^2} = -0,4082 \quad (2)$$

Por tanto, al calcular el valor de p para 5 grados de libertad, el estadístico $\hat{t}$ nos proporciona un valor de $p \simeq 0,70 > \alpha$, lo que nos indica que tampoco en este caso podemos rechazar la hipótesis nula de igualdad de rendimiento de ambos modelos mediante el uso de este test.

¹Los subíndices 1 y 2 en la tabla de contingencia son los asociados a los modelos Näive Bayes y KNN, respectivamente.

4. Conclusiones

Ambos modelos han rechazado la hipótesis nula, aportando valores de estadístico (tanto para $\hat{t}$ como para χ^2) de magnitudes bastante bajas (ambas muy cercanas a cero). Esto nos indica que las diferencias de rendimiento entre los modelos en las particiones evaluadas son pequeñas, lo que concuerda con los valores altos obtenidos en el cálculo del valor de p . Esto sugiere que probablemente las diferencias observadas han sido azarosas y no fruto de diferencias de rendimiento significativas en ambos modelos.

Además, nos hemos enfrentado a un problema en el que, tanto el conjunto de datos de entrenamiento como de testeo, presentan un tamaño demasiado pequeño (100 muestras en total), lo que con alta probabilidad ha contribuido a un mal desempeño del test y a una mala generalización del modelo. Particularmente, el test de McNemar necesita para un desempeño óptimo un conjunto mucho mayor de datos, lo que con total seguridad ha influido en los resultados obtenidos. Por otro lado, el test *5x2 cross-validation t-test* no presenta de forma tan acusada este problema, pero aún así, al fragmentar los datos, cada instancia de modelo se ha entrenado sólo con 50 muestras (que además el test asume como independientes de los datos de testeo), lo que seguramente ha llevado a resultados poco confiables.

Tengamos también en cuenta que la selección de las dos características a clasificar presentaban cierto solapamiento en su distribución, lo cual es muy difícil para un modelo realizar distinciones con tan pocos datos, donde seguramente se hayan producido sesgos en las particiones. A pesar de ello, y dadas las condiciones de entorno presentadas en este problema, ninguno de los dos test ha podido dilucidar una diferencia de rendimiento significativa entre los modelos. Sin embargo, no se concluye por ello que ambos modelos rindan de forma equivalente. Sería conveniente realizar estudios más profundos (con más datos u otras técnicas de selección) para poder tomar un veredicto acerca del rendimiento de ambos modelos.

Aún así, han resultado dos técnicas para afrontar el problema de selección de modelos muy interesantes. Hemos podido observar cómo, con técnicas estadísticas, hemos sido capaces de estudiar la diferencia de rendimiento de dos algoritmos para una medida de rendimiento dada y un nivel de significancia prefijado. Sin embargo, la selección de modelos es un problema altamente complejo, y hemos visto cómo la cantidad de datos disponibles o la aleatoriedad en la partición de los datos pueden repercutir de forma significativa en las conclusiones del estudio. Por ello, se ha visto la importancia del uso de distintas técnicas en paralelo para la evaluación de rendimiento y su posterior selección en un mismo problema, no confiando únicamente en una técnica o método.

Referencias

- [1] Remco R Bouckaert. Estimating replicability of classifier learning experiments. In *Proceedings of the twenty-first international conference on Machine learning*, page 15, 2004.
- [2] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *The Journal of Machine learning research*, 7:1–30, 2006.
- [3] Thomas G Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural computation*, 10(7):1895–1923, 1998.
- [4] Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.
- [5] George W. Snedecor and William G. Cochran. *Statistical Methods*. Iowa State University Press, Ames, 8 edition, 1989.