

# Práctica 1

David García Curbelo

—

Minería de Datos

Universidad Nacional de Educación a Distancia

Curso 2024-2025

# Índice

|                                   |          |
|-----------------------------------|----------|
| <b>1. Introducción</b>            | <b>2</b> |
| <b>2. Técnicas</b>                | <b>5</b> |
| 2.1. Test de McNemar . . . . .    | 5        |
| 2.2. 5x2-fold CV t-test . . . . . | 6        |
| <b>3. Resultados</b>              | <b>7</b> |
| <b>4. Conclusiones</b>            | <b>9</b> |

# 1. Introducción

La creciente disponibilidad de datos y el avance de las técnicas computacionales han permitido el desarrollo de una amplia variedad de algoritmos de aprendizaje supervisado: desde algoritmos clásicos hasta estructuras mucho más complejas como las redes neuronales. Cada uno de ellos presenta sus ventajas y desventajas, variando incluso su efectividad en función del contexto en el que se aplique. Ante este paradigma, nos encontramos con la necesidad de evaluar la capacidad predictiva de estos modelos en condiciones realistas, y por ende la necesidad de encontrar un método de evaluación eficiente y robusto.

Desde un principio se reconoció que los modelos entrenados en datos específicos tienden a ajustarse a las particularidades de esos datos, lo que genera preocupaciones sobre su capacidad para generalizar. Esto llevó al desarrollo de distintas metodologías no sólo para elegir métricas de evaluación, sino también para diseñar procedimientos robustos que permitan segmentar los datos y validar los resultados obtenidos. Sin embargo, este proceso de encontrar una métrica de evaluación que proporcione una visión real del rendimiento del modelo no es una tarea trivial; involucra el estudio estadístico de sus características, así como una comprensión profunda de los datos que los conciernen y del comportamiento de los modelos en diversos escenarios. Como podemos observar, este problema surge de una intersección de consideraciones estadísticas, computacionales y prácticas, siendo esencial en la investigación y desarrollo de sistemas de aprendizaje robustos.

Como podemos ver, la selección de modelos no sólo es una tarea técnica, sino que también está profundamente arraigada en principios estadísticos que buscan garantizar que las decisiones tomadas sobre el mejor modelo sean justificables y reproducibles. En este sentido, uno de los mayores retos lo encontramos en el problema de diferenciar entre las variaciones reales en el rendimiento de los modelos y aquellas que podrían atribuirse al azar inherente de los datos o a sesgos introducidos por los métodos de evaluación. Aquí, los conceptos de error Tipo I y Tipo II<sup>1</sup>, discutidos en detalle por Bouckaert y Dietterich, juegan un papel crucial [3], los cuales son indicadores esenciales para comprender la fiabilidad de nuestras comparaciones.

Por tanto, un enfoque riguroso para abordar esta incertidumbre es el diseño de experimentos que no solo evalúen la capacidad predictiva de un modelo, sino que también consideren la replicabilidad de los resultados obtenidos. Bouckaert introduce el concepto de replicabilidad como la probabi-

---

<sup>1</sup>Mientras que el error Tipo I representa la probabilidad de identificar incorrectamente un modelo como superior cuando no lo es, el error Tipo II refleja la incapacidad de detectar una diferencia cuando realmente existe.

lidad de que un experimento repetido bajo las mismas condiciones produzca un resultado consistente [1]. Este concepto es particularmente relevante en el aprendizaje automático, donde las decisiones tomadas a partir de conjuntos de datos limitados o ruidosos pueden llevar a conclusiones erróneas. La replicabilidad actúa como una métrica adicional para evaluar la robustez de los diseños experimentales, ayudando a evitar conclusiones prematuras y asegurando que las decisiones sean generalizables a nuevos datos.

Además de la replicabilidad, otro aspecto fundamental en la selección de modelos es la metodología empleada para dividir los datos en subconjuntos de entrenamiento y prueba. Métodos clásicos como la validación cruzada y el re-muestreo se han convertido en estándares debido a su capacidad para proporcionar estimaciones robustas del rendimiento promedio de los modelos. Sin embargo, estos métodos también presentan desafíos inherentes. Por ejemplo, la validación cruzada con divisiones aleatorias puede llevar a un aumento en el error Tipo I si se combina con pruebas  $t$  convencionales, una observación destacada por Dietterich y corregida mediante ajustes en las varianzas estimadas, como lo demostraron posteriormente Nadeau y Bengio [5].

En este contexto, las pruebas estadísticas desempeñan un papel esencial en la comparación de modelos, ya que permiten formalizar las evaluaciones del rendimiento y tomar decisiones fundamentadas sobre las diferencias observadas y su significancia estadística. Sin embargo, estas pruebas están sujetas a diversas suposiciones que deben ser cuidadosamente consideradas para garantizar la validez de los resultados. Entre estas suposiciones se encuentran la normalidad de las diferencias entre las métricas de rendimiento de los modelos y la independencia de las observaciones, elementos centrales en métodos como la prueba  $t$  emparejada. Considerar estas suposiciones y las posibles violaciones es fundamental para interpretar correctamente los resultados y seleccionar el método más adecuado para cada escenario.

En entornos donde los datos no cumplen estas suposiciones de normalidad, otra línea de abordaje incluye el uso de pruebas no paramétricas, como el test de Friedman y el test de Wilcoxon [2], que no asumen normalidad en la distribución de los errores de los clasificadores. Estas pruebas ofrecen una robustez mayor frente a distribuciones complejas y datos dependientes, siendo útiles cuando se necesita comparar múltiples modelos de forma simultánea o cuando los datos presentan sesgos estructurales. Pero, a pesar de su robustez, es necesario aplicar técnicas de corrección de significancia, tales como Bonferroni y Holm. Estas correcciones son realizadas para evitar el riesgo de errores Tipo I, especialmente en comparaciones múltiples, que pueden llevar a la selección de un modelo aparentemente superior pero en realidad insustancial. El problema que presentan estas correcciones es que puede reducir la sensibilidad de las pruebas, dificultando la detección de diferencias reales

entre modelos.

Otra dimensión importante en la selección de modelos es la influencia del tamaño de la muestra y la complejidad del modelo. A medida que aumentan las dimensiones de los datos y la complejidad de los modelos, también lo hacen los riesgos de sobreajuste y la variabilidad en las estimaciones de rendimiento. Este problema se puede observar en contextos donde los datos son escasos o están altamente desbalanceados, lo que subraya la importancia de diseñar experimentos que aprovechen al máximo la información disponible sin comprometer la validez estadística. En particular, el uso de métodos como la repetición de validación cruzada con múltiples particiones independientes ha mostrado ser efectivo para mitigar estos riesgos, aunque a un costo computacional mayor.

Finalmente, cabe destacar que el problema de selección de modelos no debería terminar con la identificación de un modelo “mejor”. La interpretación y comunicación de los resultados obtenidos, junto con una evaluación crítica de los supuestos y limitaciones de los métodos empleados, son igualmente esenciales. En aplicaciones prácticas, las decisiones tomadas sobre qué modelo utilizar pueden tener implicaciones significativas, lo que refuerza la necesidad de enfoques sistemáticos y transparentes capaces de proporcionar una comprensión clara y significativa de los resultados obtenidos.

## 2. Técnicas

Dentro del paradigma anterior, encontramos gran variedad de pruebas, entre las que se encuentran el test de McNemar y el test de Student pareado aplicado al esquema 5x2-fold CV. Ambos enfoques, aunque diferentes en su diseño y aplicación, representan soluciones clave para analizar la significancia estadística en la comparación de modelos.

### 2.1. Test de McNemar

El test de McNemar, introducido en 1947, es una prueba basada en la distribución binomial y se formula como una prueba de hipótesis, donde la hipótesis nula  $H_0$  postula que no hay diferencia en las proporciones de errores cometidos por los dos modelos en las mismas instancias [4]. Su realización se basa en la construcción de una matriz de contingencia basada en las predicciones de los dos modelos. De las cuatro categorías posibles (TP, FP, FN, TN), el test de McNemar se centra únicamente en las discordancias, es decir, en las celdas correspondientes a los escenarios donde los modelos no coinciden. El estadístico del test es el siguiente:

$$\chi^2 = \frac{(b - c)^2}{b + c}$$

donde  $b$  y  $c$  son las frecuencias de las discordancias de cada modelo. El principal atractivo del test de McNemar radica en su simplicidad y en su independencia de la distribución subyacente de los datos. A diferencia de otros métodos, como el  $t$ -test emparejado, el test de McNemar no asume normalidad en las diferencias entre los modelos, lo que lo hace mucho más versátil. Sin embargo, este test asume independencia entre observaciones, una condición que no siempre se cumple en la realidad. Además, no captura diferencias en el rendimiento general de los modelos más allá de las discordancias, lo que limita su aplicabilidad en contextos donde las métricas continuas podrían ser más relevantes.

Un punto fuerte que tiene es que, al centrarse en las discordancias, el test de McNemar minimiza el riesgo de errores Tipo I al evitar conclusiones precipitadas basadas en diferencias triviales en las métricas de rendimiento. Sin embargo, su sensibilidad limitada a otros aspectos del rendimiento del modelo, como la consistencia en las predicciones correctas, subraya la importancia de complementarlo con otras técnicas de evaluación.

En resumen, el test de McNemar es un test simple pero robusto. Mientras que los métodos basados en validación cruzada ofrecen una estimación más detallada del rendimiento promedio de un modelo, el test de McNemar

proporciona una evaluación específica y directa de la diferencia en las tasas de error, haciéndolo ideal para comparaciones rápidas en escenarios bien definidos.

## 2.2. 5x2-fold CV t-test

El test de Student pareado aplicado sobre los resultados de un esquema de validación 5x2-fold Cross Validation constituye una metodología robusta para la comparación estadística del rendimiento de dos modelos de aprendizaje supervisado, uniendo la flexibilidad de la validación cruzada con la eficiencia del test  $t$ . Introducido y explorado en profundidad por Dietterich, este método aborda varias limitaciones de otros enfoques estadísticos para la comparación de modelos.

Este test pareado evalúa las diferencias de rendimiento para cada una de las particiones de los datos. A partir de estas diferencias  $p_i^{(1)}$  y  $p_i^{(2)}$ <sup>2</sup> podemos calcular las varianzas  $s_i^2$ , construyendo así el estadístico  $\hat{t}$ :

$$\hat{t} = \frac{p_1^{(1)}}{\sqrt{\frac{1}{5} \sum_{i=1}^5 s_i^2}}$$

La ventaja fundamental de combinar ambos paradigmas radica en su capacidad para abordar dos desafíos comunes en la evaluación de modelos: la dependencia de los datos y la alta varianza de las particiones. A diferencia de otros enfoques más simples, el esquema 5x2-fold CV genera estimaciones de rendimiento en múltiples configuraciones, proporcionando una medida más confiable. Sin embargo, este método asume independencia entre las diferencias  $p_i$ , lo cual no siempre se cumple, sin olvidar también la suposición de normalidad en la aplicación del test  $t$ .

En resumen, el test de Student pareado sobre los resultados de 5x2-fold CV representa una herramienta poderosa y equilibrada para la comparación estadística de modelos en aprendizaje supervisado. Mientras que el test de McNemar se centra exclusivamente en discordancias en clasificaciones, este test considera la magnitud de las diferencias de rendimiento promedio, ofreciendo una visión más rica del desempeño relativo de los modelos.

---

<sup>2</sup>Los superíndices 1 y 2 indican las dos permutaciones asociadas a la partición  $i$ -ésima.

### 3. Resultados

Se propone la aplicación de las dos técnicas de selección de algoritmos anteriores al conjunto de datos *Iris* para la evaluación de dos modelos de clasificación: *Näive Bayes* y *K Nearest Neighbors* para  $k = 3$ . Se aplicarán los test de McNemar y el  $5x2$  *CV t-test* para comparar ambos modelos. Debido a que los datos etiquetados sobre la clase *Setosa* son claramente separables, realizaremos el estudio sobre las dos etiquetas restantes, que sí presentan solapamiento de distribuciones y resultará más interesante para este estudio.

Para la comparación de los modelos entrenados se ha seleccionado como medida de rendimiento la precisión (accuracy). Esta medida es adecuada para este conjunto de datos, dado que las clases están equilibradas, permitiendo una interpretación directa de la capacidad de cada modelo para clasificar correctamente las especies de *Iris*. Además, para ambos test vamos a establecer un nivel de significancia  $\alpha = 0,05$  para estudiar la aceptación o rechazo de la hipótesis nula  $H_0$  de igualdad de rendimiento entre ambos modelos.

Para la aplicación del test de McNemar se ha construido una matriz de confusión para los resultados de predicción de ambos modelos, donde se identifican los casos de falsos positivos y falsos negativos para un conjunto de test del 30% con división estratificada. Con ello, calculamos el estadístico de McNemar  $\chi^2$  para su tabla de contingencia:

|             | $Acierto_1$ | $Error_1$ |
|-------------|-------------|-----------|
| $Acierto_2$ | 25          | 2         |
| $Error_2$   | 1           | 2         |

$$\chi^2 = \frac{(b - c)^2}{b + c} = \frac{1}{3} \quad (1)$$

donde  $b$  son los errores de KNN que Naive Bayes clasificó correctamente, y  $c$  son los errores de Näive Bayes que KNN clasificó correctamente<sup>3</sup>. Tomando

<sup>3</sup>Los subíndices 1 y 2 en la tabla de contingencia son los asociados a los modelos Näive




Figura 1: Distribuciones de los datos seleccionados. En naranja Versicolor y en verde Virginica para las cuatro características.



este valor del estadístico para un grado de libertad, obtenemos un valor de  $p \simeq 0,56 > \alpha$ , por lo que no podemos rechazar la hipótesis nula de que las tasas de error de ambos modelos son estadísticamente iguales mediante el uso de este test.

En la aplicación del *5x2 CV t-test*, hemos realizado 5 fragmentaciones aleatorias de 50/50 en los datos (también de forma estratificada), entrenado las instancias de modelos y calculado el estadístico  $\hat{t}$  con los resultados obtenidos en cada una de las particiones. Obtenemos lo siguiente:

$$\hat{t} = \frac{p_1^{(1)}}{\sqrt{\frac{1}{5} \sum_{i=1}^5 s_i^2}} = -0,4082 \quad (2)$$

Por tanto, al calcular el valor de  $p$  para 5 grados de libertad, el estadístico  $\hat{t}$  nos proporciona un valor de  $p \simeq 0,70 > \alpha$ , lo que nos indica que tampoco en este caso podemos rechazar la hipótesis nula de igualdad de rendimiento de ambos modelos mediante el uso de este test.

---

Bayes y KNN, respectivamente.

## 4. Conclusiones

Ambos modelos han rechazado la hipótesis nula, aportando valores de estadístico (tanto para  $\hat{t}$  como para  $\chi^2$ ) de magnitudes bastante bajas (ambas muy cercanas a cero). Esto nos indica que las diferencias de rendimiento entre los modelos en las particiones evaluadas no son significativas, lo que concuerda con los valores altos obtenidos en el cálculo del valor de  $p$ . Esto sugiere que probablemente las diferencias observadas han sido azarosas y no fruto de diferencias de rendimiento significativas en ambos modelos.

Además, nos hemos enfrentado a un problema en el que, tanto el conjunto de datos de entrenamiento como de testeo, presentan un tamaño demasiado pequeño (100 muestras en total), lo que con alta probabilidad ha contribuido a un mal desempeño del test y a una mala generalización del modelo. Particularmente, el test de McNemar necesita para un desempeño óptimo un conjunto mucho mayor de datos, lo que con total seguridad ha influido en los resultados obtenidos. Por otro lado, el *5x2 CV t-test* no presenta de forma tan acusada este problema, pero aún así, al fragmentar los datos cada instancia de modelo se ha entrenado sólo con 50 muestras (que además el test asume como independientes de los datos de testeo), lo que seguramente ha llevado a resultados poco confiables.

Tengamos también en cuenta que la selección de las dos características a clasificar presentaban cierto solapamiento en su distribución, lo cual es muy difícil para un modelo realizar distinciones con tan pocos datos, donde seguramente se hayan producido sesgos en las particiones. A pesar de ello, y dadas las condiciones de entorno presentadas en este problema, ninguno de los dos test ha podido dilucidar una diferencia de rendimiento significativa entre los modelos. Sin embargo, no se concluye por ello que ambos modelos rindan de forma equivalente. Sería conveniente realizar estudios más profundos (con más datos u otras técnicas de selección) para poder tomar un veredicto acerca del rendimiento de ambos modelos.

Aún así, han resultado dos técnicas para afrontar el problema de selección de modelos muy interesantes. Hemos podido observar cómo, con técnicas estadísticas, hemos sido capaces de estudiar la diferencia de rendimiento de dos algoritmos para una medida de rendimiento dada y un nivel de significancia prefijado. Sin embargo, la selección de modelos es un problema altamente complejo, y se ha podido ver cómo la cantidad de datos disponibles o la aleatoriedad en la partición de los datos pueden repercutir de forma significativa en las conclusiones del estudio. La importancia del uso de distintas técnicas en paralelo para la evaluación de rendimiento y su posterior selección en un mismo problema se hace evidente, no confiando únicamente en una técnica o método.

## Referencias

- [1] Remco R Bouckaert. Estimating replicability of classifier learning experiments. In *Proceedings of the twenty-first international conference on Machine learning*, page 15, 2004.
- [2] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *The Journal of Machine learning research*, 7:1–30, 2006.
- [3] Thomas G Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural computation*, 10(7):1895–1923, 1998.
- [4] Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.
- [5] Claude Nadeau and Yoshua Bengio. Inference for the generalization error. *Advances in neural information processing systems*, 12, 1999.