

Práctica 1: Selección de modelos

11 de octubre de 2019

Resumen

La selección de un modelo de clasificación o regresión es en sí mismo un problema estadístico. En esta práctica vamos a ilustrar con métodos relativamente sencillos cuáles son pasos que debemos realizar.

1. Introducción

Dada una tarea de clasificación o regresión, el profesional del área de la Minería de Datos se encuentra a menudo con una variedad de modelos entre los que debe elegir. El primer paso en este camino es decidir cuáles van a ser los criterios que vamos a emplear para seleccionar y cómo vamos a medirlos. Por fijar ideas, y sin que esto prejuzgue qué medidas son mejores que otras, vamos a pensar que estamos comparando modelos de regresión en base al error cuadrático medio (MSE en sus siglas en inglés) en la predicción. En segundo lugar, debemos ser conscientes de que las métricas de evaluación con las que vamos a medir la calidad de los modelos son en sí mismas variables aleatorias y que un valor concreto habrá sido obtenido para un conjunto de datos dado y posiblemente, para una inicialización particular de los parámetros del modelo. Otro conjunto de datos u otra inicialización darán, en general, valores distintos de la medida. Por lo tanto, seleccionar entre dos modelos distintos (por ejemplo, un clasificador neuronal y otro basado en árboles de decisión) representa un problema estadístico en el que las distribuciones de las medidas de calidad deben ser tenidas en cuenta.

El ideal sería tener acceso a un conjunto infinito de datos de manera que nuestra estimación de la medida de calidad de un modelo fuese perfecta. En ese caso, seleccionaríamos el modelo con mejor medida de calidad. Sin embargo, esto no es posible en general y debemos conformarnos con estimaciones obtenidas a partir de conjuntos de datos finitos y frecuentemente sesgados. En esta práctica vamos a realizar una selección de modelos de clasificación obtenidos para un conjunto de datos pequeño y muy popular (el conjunto iris).

Existen en la bibliografía numerosos trabajos que estudian cuál es la mejor metodología para realizar comparaciones de modelos. Podemos dividir el problema en dos partes: una, cómo estimar la distribución de la medida de calidad para diferentes conjuntos de datos; otra, cuál es el test estadístico apropiado dada la técnica de estimación seleccionada.

Una técnica muy habitual en la bibliografía es la estimación de la distribución de la medida de calidad mediante la validación cruzada y la comparación de las distribuciones mediante el test t de Student. Es, por ejemplo, la base

de la recomendación de [1] (aunque con variaciones sustantivas que aumentan la replicabilidad de los experimentos). Es importante recalcar que una de las hipótesis que subyacen al test t de Student es la independencia de las muestras. Sin embargo, en la validación cruzada las muestras no son independientes por definición. Un trabajo pionero en este tipo de análisis y con vigencia en la actualidad es [2]. En él se recomienda la utilización del test de McNemar [3] o, en caso de que los tiempos de entrenamiento no sean un problema, el test pareado de Student sobre 5 ejecuciones de 2-fold cross validation. Los criterios para preferir unas técnicas u otras tienen en cuenta los errores de tipo I y II y las exigencias de las hipótesis de cada test sobre las distribuciones de los estadísticos. En [1] se incluye también el criterio de replicabilidad. Finalmente, es importante resaltar que estas citas bibliográficas se refieren a comparaciones entre dos clasificadores. Cuando en la selección de modelos entran más de dos algoritmos las técnicas recomendadas suelen ser no paramétricas (visítad <https://sci2s.ugr.es/sicidm> para encontrar un resumen relativamente exhaustivo).

En esta práctica sugerimos realizar una comparación de dos modelos siguiendo algunas de las técnicas propuestas sin por ello dar la impresión de que el problema estadístico está resuelto y que existe una técnica de facto aceptada por toda la comunidad y de validez universal. Hacia el final de este enunciado el estudiante encontrará varias referencias a trabajos en los que se discuten las ventajas e inconvenientes de cada técnica.

2. Descripción

En esta práctica vamos a intentar dilucidar si existen diferencias significativas en el rendimiento de dos clasificadores entrenados y evaluados sobre el mismo conjunto de datos. Esta situación (pocos datos que tienen que ser reutilizados varias veces) está lejos de lo que un científico de datos considera ideal, pero muy común en la práctica.

El estudiante debe comenzar por definir cómo va a medir el rendimiento o la calidad de dos clasificadores de su elección (por ejemplo, de entre los disponibles en el paquete *caret* de R). En este punto recomendamos seleccionar dos algoritmos de los estudiados en el tema 2 (un clasificador lineal y uno basado en los vecinos más cercanos) pero dejamos libertad al estudiante para elegir otros que no sean parte del temario de la asignatura (por ejemplo, un clasificador naive Bayes, que no necesita la especificación de parámetros). El estudiante puede elegir un conjunto de datos que sea de su interés o que tenga a su disposición. Alternativamente, puede utilizar el conjunto de datos clásico *iris* disponible por defecto en R.

Dados los dos clasificadores, el estudiante debe aplicar el test de McNemar y el test de Student pareado sobre los resultados de aplicar 5x2-fold cross validation (es decir, validación cruzada con 2 bloques repitiendo la selección aleatoria pero estratificada de los dos bloques 5 veces). Existen múltiples descripciones de los métodos sugeridos en la red/bibliografía. Por citar una revisión relativamente completa, podéis consultar el siguiente trabajo no publicado de S. Raschka <https://sebastianraschka.com/pdf/manuscripts/model-eval.pdf>.

3. Epígrafes de la memoria entregable y rúbrica

La memoria deberá incluir las siguientes secciones:

1. Breve resumen teórico del problema de la selección de modelos: qué técnicas se han propuesto en la bibliografía y cuáles son sus limitaciones. Para ello el estudiante deberá realizar una búsqueda bibliográfica. Máximo: tres DIN A4 por una cara (fuente de 12 puntos). Puntuación máxima: 5 puntos
2. Resumen de las técnicas pedidas en este enunciado, de sus puntos fuertes y débiles en comparación con otras alternativas de las expuestas en el punto anterior. Máximo: 1 DIN A4 por una cara (fuente de 12 puntos). Puntuación máxima: 1.5 puntos
3. Descripción de los resultados obtenidos con especificación de la medida del rendimiento elegida, cálculo del valor del estadístico y de los umbrales seleccionados a priori como límites de significatividad. Máximo 1 DIN A4 (fuente de 12 puntos). Puntuación máxima: 2 puntos
4. Conclusiones. Máximo 1 DIN A4. Puntuación máxima: 1.5 punto.

La corrección de la memoria tendrá muy en cuenta la claridad y la rigurosidad en la exposición de conceptos y en el análisis de los resultados. Por otra parte, también se valorará el estilo y la corrección orto-tipográfica del texto.

Referencias

- [1] R. R. Bouckaert, “Estimating replicability of classifier learning experiments,” in *Proceedings of the Twenty-first International Conference on Machine Learning*, ICML '04, (New York, NY, USA), pp. 15–, ACM, 2004.
- [2] T. G. Dietterich, “Approximate statistical tests for comparing supervised classification learning algorithms,” *Neural Computation*, vol. 10, no. 7, pp. 1895–1923, 1998.
- [3] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” *Psychometrika*, vol. 12, pp. 153–157, Jun 1947.