

Práctica 2

David García Curbelo

—

Minería de Datos

Universidad Nacional de Educación a Distancia

Curso 2024-2025

Índice

1. Generación de datos	2
2. Técnicas de selección de características	3
2.1. Métodos de filtrado	3
2.1.1. Información mutua	3
2.1.2. Test de independencia χ^2	4
2.1.3. ReliefF	4
2.2. PCA	4
2.3. Método de envoltura	5
3. Justificación de técnicas seleccionadas	6
4. Resultados	7
4.1. Métodos univariados	7
4.2. Métodos multivariados	7
5. Conclusiones	10
Referencias	12

1. Generación de datos

El conjunto de datos sintético generado para esta práctica está compuesto por cinco variables predictoras y una variable objetivo (clase), con un total de 100 instancias. De las 5 variables predictoras, las variables X_1, X_2, X_3 y X_5 se definen como variables booleanas generadas aleatoriamente con una distribución uniforme. La variable X_4 se define como la operación XOR bit a bit entre las variables X_2 y X_3 :

$$X_4 = X_2 \oplus X_3$$

donde $\oplus$ representa la operación XOR (OR exclusivo). Esta función devuelve un valor de 1 si el número de variables entre X_2 y X_3 con valor 1 es impar, y 0 si es par.

La variable objetivo, denotada como Y , se define como una función XOR extendida a tres dimensiones:

$$Y = X_1 \oplus X_2 \oplus X_3,$$

Esta definición garantiza que la relación entre las variables predictoras y la clase sea no lineal y conjunta, de modo que ninguna variable individual sea suficiente para predecir Y de manera aislada.

Desde el punto de vista de la relevancia de las variables, X_1 se considera relevante en sentido fuerte, ya que su exclusión modificaría la probabilidad de predecir correctamente la variable objetivo. Las variables X_2 y X_3 son relevantes en sentido débil, pues aunque su contribución a la predicción de Y es importante, su información puede ser parcialmente recuperada a través de X_4 , que depende exclusivamente de ellas. La variable X_4 , a pesar de derivarse de X_2 y X_3 , sigue siendo relevante en sentido débil dado que introduce redundancia estructurada en el conjunto de datos y puede influir en los métodos de selección de características. Finalmente, X_5 es una variable completamente irrelevante, ya que su valor es generado de manera completamente aleatoria e independiente del resto de las variables.

El diseño de este conjunto de datos permite evaluar con precisión las técnicas de selección de características, al contar con una relevancia conocida de antemano para cada variable. Además, la inclusión de una variable irrelevante y otra redundante permite analizar la robustez de los algoritmos ante el ruido y situaciones de selección de características complejas. Este marco sintético proporcionado en [6] nos genera un entorno controlado para comparar distintas estrategias de selección de características en algoritmos de aprendizaje supervisado, garantizando una evaluación rigurosa de su desempeño y de sus posibles limitaciones.

2. Técnicas de selección de características

Las técnicas de selección de características permiten identificar un subconjunto óptimo de variables que contribuyan de manera significativa a la predicción de la variable objetivo, eliminando aquellas redundantes o irrelevantes. Para el conjunto de datos sintetizado, se aplicarán cinco técnicas de selección de características, incluyendo tres métodos de filtrado, el análisis de componentes principales (PCA) y un método de envoltura basado en un clasificador supervisado.

2.1. Métodos de filtrado

Los métodos de filtrado evalúan la relevancia de las características de manera independiente del modelo de clasificación, aplicando criterios estadísticos o teóricos para determinar su importancia. Su principal ventaja radica en su eficiencia computacional, ya que no requieren entrenar un modelo de aprendizaje supervisado, sino que utilizan métricas predefinidas para estimar la relación entre cada variable predictora y la variable objetivo.

2.1.1. Información mutua

Uno de los enfoques más comunes dentro de este grupo es la selección basada en la información mutua (MI por sus siglas en inglés), donde se mide la dependencia estadística entre cada variable predictora y la variable objetivo. Este método, basado en la teoría de la información de Shannon [11]¹, cuantifica cuánta información sobre Y se obtiene al observar X_i . Formalmente, la información mutua entre dos variables aleatorias X_i e Y se define como:

$$I(X_i, Y) = \sum_{x \in X_i} \sum_{y \in Y} p(x, y) \log \left(\frac{p(x, y)}{p(x)p(y)} \right)$$

donde $p(x, y)$ representa la distribución conjunta de X_i e Y , y donde $p(x)$ y $p(y)$ son las distribuciones marginales. Un valor alto de información mutua indica que el conocimiento de X_i reduce significativamente la incertidumbre sobre Y , sugiriendo su utilidad en la clasificación.

¹A pesar de ser propuesto por Shannon en su artículo de 1948, no se popularizó para el problema de selección de características hasta muchos años después, con el artículo de R.Battiti [1].

2.1.2. Test de independencia χ^2

Otro método dentro de los filtros es el test de independencia de χ^2 , empleado para evaluar si una variable predictora y la variable objetivo son independientes [9]. Se basa en la comparación entre las frecuencias observadas y las frecuencias esperadas bajo la hipótesis de independencia, calculando el estadístico:

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde O_{ij} y E_{ij} representan, respectivamente, la frecuencia observada y la esperada para la combinación de valores i, j . Un valor alto de este estadístico sugiere que la variable en cuestión está fuertemente asociada con la clase.

2.1.3. ReliefF

El tercer método de filtrado a emplear es ReliefF, una variante del algoritmo Relief que mejora la robustez ante el ruido. Desarrollado por [7] como extensión del algoritmo original presentado en [5], ReliefF asigna un peso a cada variable en función de su capacidad para diferenciar correctamente ejemplos de ambas clases, ajustándolo iterativamente mediante la comparación de la instancia actual con múltiples vecinos: aquellos pertenecientes a la misma clase (“near-hit”) y aquellos de la clase opuesta (“near-miss”).

Para cada instancia x_k en un conjunto de m instancias, considerando los n vecinos de dicha instancia, el peso de una variable X_i se actualiza en cada iteración con la siguiente fórmula:

$$W[i] = W[i] + \frac{1}{m \cdot k} \left(\sum_{j=1}^n \frac{|x_{k,i} - x_{j,i}^{(miss)}|}{\text{máx}(X_i) - \text{mín}(X_i)} - \sum_{j=1}^n \frac{|x_{k,i} - x_{j,i}^{(hit)}|}{\text{máx}(X_i) - \text{mín}(X_i)} \right)$$

donde $x_{j,i}^{(hit)}$ denota el j -ésimo vecino más cercano de la misma clase que x_k y $x_{j,i}^{(miss)}$ representa el j -ésimo vecino más cercano de la clase opuesta a x_k . Este método resulta especialmente útil en problemas donde las interacciones entre características y la presencia de ruido pueden afectar la capacidad discriminativa de las variables, ya que es capaz de capturar las posibles dependencias locales entre las mismas.

2.2. PCA

El análisis de componentes principales constituye una técnica ampliamente utilizada para la reducción de dimensionalidad y la selección de ca-

racterísticas, aunque no por ello óptima en la mayoría de situaciones. Su aplicación difiere de los métodos anteriores, ya que transforma las variables originales en nuevas combinaciones lineales denominadas componentes principales [4]. Estos componentes se obtienen mediante la descomposición en valores singulares de la matriz de covarianza de los datos, generando una base ortogonal donde las nuevas variables son ordenadas según la varianza explicada. Dado un conjunto de características X , se busca una transformación lineal W tal que:

$$Z = WX$$

donde las filas de W corresponden a los vectores propios de la matriz de covarianza de X , ordenados en función de sus valores propios. Seleccionando los primeros k componentes con mayor varianza, se obtiene una representación compacta de los datos que conserva la mayor cantidad de información posible.

2.3. Método de envoltura

Para la selección de características mediante envoltura se empleará el método de Eliminación Recursiva de Características con Máquinas de Vectores de Soporte (RFE-SVM), propuesto por Guyon y Elisseeff [2]. Este enfoque combina la capacidad de las SVM para construir hiperplanos de separación óptimos con un proceso iterativo de eliminación de variables basado en su relevancia.

El RFE-SVM se basa en la idea de que las variables más relevantes son aquellas que contribuyen significativamente a la construcción del hiperplano de separación en un SVM. Para un problema de clasificación binaria, el hiperplano se define como:

$$f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$$

donde $\mathbf{w}$ es el vector de pesos asociado a cada variable y b es el término de sesgo de la ecuación. La magnitud de cada peso $|w_i|$ indica la importancia de la variable X_i en la función de decisión.

3. Justificación de técnicas seleccionadas

La elección de las técnicas de selección de características aplicadas a nuestro caso de uso se fundamenta en las propiedades intrínsecas del conjunto de datos generado y en las definiciones teóricas de relevancia establecidas en [2, 6]. Dentro de las técnicas univariadas, la Información mutua ha sido elegida por su capacidad de capturar dependencias estadísticas no lineales entre cada variable predictora y la variable objetivo, permitiendo que identifique patrones en las distribución conjuntas. En particular, se espera que este método detecte la relevancia fuerte de X_1 , cuya exclusión alteraría la distribución de Y , así como la redundancia parcial de X_4 , derivada de su dependencia determinista de X_2 y X_3 .

Por su parte, el test χ^2 al ser también un método univariado, su capacidad para detectar variables relevantes en sentido débil en nuestro caso de uso es limitada, ya que su contribución a Y solo se manifiesta en combinación con otras variables. Este método servirá como contraste para evaluar cómo las técnicas univariadas infravaloran las variables que requieren interacciones para ser informativas, destacando la necesidad de enfoques multivariados.

Entrando en técnicas multivariadas, el algoritmo ReliefF se selecciona por su capacidad para evaluar la relevancia en función de su entorno en el espacio de características. En problemas como el que nos concierne, se espera que este algoritmo se comporte mejor que los métodos univariados, ya que pondera las características según su utilidad en contextos locales. En concreto, se espera que considere la redundancia entre X_2 , X_3 y X_4 , asignando pesos similares a estas variables y reflejando así su interdependencia.

El análisis de componentes principales se incluye como técnica de referencia para contrastar su desempeño en un problema donde la relevancia de las variables está ligada a interacciones no lineales. PCA, al ser un método no supervisado y lineal, prioriza la varianza explicada en los datos, lo que puede no correlacionarse con la relevancia para la clasificación. En este caso, se espera que PCA asigne importancia a X_4 , ya que su dependencia determinista de X_2 y X_3 introduce varianza estructurada. Sin embargo, no se espera lo mismo de X_1 , cuya varianza individual es idéntica a la de X_5 .

Por último, la eliminación recursiva de características acoplada a un algoritmo SVM proporciona una evaluación de la relevancia en función de la contribución de cada variable a un modelo predictivo. Al emplear RFE con SVM lineal (como se sugiere en [2]), se fuerza al modelo a operar en un espacio donde las variables deben ser relevantes de forma individual o lineal. Esto genera un escenario ideal para evaluar cómo los métodos de envoltura pueden fallar ante relaciones no lineales si el modelo base no está adaptado, contrastando con los resultados de técnicas como ReliefF.

4. Resultados

4.1. Métodos univariados

Para calcular la información mutua entre cada variable predictora y la variable objetivo Y , se ha utilizado la función `mutual_info_classif` de la librería `scikit-learn`, con el hiperparámetro `n_neighbors=3`². Éste ha sido dejado en su valor por defecto, ya que un uso bajo de vecinos para muestras de tamaño moderado se ha estudiado que consigue un buen equilibrio entre sesgo y varianza en la estimación, volviéndolo óptimo para nuestro caso [8].

Variable	X4	X2	X3	X1	X5
MI with Y	$6 \cdot 10^{-3}$	$7 \cdot 10^{-4}$	$1 \cdot 10^{-4}$	$7 \cdot 10^{-5}$	$4 \cdot 10^{-5}$

Podemos observar en la tabla anterior que los valores obtenidos por este algoritmo son muy bajos, lo que refleja la limitación de los métodos univariados para capturar relaciones no lineales. Además, junto con el hecho de que las diferencias entre variables no son significativas, vuelve difícil la decisión de un valor frontera para catalogar la relevancia de cada una de las variables.

Continuando con el test de χ^2 , se ha obtenido la función `chi2` de la librería `scikit-learn` para su cálculo. La siguiente tabla muestra las puntuaciones y sus respectivos p-valores obtenidos:

Variable	X4	X2	X3	X1	X5
χ^2 Score	0.62	0.08	0.012	0.006	0.003
p-Value	0.43	0.78	0.91	0.94	0.96

Vemos cómo todos los valores del estadístico son bastante bajos, lo que nos indica que ninguna variable presenta desviaciones significativas respecto a la hipótesis de independencia, lo cual se corrobora con los valores tan altos de p -valor.

4.2. Métodos multivariados

Para el caso de ReliefF, se ha utilizado la implementación `ReliefF` del paquete `skrebate`. Se ha tomado como número de vecinos $k = 10$, con la intención de evitar sesgos en la estimación de relevancia³.

Vemos como en este caso, donde los valores de este método oscilan entre -1 y 1 , hemos obtenido valores con un rango mejor ajustado y más significativo que en los dos casos anteriores. Obtenemos en este caso una variable

²Se trata de un estimador de la información mutua basado en el algoritmo k-NN.

³Siguiendo las recomendaciones citadas en [9, 12].

Variable	X1	X4	X3	X2	X5
ReliefF	0.688	0.306	0.123	0.085	-0.217

con un alto impacto en la determinación de la variable objetivo, dos con impacto leve, una irrelevante y otra que produce un impacto negativo en la categorización de la variable objetivo.

Continuando con PCA de la librería `scikit-learn`, se han considerado los siguientes parametros: `n_components=5` (para conservar las 5 variables y estudiar su varianza) y `svd_solver="full"` (para realizar la descomposición completa de la matriz de covarianza⁴).

Variable	X1	X2	X3	X4	X5
E. Variance	0.27	0.21	0.19	0.18	0.14

Se observa cómo la varianza explicada de la variable X1 es ligeramente superior al resto, al igual que se observa cómo la de X5 es ligeramente menor. Se puede ver de igual manera en la Figura 1 su relación con cada una de las componentes principales, donde se observa una mayor relevancia de las primeras variables. Sin embargo, al tratarse de un método no supervisado, esto no implica necesariamente una mayor relevancia con la variable objetivo y por tanto con su categorización.




Figura 1: Loadings de cada variable en cada componente principal.

Por último, para el método de RFE-SVM, se ha utilizado la implementación RFE de `scikit-learn` con un modelo base SVM de kernel lineal (`SVC(kernel='linear')`).

Los hiperparámetros seleccionados incluyen `n_features_to_select=1` (para obtener un ranking completo) y `step=1` (eliminar una variable por iteración), siguiendo las recomendaciones de [3] para garantizar un proceso conservador que minimice la pérdida prematura de variables relevantes.

Variable	X4	X1	X3	X2	X5
Ranking RFE-SVM	1	2	3	4	5

⁴Se utiliza una descomposición completa para no perder precisión en el cálculo, al ser un dataset de tamaño pequeño. Así se recomienda en la propia documentación de la librería [10].

Se puede observar cómo con este método, las variables que tienen información relevante o redundante son eliminadas las últimas, mientras que las que proporcionan ruido son eliminadas las primeras.

5. Conclusiones

Los resultados obtenidos en este estudio sintético revelan patrones fundamentales sobre el comportamiento de las técnicas de selección de características en contextos con dependencias no lineales y redundancia estructurada. Como adelantamos en la Sección 3, hemos podido observar en la sección de resultados una clara discrepancia de comportamiento entre los métodos univariados y multivariados, que a continuación discutiremos más en detalle.

Centrándonos primeramente en los métodos univariados, ambos han presentado resultados que los hacen poco válidos para la toma de decisiones en nuestro problema. Por un lado, el método de información mutua, debido a su falta de correlación directa entre las variables predictoras y la variable objetivo (debido a que estas relaciones son no lineales) ha hecho que la figura de mérito no se encuentre en rangos válidos para su correcta evaluación. Del mismo modo, el test χ^2 , siguiendo las suposiciones hechas en apartados anteriores, ha demostrado no ser capaz de romper con la hipótesis de independencia para ninguna de las variables, asumiendo incluso p-valores excesivamente altos para variables a priori correlacionadas con la variable objetivo.

Además, cabe mencionar que ambos métodos univariados se han visto altamente influidos por la aleatorización de los datos. Cambios en la semilla de creación de las variables predictoras ha producido no sólo variaciones en las medidas de mérito de las variables por parte de los métodos anteriores, sino que también ha producido variaciones significativas en los rankings aportados. Partiendo de que las variables predictoras se han generado de la misma forma y con la misma distribución de probabilidad, hace ver que los métodos univariados para pequeños conjuntos de muestras y con relaciones no lineales con la variable objetivo los vuelven poco estables para la toma de decisiones en el problema que nos concierne.

Los métodos multivariados, sin embargo, han ofrecido una mayor estabilidad en este punto. Todos ellos han mantenido el ranking de forma estable y con escasas variaciones en sus figuras de mérito, manteniendo invariante su evaluación a pesar de las modificaciones en la naturaleza del dataset.

El método ReliefF se ha mostrado como la única técnica de filtrado capaz de mostrar unas métricas evaluables para la toma de decisiones. Su propuesta de ranking coincide con la información teórica que contienen las variables de cara a la categorización de la variable objetivo, además de realizar una mejor separación de las que se podrían considerar como variables con relevancia fuerte, relevancia débil e irrelevancia. Esta capacidad de distinción se debe a su enfoque basado en vecinos locales, permitiendo identificar dependencias contextuales en el espacio de características.

El análisis de componentes principales, aunque útil para cuantificar la varianza explicada, confirmó su naturaleza agnóstica con la variable objetivo al tratarse de una técnica no supervisada. Las variaciones leves entre las varianzas explicadas por cada una de las variables predictoras refleja diferencias en la estructura de los datos, pero no informa acerca de su relevancia predictiva. Esta distinción entre varianza y utilidad clasificatoria subraya la necesidad de complementar técnicas no supervisadas como ésta con enfoques que aporten información sobre las clases en problemas de selección de características.

Finalmente, el método de eliminación recursiva de características con SVM ha demostrado un desempeño alineado con la estructura de relevancia del conjunto de datos. La eliminación progresiva de variables ha seguido un orden coherente, descartando primero aquellas irrelevantes y reteniendo hasta el final las que tienen una mayor contribución a la separación de clases. Este resultado pone en evidencia la ventaja de los métodos de envoltura cuando el modelo subyacente es capaz de capturar las relaciones presentes en los datos. No obstante, en escenarios donde las interacciones no son lineales, como el problema XOR considerado, el uso de un clasificador lineal puede suponer una limitación, ya que la selección de variables dependerá de la capacidad del modelo para representar adecuadamente la relación entre las características y la variable objetivo.

Los resultados obtenidos refuerzan la idea de que la selección de características debe ser abordada desde una perspectiva adaptada a la estructura del problema. Mientras que los métodos univariados pueden ser adecuados cuando las variables individuales presentan una fuerte correlación con la clase, en problemas donde la información relevante se distribuye de manera conjunta a través de múltiples variables, los métodos multivariados ofrecen una mejor aproximación. A su vez, se ha demostrado que los métodos no supervisados como PCA no son adecuados para este tipo de tareas, ya que no optimizan la selección en función de la capacidad predictiva. Los métodos de envoltura, aunque efectivos, dependen de la elección del modelo base, lo que puede introducir sesgos si la hipótesis del clasificador no está alineada con la complejidad del problema. En última instancia, la selección de características no es un problema trivial y requiere un análisis cuidadoso tanto de la naturaleza de los datos como de las herramientas utilizadas, asegurando que la técnica aplicada sea coherente con las dependencias estructurales presentes en la información disponible.

Referencias

- [1] Roberto Battiti. Using mutual information for selecting features in supervised neural net learning. *IEEE Transactions on neural networks*, 5(4):537–550, 1994.
- [2] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003.
- [3] Isabelle Guyon, Jason Weston, Stephen Barnhill, and Vladimir Vapnik. Gene selection for cancer classification using support vector machines. *Machine Learning*, 46(1-3):389–422, 2002.
- [4] Ian T Jolliffe. *Principal Component Analysis*. Springer, 2nd edition, 2002.
- [5] Kenji Kira and Larry A Rendell. A practical approach to feature selection. In *Machine learning proceedings 1992*, pages 249–256. Elsevier, 1992.
- [6] Ron Kohavi and George H John. Wrappers for feature subset selection. *Artificial intelligence*, 97(1-2):273–324, 1997.
- [7] Igor Kononenko, Marko Robnik-Sikonja, and Uros Pompe. *ReliefF for estimation and discretization of attributes in classification, regression, and ILP problems*, volume 35. Citeseer, 1996.
- [8] Alexander Kraskov, Harald Stögbauer, and Peter Grassberger. Estimating mutual information. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 69(6):066138, 2004.
- [9] Huan Liu and Hiroshi Motoda. *Feature selection for knowledge discovery and data mining*. Springer Science & Business Media, 2012.
- [10] Fabian Pedregosa, Gael Varoquaux, Alexandre Gramfort, and Vincent Michel. Documentation scikit-learn: machine learning in Python.
- [11] Claude E Shannon. A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423, 1948.
- [12] Ryan J Urbanowicz, Melissa Meeker, William La Cava, Randal S Olson, and Jason H Moore. Relief-based feature selection: Introduction and review. *Journal of biomedical informatics*, 85:189–203, 2018.