

Práctica 2: Evaluación de la relevancia de variables de entrada

Resumen

Uno de los elementos más importantes en el desarrollo de modelos de clasificación o regresión es la selección de variables que contengan la información (término utilizado aquí en un sentido amplio y no técnico) necesaria para alcanzar los objetivos propuestos. En esta práctica os proponemos un ejercicio para aclarar conceptos y poner en práctica diferentes técnicas disponibles en la bibliografía.

1. Objetivo

Uno de los elementos más importantes en el desarrollo de modelos de clasificación o regresión es la selección de variables que contengan la información (término utilizado aquí en un sentido amplio y no técnico) necesaria para alcanzar los objetivos propuestos. La inclusión de variables irrelevantes puede llevar en el mejor de los casos a un incremento significativo de la complejidad de los modelos, de los tiempos de entrenamiento y predicción y a una merma en la interpretabilidad de los modelos. En el peor de los casos, la presencia de variables irrelevantes pero cuyo muestreo en los conjuntos de entrenamiento o validación esté sesgada puede conducir a deterioros graves de las métricas de evaluación.

En líneas generales hay formas diversas de definir la relevancia de una variable y, en consecuencia, diferentes formas de medir ese concepto. Esta práctica se basa en dos trabajos clásicos que giran en torno a la definición de relevancia [1] y a las diferentes técnicas propuestas en la bibliografía para estimar la relevancia [2].

En este trabajo nos vamos a colocar en una posición inhabitual que no se produce en la práctica común de la Minería de Datos: vamos a trabajar con un conjunto de datos en el que la relevancia es conocida de antemano porque lo habremos generado nosotros. Al definir el problema (las variables predictoras y la variable objetivo) tenemos control sobre la relevancia (definida en un sentido particular) de cada variable de entrada. A partir de esa definición generaremos una muestra de datos sintéticos que utilizaremos como conjunto de evaluación para diferentes técnicas de selección de variables.

El elemento clave de esta práctica radica en la comprensión tanto de las definiciones de relevancia como de las técnicas de estimación **y en el análisis de la adecuación de unas y otras para un problema dado.**

2. Descripción

El estudiante generará un conjunto de datos artificial compuesto por 100 instancias caracterizadas cada una de ellas por cinco variables predictoras: una variable relevante en sentido fuerte, tres variables relevantes en sentido débil y una variable totalmente irrelevante. Aunque se pueden crear conjuntos como el descrito a partir de muchas definiciones de clase, sugerimos *i*) extender el ejemplo XOR de [1] a tres dimensiones (es decir, definir la variable clase como la función XOR de 3 variables), *ii*) definir la cuarta variable como una función de un subconjunto de las tres primeras (por ejemplo, $X_4 = X_2 \text{ XOR } X_3$) y *iii*) la quinta como una variable booleana aleatoria.

A continuación, aplicará 5 técnicas de las mencionadas en [2] al conjunto de datos así generado. Deberá seleccionar un mínimo de tres técnicas de filtrado, el análisis de componentes principales y la técnica de envoltura con un clasificador de los estudiados en el tema 2.

Como sugerencia (y sin que esto pretenda ser una lista exhaustiva ni actualizada) podemos mencionar los paquetes `caret` y `FSelector` de R. En python, tenéis algunas funciones implementadas en `sklearn.feature_selection`.

3. Epígrafes de la memoria entregable

La memoria debe incluir los siguientes puntos:

1. Una descripción de cómo se han definido las 6 variables del conjunto de datos sintético (5 predictoras más la variable clase). Máximo: 1 cara de página DIN A4.
2. Una descripción concisa pero con fórmulas cuando sea necesario de las 5 técnicas que serán utilizadas. Máximo: 3 caras de página DIN A4.
3. Una justificación de la técnicas de ranking+filtrado elegidas en términos de las propiedades del conjunto de datos generado. Máximo: 1 cara de página DIN A4.
4. Un resumen de los resultados obtenidos que incluya los valores de los parámetros configurables de cada técnica que hayan sido utilizados (si se han utilizado los valores por defecto, se ha de justificar por qué; si se han probado diferentes valores, se han de resumir los resultados). El resumen debe contener toda la información necesaria para el análisis de los resultados. Por ejemplo, los valores de las figuras de mérito utilizadas para ordenar las variables predictoras o los subconjuntos de éstas o los umbrales utilizados para realizar la selección. Máximo: 1.5 DIN A4.
5. Una sección que explique los resultados obtenidos. Ésta es la sección más importante de la memoria y no puede contener información redundante con el apartado anterior. Tampoco explicaciones basadas únicamente en la relevancia o irrelevancia conocida por el experimentador. Máximo: 2 DIN A4.

4. Rúbrica

Sección	Criterio	Máx.
2	La descripción de las técnicas es rigurosa y completa	2
3	Contiene reflexiones acertadas sobre la adecuación de las técnicas	2
4	Contiene toda la información necesaria para el análisis de resultados	1
5	Explica los resultados en función de los principios teóricos de las técnicas y de las definiciones de las variables.	3
5	Discute y explica los valores numéricos de las figuras de mérito	2

Tabla 1: Rúbrica de corrección de la práctica.

La corrección de la memoria tendrá muy en cuenta la claridad y la rigurosidad en la exposición de conceptos y en el análisis de los resultados. Por otra parte, también se valorará el estilo y la corrección orto-tipográfica del texto.

Referencias

- [1] R. Kohavi and G. H. John, “Wrappers for feature subset selection,” *Artificial Intelligence*, vol. 97, no. 1, pp. 273 – 324, 1997. Relevance.
- [2] I. Guyon and A. Elisseeff, “An introduction to variable and feature selection,” *J. Mach. Learn. Res.*, vol. 3, pp. 1157–1182, Mar. 2003.