

Práctica 3

David García Curbelo

—

Minería de Datos

Universidad Nacional de Educación a Distancia

Curso 2024-2025

Índice

1. Técnicas de <i>Data Augmentation</i>. Impacto en el modelado	2
2. Resultados	3
2.1. Redes densas estándar	3
2.1.1. Modelo 1: NET-1	3
2.1.2. Modelo 2: Red densa con capas ocultas	4
2.2. Modelo 3: CNN	4
2.3. Modificaciones de CNN	4
2.3.1. Modelo 4: adición de capas convolucionales	4
2.3.2. Modelo 5: regularización L2	5
3. Análisis de resultados	6
3.1. Comparativa general	6
3.2. Estudio detallado sobre CNN	7
3.3. Pesos	7
3.4. Mapas de características	7
3.5. Mapas de calor	9
4. Conclusiones	11

1. Técnicas de *Data Augmentation*. Impacto en el modelado

En el contexto de la clasificación de granos de polen, cuya variabilidad visual es mínima y las diferencias entre especies se concentran en detalles sutiles de forma y tamaño, se ha explorado en esta práctica la aplicación de técnicas de data augmentation para evaluar su impacto en la capacidad de generalización de los modelos. Dado el tamaño del conjunto de datos y la alta similitud entre clases, se ha realizado el estudio basado en transformaciones que replicaran posibles variaciones naturales en la captura de imágenes microscópicas, realizando una generación de 5 muestras mediante modificaciones aleatorias a partir de cada instancia en el conjunto de entrenamiento. Estas transformaciones se basaron en operaciones geométricas, como rotaciones de hasta 10 grados en ambas direcciones, zoom entre $\times 0,9$ y $\times 1,1$ y un desplazamiento en ambos ejes de hasta 5 píxeles.

Para evaluar la validez de esta técnica, se han realizado varios entrenamientos para cada una de las arquitecturas. Tras la aplicación de data augmentation al conjunto de entrenamiento, este se ha adherido al conjunto original para constituir así el nuevo conjunto de entrenamiento aumentado. Estos son los resultados tras la evaluación con el conjunto de testeo:

Arquitectura	Desplazamiento	Rotación	Zoom	Acierto (%)	Ratio de error
NET-1				84.2	67/33
NET-1	✓			79.2	85/15
NET-1	✓	✓		79.4	86/14
NET-1	✓	✓	✓	76.4	88/12
Red densa				90.8	27/73
Red densa	✓			93.1	36/64
Red densa	✓	✓		94.2	43/57
Red densa	✓	✓	✓	93.3	50/50
CNN				85.3	70/30
CNN	✓			88.6	73/27
CNN	✓	✓		89.2	74/26
CNN	✓	✓	✓	90.3	50/50

Observamos cómo, salvo para NET-1, la aplicación de data augmentation ha mejorado el rendimiento de los modelos. Y no sólo el rendimiento es importante en este caso, sino que también se ha visto influenciada la ponderación entre clases, aproximándonos gracias a estas técnicas a un ratio del error equitativo para ambas categorías. Es por ello que para el análisis de las arquitecturas presentes y las modificaciones faltantes, se ha decidido emplear la técnica de data augmentation en el entrenamiento de los modelos con todas las transformaciones anteriores, con la intención de maximizar la capacidad de generalización de los modelos y obtener resultados más robustos y fiables.

2. Resultados

Se presentan a continuación los resultados obtenidos para cada una de las arquitecturas. Cabe denotar que todas las redes que aquí se presentan se han entrenado y evaluado bajo el mismo pipeline, con la intención de que la comparación sea fiable y robusta. Se ha definido un valor máximo de etapas de entrenamiento a 100, incluyendo una parada temprana en función del decrecimiento de la función de pérdida para el conjunto de validación. El entrenamiento se ha realizado con un batch de tamaño 128 y una tasa de aprendizaje de 0.0001 para el optimizador Adam. Estos valores permanecerán inmutables a lo largo de este análisis.

2.1. Redes densas estándar

2.1.1. Modelo 1: NET-1

El modelo NET-1 consiste en un modelo sin capas ocultas, disponiendo únicamente de una capa de aplanamiento de la imagen y una neurona discriminativa con función sigmoide, haciendo que la red actúe como una regresión logística binomial.

Debido a la carencia de capas ocultas, este modelo ha demostrado un rendimiento bastante mejorable, obteniendo un acierto en el conjunto de testeo del 76.4 %. Este valor fue extraído del modelo en la etapa 7 de entrenamiento, donde se puede empezar a ver en la Figura 1 un mínimo de la función de pérdida. La matriz de confusión denota una marcada desponderación del error, predominando la clasificación de la clase Kunzea.




Figura 1: Matriz de confusión de NET-1 para el conjunto de testeo y la evolución de la función de pérdida en los conjuntos de entrenamiento y validación.

2.1.2. Modelo 2: Red densa con capas ocultas

Para este caso se han añadido dos capas ocultas a la arquitectura anterior, la primera con 128 neuronas y la segunda con 64, ambas con función de activación ReLu. El resto de la arquitectura de la red se mantiene invariante.

En este caso, la incorporación de capas ocultas ha producido un aumento de la comprensión de patrones que la red anterior no era capaz de capturar, aumentando el acierto a un 93.3 % en el conjunto de testeo. Además, en la Figura 2 se justifica la parada temprana en la etapa 15, consiguiendo mitigar por completo el problema de desponderación de errores.




Figura 2: Matriz de confusión de una red densa con capas ocultas para el conjunto de testeo y la evolución de la función de pérdida en los conjuntos de entrenamiento y validación.

2.2. Modelo 3: CNN

Comenzando con las redes convolucionales, se ha definido una red con dos capas convolucionales con kernel 3×3 seguidas de una capa de MaxPooling cada una con kernel 2×2 . Las capas convolucionales disponen de 32 y 64 filtros, respectivamente.

En la Figura 3 se puede observar cómo la red ha sido capaz de generalizar correctamente ambas clases, obteniendo un acierto del 90.3 % en el conjunto de testeo. La parada temprana se ha realizado en la etapa 81, donde se observa un decrecimiento en el acierto del conjunto de validación. Al igual que en la red anterior, se ha conseguido una ponderación equitativa de errores.

2.3. Modificaciones de CNN

2.3.1. Modelo 4: adición de capas convolucionales

Se ha tratado de mejorar la capacidad de generalización de la red añadiendo una tercera y cuarta capa convolucional con 128 y 256 filtros respectiva-




Figura 3: Matriz de confusión de una red con dos capas convolucionales para el conjunto de testeo y la evolución de la función de pérdida en los conjuntos de entrenamiento y validación.

mente, manteniendo el resto de la arquitectura invariante. Se ha mejorado ligeramente el acierto al 92.5 %, a expensas de una ligera sobreetiquetación en la clase Kunzea. La parada temprana se ha realizado en la etapa 28, donde se observa en la Figura 4 un mínimo local en la función de pérdida.




Figura 4: Matriz de confusión de la red 3 con dos capas convolucionales más para el conjunto de testeo y la evolución de la función de pérdida en los conjuntos de entrenamiento y validación.

2.3.2. Modelo 5: regularización L2

En este caso, se ha añadido regularización L2 a las dos capas convolucionales de la red original, con un factor de regularización de 0.001. Además de esta mejora, se han añadido después de la capa de aplanamiento, dos capas densas de 128 y 64 neuronas respectivamente, con la intención de que el modelo pueda obtener lo mejor de ambas arquitecturas. Se ha conseguido de esta manera un aumento al 94.2 %, además de mantener la ponderación de errores. Esto se puede observar en la Figura 5, donde la parada temprana se ha realizado en la etapa 21.




Figura 5: Matriz de confusión de la red 3 con regulación L2 y dos capas densas para el conjunto de testeo y la evolución de la función de pérdida en los conjuntos de entrenamiento y validación.

3. Análisis de resultados

Red	NET-1	Red densa	CNN	CNN 4 capas	CNN L2 + Densa
Acierto	76.4	93.3	90.3	92.5	94.2
Ratio de error	88/12	50/50	50/50	70/40	50/50

Cuadro 1: Resumen de resultados de evaluación sobre el conjunto de testeo.

3.1. Comparativa general

En la Figura 6 se pueden observar las distintas curvas fruto de la evaluación sobre el conjunto de validación. En general, se puede observar cómo la red convolucional con L2 y dos capas ocultas ha sido la que ha obtenido una mejor puntuación en este conjunto durante todo el entrenamiento. Sin embargo, Hay que tener cuidado con la interpretación de los resultados de esta gráfica, ya que las redes frente a datos no vistos en el entrenamiento se pueden comportar de manera muy distinta a la observada en el conjunto de validación.

Además, se observa para las redes convolucionales de cuatro capas y la red densa, ambas han presentado un entrenamiento muy similar, salvo por pequeños tramos donde ha dominado una frente a otra. Esto nos




Figura 6: Gráfica comparativa de los aciertos en el conjunto de validación para las diferentes arquitecturas durante el proceso de entrenamiento.

muestra que las redes convolucionales, aunque a priori deberían presentar un mejor comportamiento frente a las redes densas, ha terminado por ser tanto computacionalmente más costosa como menos eficiente. Sin embargo, se ha observado cómo, aunque en los conjuntos de validación se observan sustanciales por momentos, sobre el conjunto de testeo sólo ha repercutido en un punto porcentual, recalcando la importancia de la evaluación sobre conjuntos de testeo independientes.

3.2. Estudio detallado sobre CNN

3.3. Pesos




Figura 7: Conjunto de pesos tras el entrenamiento para la CNN de dos capas.

Haciendo un análisis detallado de las características de nuestra red convolucional base, se ha procedido a extraer los pesos de las capas convolucionales para visualizarlos. En la Figura 7 se pueden observar los pesos de las dos capas convolucionales, donde cada una ha aprendido a detectar, gracias al backpropagation, ciertas características de nuestros datos en el conjunto de entrenamiento. Veremos a continuación su efecto en los mapas de características generados para cada imagen.

3.4. Mapas de características

Para la visualización de los mapas de características, se ha procedido a seleccionar dos imágenes del conjunto de testeo para observar las repercusiones de los pesos aprendidos durante el entrenamiento a imágenes no vistas

no vistas en este proceso. Cabe destacar que la visualización de estos mapas se ha decidido realizar mediante el uso de una escala de colores distinta a la escala de grises, para una mejor visualización de los cambios de tonalidad y una mejor detección de cambios sutiles en los píxeles. Podemos ver por ejemplo en la Figura 8 la comparativa de las dos gamas de colores utilizadas. Se observan tanto unos perfiles más marcados como una mejor visualización de las sombras dentro del relieve del grano de polen.




Figura 8: Comparativa entre las dos gamas de colores estudiadas.

Observamos a continuación en la Figura 9 los mapas de características de las dos capas de nuestra red convolucional para la imagen anterior.




Figura 9: Mapas de características de las dos capas de CNN para la imagen 8.

Vemos aquí la importancia de los pesos aprendidos durante el entrenamiento. En la primera capa se ha jugado mucho más con el contraste y las transformaciones más abruptas para detectar formas más genéricas, mientras que en la segunda capa se ha centrado mucho más el foco en la aparición de relieves y sombras, con una mayor sensibilidad a los cambios de tonalidad.

Observando algunos ejemplos en concreto, se puede ver en el 38 cómo sus pesos han aprendido a generar unos mapas con altos relieves, simulando la aparición de sombras fruto de una iluminación procedente de la parte superior de la imagen. En efecto, el filtro 38 con los pesos entrenados de la Figura 7 contiene un degradado de pesos en el eje vertical, propiciando lo que observamos en su respectivo mapa de características. En contraste, el mapa 56 por

ejemplo simula volúmenes y sombras procedentes justo de la dirección opuesta. En conjunto, este juego de transformaciones por parte de los pesos aprendidos durante el entrenamiento le proporcionan a la red una información mucho más rica y mejor procesada, permitiendo una mejor generalización y una mayor capacidad de detección de patrones en imágenes, que a simple vista el ojo humano no sería capaz de ver.

Veamos otro ejemplo, ahora del conjunto de test para una nueva imagen donde se observa un patrón circular mucho más marcado. Tenemos en la Figura 10 la imagen de la que se han extraído los mapas de características. Como los pesos aprendidos por la red son los mismos para ambas imágenes en la clasificación, sus patrones en los mapas de características también son similares, ya que la transformación es la misma. Observamos a continuación en la Figura 11 los mapas de características de la imagen 10.




Figura 10: Imagen del conjunto de testeo.




Figura 11: Mapas de características de las dos capas de CNN para la imagen 10.

3.5. Mapas de calor

También mediante el uso de mapas de calor sobre la imagen podemos visualizar la importancia de cada uno de los píxeles en la imagen para la red. En la Figura 12 y 13 se puede observar cómo la red ha aprendido a centrar su atención en ciertas áreas de la imagen, por supuesto como es obvio centrando su atención en los píxeles con información. Cabe destacar que en

estas imágenes se muestra en color rojo las zonas con mayor importancia y en azul aquellas con menor importancia.




Figura 12: Mapa de calor de la Figura 8 para la red convolucional.




Figura 13: Mapa de calor de la Figura 8 para la red convolucional.

4. Conclusiones

Durante el desarrollo de esta práctica, se han propiciado distintas situaciones que han permitido extraer conclusiones fundamentales sobre el diseño, la eficacia y las limitaciones de los modelos de deep learning aplicados a la clasificación de imágenes en campos técnicos donde la variabilidad visual es mínima entre clases.

Una de las conclusiones más relevantes desde un principio fue la implicación del uso de data augmentation y su impacto en las distintas arquitecturas de las redes. Mientras que para el modelo NET-1 esta técnica resultó contraproducente, en cuanto la arquitectura subía ligeramente de complejidad el problema quedaba mitigado, proporcionando mejores resultados y un mejor balanceo de clases. Se pudo observar que, aunque a priori pudiera parecer obvio, no en todos los casos tiene cabida la utilización de data augmentation, siendo indispensable la experimentación previa y un análisis del impacto para determinar su utilidad.

Otro punto importante ha sido la comparación de resultados para redes densas y convolucionales. Aunque las redes convolucionales teóricamente están diseñadas específicamente para trabajar con imágenes, hemos podido ver cómo una red densa bastante simple ha conseguido buenos resultados en nuestro caso de uso, mejorando incluso la demanda computacional en el entrenamiento y los resultados obtenidos para algunos casos de CNN.

Si bien a priori se pudiera ver con los experimentos realizados que el uso de la convolución no es estrictamente necesario, el maridaje de ambas técnicas ha dado fruto a lo mejor de cada una de las arquitecturas. Habiendo obtenido los patrones necesarios por los mapas de características en las capas de convolución, las capas densas han sido capaces, gracias a esta información depurada, de proporcionar una generalización mucho más efectiva de las pequeñas sutilezas de las imágenes, generando modelos con una mayor capacidad de abstracción.

La integración de los distintos enfoques experimentales y la comparación entre arquitecturas han permitido evidenciar que el éxito en la clasificación de imágenes con esta mínima variabilidad visual que nos concierne depende de un proceso iterativo y meticuloso, en el que la experimentación y el análisis crítico son fundamentales. Gracias a esto, se ha podido comprender en profundidad que cualquier investigación en este campo, además de la literatura existente, debe de ir guiada siempre por una experimentación consciente del problema a resolver.