

Minería de Datos

Práctica 4 - Random Forest

Manuel Castillo Cara / Luis Sarro

Octubre 2024

Introducción

En este documento se presenta la cuarta actividad de la asignatura Minería de Datos, del Máster Universitario en Investigación en Inteligencia Artificial (MUIIA). Esta actividad abarca, exactamente, el Tema 7: Bosques Aleatorios. Antes de su realización, se asume que el alumnado ha completado las lecturas indicadas en la guía de la asignatura sobre cada uno de los temas. Aunque no son obligatorias, la realización de las prácticas de programación disponibles en el aula virtual será de gran ayuda para la realización de la PEC4.

El objetivo de esta actividad es que el alumnado ponga en práctica los contenidos teóricos/prácticos relativos a Random Forest para consolidar su conocimiento de estas técnicas. Es importante destacar que, como ocurre en el resto de las actividades evaluables de esta asignatura, lo crucial no es tanto resolver un problema propuesto por el equipo docente, sino demostrar que se han comprendido e interiorizado los diversos aspectos clave de las técnicas que se ponen en juego.

Cómo desarrollar la PEC

En cuanto al software utilizado para realizar la actividad, el equipo docente recomienda el uso de `Scikit-learn` (sobre Python) por su facilidad de uso, aunque no es obligatorio y es posible elegir otras alternativas, tanto en el uso de librerías como uso de otros lenguajes de programación. Se recomienda encarecidamente realizar las prácticas de programación, ya que suponen la comprensión de cómo implementar la práctica en Python. Además, recordamos que las prácticas de programación se han trabajado intensivamente con esta librería, que incluye la gran mayoría de los algoritmos basados en Bagging y, por tanto, Random Forest.

Por tanto, para quienes no tengan experiencia previa, se recomienda, como primer paso para el desarrollo de esta práctica, seguir las prácticas de programación que se encuentran en el mismo aula virtual en Python. Así mismo, podrán utilizar otros lenguajes de programación o librerías con las que se encuentren más cómodos para desarrollar la PEC4. En tal caso, a fin de compartir experiencias, se sugiere al alumnado que abra un hilo en el foro y exponga los motivos de tal decisión y las posibles ventajas de esas alternativas.

Datasets con los que trabajar la PEC

El equipo docente pone a disposición del alumnado un conjunto de datasets que han sido trabajados anteriormente tanto por nosotros como por la comunidad, para que pueda seleccionar uno de ellos. Para la práctica, se trabajará **un único dataset** de entre todos los disponibles, el cual deberá entender en su contexto y desarrollar en la PEC4. En este sentido, a continuación se presentan un conjunto variado de datasets:

- <https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+%28Diagnostic%29>
- <https://archive.ics.uci.edu/dataset/471/electrical+grid+stability+simulated+data>
- <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients>
- <https://archive.ics.uci.edu/ml/datasets/Wine+Quality>
- <https://archive.ics.uci.edu/dataset/162/forest+fires>
- <https://archive.ics.uci.edu/ml/datasets/Air+quality>
- <https://archive.ics.uci.edu/ml/datasets/HCV+data>
- <https://archive.ics.uci.edu/ml/datasets/Statlog+%28Image+Segmentation%29>
- <https://archive.ics.uci.edu/dataset/329/diabetic+retinopathy+debrecen>
- <https://archive.ics.uci.edu/ml/datasets/Bike+Sharing+Dataset>
- <https://archive.ics.uci.edu/ml/datasets/Appliances+energy+prediction>
- <https://archive.ics.uci.edu/ml/datasets/QSAR+aquatic+toxicity>
- <https://archive.ics.uci.edu/dataset/31/covertime>
- <https://www.kaggle.com/datasets/camnugent/california-housing-prices>
- <https://www.kaggle.com/datasets/schirmerchad/bostonhousingmlnd>

Adicionalmente, desde el equipo docente exponemos que la elección de los datasets es totalmente libre, es decir, el alumnado podrá seleccionar cualquier otro dataset en formato tabular que considere interesante. **Importante:** Eso sí, antes de realizar cualquier tipo de elección propia de un dataset que no sea los expuestos anteriormente, se debe subir al foro para poder evaluarlo previamente.

Especificación de la tarea

A partir del conjunto de datos que se haya escogido para la tarea, se propone el desarrollo de un proyecto de machine learning completo. La idea es realizar todas las fases de un proyecto de machine learning, poniendo un énfasis en el desarrollo de la fase de modelado con los algoritmos Bagging. Así, las diferentes fases a realizar serán:

- Fase de análisis de datos.
- Fase de preprocesamiento y tratamiento de datos.
- Fase de modelado.
- Fase de optimización.

IMPORTANTE: Aunque se deberá exponer en la práctica el código, no se calificará el mismo, sino que se calificarán el análisis crítico de los resultados, la discusión en la salida del código y visualizaciones y, sobre todo, la discusión crítica y el hilo argumental que el alumnado proporcione.

Fase de análisis de datos

En esta fase, se estudiará una de las partes más importantes para trabajar en analítica predictiva, es decir, el análisis de los datos y el conocimiento de su comportamiento. Para ello, comenzaréis manipulando un conjunto de datos que hayáis seleccionado para la PEC4 para, posteriormente, intentar conocer y entender su comportamiento. El lenguaje de programación escogido proporciona una serie de funciones muy interesantes que deberemos utilizar al inicio del trabajo en modelado predictivo.

En este sentido, el tema se divide en los siguientes conceptos para su análisis:

- **Estadística Descriptiva.** Este es uno de los temas más importantes que los que trabajan con machine learning deben conocer. Entender los datos y analizar sus atributos e instancias serán lo primero que deberemos observar en cualquier proyecto.
- **Visualización de datos.** Proporcionar una serie de gráficos para poder visualizar los datos, analizarlos y discutir sus fortalezas y debilidades correctamente.
- **Análisis Exploratorio de Datos:** Empezaremos viendo cómo se realiza un correcto Análisis Exploratorio de nuestros datos con la base de la unidad anterior.

Por poner algunos ejemplos de lo que se puede trabajar en esta parte: tipo de problema (clasificación / regresión), outliers, valores corruptos, valores NaN, distribución en los datos (gaussiana, exponencial, ...), tipo de variable (categórica o numérica), desbalance de la clase en un problema de clasificación, etc.

Fase de preprocesamiento y tratamiento de datos

En esta fase, se trabajará con las funciones de generación de gráficos para ver el comportamiento e interrelaciones de las diferentes características de un conjunto de datos en particular. Así mismo, se trabajarán los conceptos de selección de características. Por tanto, se podrá dividir en estos apartados:

- **Preprocesamiento de datos:** Se analizarán las diferentes técnicas de preprocesamiento y/o transformación de datos que tenemos a nuestra disposición para poder realizar un buen preprocesamiento de datos y, así, mejorar el rendimiento de nuestros modelos.
- **Fase de tratamiento de datos:** El proceso de *feature selection* y/o *feature importance* en los datos permite modelar su problema y se denomina selección de mejores características, es decir, atributos más relevantes para los modelos de aprendizaje.

Por poner algunos ejemplos de lo que se puede trabajar en esta parte: corrección del desbalance de la clase, normalización, estandarización, Box-Cox, PCA, etc. Más importante aún es la parte de Fase de Tratamiento de datos, es decir, el uso de técnicas como Extra Trees, Random Forest, etc, para la selección de variables. **Importante:** En este último punto hay que poner especial énfasis ya que tiene un peso mayor en la nota que la Fase de Prerocesamiento. La idea principal es poder contrastar las técnicas ya estudiadas en el Tema 4: Selección de características con las nuevas vistas en el Tema 7: Random Forest.

Fase de modelado

En esta fase, se debatirá sobre los algoritmos ensembles para comparar su rendimiento y buscar a los mejores candidatos. De todos los algoritmos que se han visto y que podáis probar, se seleccionarán los 3 modelos que mejor resultado cuantitativo y cualitativo hayan obtenido para poder analizarlos en la fase de optimización. Se deberán trabajar los algoritmos vistos en esta tema 7 con lo ya estudiados en los temas 2, 3, 4 y 5 (el MultiLayer Perceptron). La idea principal es evaluar si los modelos Bagging han obtenido un mejor resultado (o no) y por qué.

Cuadro 1: Rúbrica o distribución de puntos para la evaluación.

Concepto	Puntos
1. Fase de análisis de datos	1
2. Fase de preprocesamiento y tratamiento de datos	3
3. Fase de modelado	3
4. Fase de optimización	2
5. Conclusiones	1
Extra: Explicabilidad e interpretabilidad en Bagging	2

Fase de optimización

La fase de optimización es crucial para mejorar el rendimiento de los algoritmos de machine learning. En esta etapa, se seleccionarán los 3 modelos ensembles con mejor desempeño cuantitativo y cualitativo. El objetivo es ajustar los hiperparámetros de estos modelos para maximizar su rendimiento.

Para llevar a cabo esta optimización, se recomienda utilizar técnicas de búsqueda de hiperparámetros, como la validación cruzada, la búsqueda en cuadrícula (*grid search*) o la búsqueda aleatoria (*random search*). Estas técnicas permiten explorar diferentes combinaciones de hiperparámetros y seleccionar aquellos que mejoren el rendimiento del modelo.

Además, es importante documentar y justificar los cambios realizados en los hiperparámetros y cómo estos ajustes han afectado el rendimiento del modelo. Se debe discutir si se ha logrado una mejora significativa en términos cuantitativos y cualitativos, y si los resultados obtenidos son consistentes y robustos.

Entregable

Se entregará una memoria que deberá estar en formato Jupyter Notebook, similar a las que se han puesto a disposición del alumnado. No se está indicando una longitud máxima (equivalente a un número máximo de páginas en formato PDF), pero queremos dejar claro que nos interesa el análisis crítico en la resolución de un proyecto de machine learning, y sobre todo, en el uso de los algoritmos ensembles. Por tanto, conceptos ampliamente conocidos pueden ser referenciados, pero no es necesario que se expongan en la misma entrega.

IMPORTANTE: Para asegurar una evaluación justa y coherente, es crucial que los estudiantes sigan estrictamente el orden y los puntos expuestos en el Cuadro 1. Esto garantizará que todos los aspectos importantes del proyecto sean abordados de manera completa y sistemática. La estructura y el contenido de la memoria deben reflejar claramente cada uno de los puntos mencionados, proporcionando un análisis detallado y crítico en cada sección.

Evaluación

La evaluación de esta práctica estará basada exclusivamente en la memoria entregada, y se hará teniendo en cuenta la distribución de puntos mostrada en el Cuadro 1. La nota final máxima será de 10 puntos, y será necesario obtener al menos 5 para aprobar.

Incidimos en que se valorará particularmente la capacidad de análisis crítico y la puesta en juego de los conceptos, antecedentes y limitaciones presentadas en la bibliografía. También se valorará el estilo y la corrección ortográfica del texto.

Finalmente, no se deben incluir definiciones ni formalización matemática ampliamente conocidas. Lo que se valora es la discusión técnica de los resultados obtenidos y cómo se enlazan estos resultados

con la teoría. Se debe centrar en la discusión crítica de los resultados obtenidos en la práctica y no en definiciones ampliamente conocidas. Lo más importante es que demostréis que habéis entendido los contenidos del tema y que los manejáis con soltura.

Extra: Explicabilidad e interpretabilidad en Bagging

Para aquellos estudiantes que deseen profundizar más en su comprensión de los algoritmos Bagging, se ofrece un punto extra opcional sobre la explicabilidad e interpretabilidad de estos modelos. Estos 2 puntos extra están diseñados para incentivar la curiosidad y el análisis crítico del dataset que hayan elegido y desarrollado todos los puntos de la práctica.

Indicaciones para abordar este extra

El objetivo de este punto extra es que los estudiantes exploren y discutan cómo los modelos ensembles pueden ser interpretados y explicados. Esto incluye el uso de técnicas de explicabilidad como SHAP (*SHapley Additive exPlanations*) [1], LIME (*Local Interpretable Model-agnostic Explanations*) [2], o cualquier otra técnica relevante que permita entender mejor cómo los modelos ensembles toman decisiones.

1. **Implementación de técnicas de explicabilidad:** Aplicar una o más técnicas de explicabilidad al modelo ensembles desarrollado en la práctica. Esto puede incluir la generación de gráficos SHAP [1], el uso de LIME [2] para explicar predicciones individuales, o cualquier otra técnica que se considere adecuada.
2. **Análisis crítico:** Discutir los resultados obtenidos con las técnicas de explicabilidad. ¿Qué atributos son más importantes para las predicciones del modelo? ¿Cómo se comportan estos atributos en diferentes instancias del dataset? ¿Qué conclusiones se pueden extraer sobre la interpretabilidad del modelo?
3. **Visualización:** Presentar los resultados de las técnicas de explicabilidad de manera visual. Esto puede incluir gráficos de importancia de características, gráficos de dependencia parcial, o cualquier otra visualización que ayude a entender mejor el comportamiento del modelo.

Entrega

La entrega de estos 2 puntos extra debe incluir una sección adicional en la memoria del proyecto, donde se detallen los pasos seguidos, los resultados obtenidos y el análisis crítico realizado.

Estos puntos extra es opcional, pero se anima a los estudiantes a explorarlo para profundizar en su comprensión de los modelos ensembles y su aplicación en la PEC4.

Referencias

- [1] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017.
- [2] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "Why should I trust you?".^{Ex}plaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*, pages 1135–1144, 2016.