

Práctica 4

David García Curbelo

—

Minería de Datos

Universidad Nacional de Educación a Distancia

Curso 2024-2025

Índice

1. Introducción	2
2. Análisis exploratorio	2
2.1. Descripción del dataset	2
2.2. Análisis de los datos	3
2.2.1. Características	3
2.2.2. Variable objetivo	4
2.2.3. Análisis conjunto de características y variable objetivo	6
3. Preprocesamiento y tratamiento de datos	8
3.1. Normalización de los datos	8
3.2. Selección de características	9
3.2.1. Métodos clásicos	9
3.2.2. Métodos de árboles de decisión	11
3.2.3. Selección de características finales	13
4. Modelado	14
4.1. Resumen de Resultados	14
4.2. Modelos seleccionados	15
5. Optimización de hiperparámetros	16
5.1. Resultados de la Optimización	16
5.2. Evaluación sobre Test	17
5.3. Análisis y Selección del Modelo Final	18
6. Conclusiones	20
Referencias	21

1. Introducción

En este trabajo se presenta una investigación profunda sobre el proceso de análisis de datos y su aplicación a selección de modelos dentro del grupo de árboles de decisión. Se ha usado el dataset *breast-cancer-wisconsin* de la UCI Machine Learning Repository, que contiene información sobre tumores de mama y su clasificación como benignos o malignos. El objetivo es aplicar diferentes algoritmos de árboles de decisión y evaluar su rendimiento en términos de precisión, sensibilidad y especificidad.

2. Análisis exploratorio

2.1. Descripción del dataset

El conjunto de datos *breast-cancer-wisconsin* es un recurso ampliamente empleado en tareas de clasificación y análisis biomédico. Este conjunto de datos, disponible en el UCI Machine Learning Repository, contiene información derivada de imágenes digitalizadas de aspirados con aguja fina de masas mamarias [3].

El objetivo principal del dataset es predecir si un tumor es benigno o maligno a partir de diversas características morfológicas extraídas de las imágenes microscópicas de las células. Cada instancia del conjunto de datos representa una muestra individual y está compuesta por un conjunto de variables numéricas que describen propiedades específicas de los núcleos celulares.

Las características principales del dataset son las siguientes:

- **Instancias:** 569 registros.
- **Características:** 30 variables numéricas continuas.
- **Variable objetivo:** Tipo de tumor (benigno o maligno).

Además, las características se dividen en tres grupos de 10 atributos cada uno, que representan diferentes aspectos de las medidas tomadas en las células. Los atributos son radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. Para cada una de ellas, se presentan las siguientes medidas:

- **mean:** Describen el valor promedio de los atributos.
- **error:** Reflejan la desviación estándar de las mismas propiedades.
- **worst:** Representan el valor máximo observado para cada atributo.

2.2. Análisis de los datos

2.2.1. Características

Tras un primer estudio de los datos, no se han observado valores nulos ni corruptos en el dataset. Todas las variables predictoras son numéricas continuas, lo que facilita el análisis estadístico y su posterior aplicación de los algoritmos de aprendizaje automático.




Figura 1: Distribución de los datos para cada una de las características.

Además, centrando nuestra atención en la distribución individual que presenta cada una de las características, podemos observar en la Figura 1 cómo todas ellas siguen una distribución que se aproxima a la normal, y en muchas de ellas con un marcado sesgo positivo en la curva.

También es muy importante la visualización de la correlación dos a dos que existe entre las variables, puesto que pueden surgir patrones como el que veremos a continuación. En la Figura 2 se ha dividido el gráfico según los tres subgrupos de variables mencionados anteriormente: mean, error y worst. Esto ha dado lugar, además de la matriz 30×30 resultante del conjunto total de variables, a una matriz 3×3 de la cual podemos extraer patrones muy interesantes.

Podemos observar que las variables asociadas a *radius*, *perimeter* y *area* están altamente correlacionadas entre sí, lo que indica que estas características están relacionadas y podrían contener información complementaria. Por otro lado, las variables asociadas a *texture*, *smoothness* y *fractal dimension* presentan una correlación considerablemente más baja con las demás, lo que podría sugerir que estas variables están aportando ruido a los datos, no siendo

variables relevantes para la predicción.¹




Figura 2: Correlación entre las características, con separación entre los tres subgrupos mean, error y worst.


Lo más relevante de esta matriz de correlación es que la relación entre esas variables (ya sean con datos de mean, error o worst) se mantiene más o menos estable en los 9 cuadrantes. A nivel de estos 3 subgrupos, vemos cómo estas correlaciones se ven incentivadas positivamente allá donde las variables de mean se vean implicadas, en especial entre ellas y con las del subgrupo de worst.

Sin embargo, se observa claramente que las variables de error son las que menos correlación presentan con el resto de variables, lo que podría sugerir que estas variables no aportan información relevante.

2.2.2. Variable objetivo

¹Veremos a posteriori si realmente estas variables aportan ruido o no cuando se estudie su relevancia en conjunto con la variable objetivo.

La variable objetivo del dataset es la clasificación de los tumores como benignos o malignos. En el conjunto de datos, esta variable se representa mediante un valor binario, donde 0 indica un tumor benigno y 1 indica un tumor maligno. La distribución de la variable objetivo no es excesivamente desequilibrada, con 357 instancias de tumores benignos y 212 instancias de tumores malignos.



Realizando un análisis pormenorizado de la distribución de la variable objetivo para cada una de las características, se observa en la Figura 3 un marcado solapamiento para la mayoría de características, lo que sugiere que la separación entre las dos clases no es tan clara como podría esperarse.




Figura 3: Distribución de la variable objetivo para cada una de las características.

Es por ello que es necesario realizar un análisis conjunto de las variables para tratar de encontrar una mejor separación entre las dos clases a clasificar.

2.2.3. Análisis conjunto de características y variable objetivo

Para analizar la relación entre las características y la variable objetivo, se han realizado gráficos de dispersión conjuntos cada una de las características, separadas por cada uno de los tres subgrupos para una mejor visualización.²




Figura 4: Distribución de las características del subgrupo mean con respecto a la variable objetivo.

Podemos observar en la Figura 4 de forma más acusada la relación lineal que existe entre las variables *radius*, *perimeter* y *area* dentro del subgrupo mean. Además, no sólo se observa una relación lineal entre estas variables, sino que también se puede apreciar cómo en general en este grupo la separación entre las dos clases de la variable objetivo es bastante clara. Esto sugiere que este subgrupo de características es bastante relevante para nuestro problema de clasificación.

En el caso de la Figura 5, se observa que la separación entre las dos clases de la variable objetivo no es tan clara como en el caso del subgrupo mean. Sin embargo, todavía hay una tendencia general en la que la implicación de

²Recalcar que no se ha realizado este estudio entre distintos subgrupos de características, ya que, debido a la cantidad de características, la visualización se haría muy complicada y no aportaría información relevante.




Figura 5: Distribución de las características del subgrupo error con respecto a la variable objetivo.

las variables *radius*, *perimeter* y *area* sugiere que algunas características de este subgrupo puedan ser útiles para la clasificación.

Por último, en la Figura 6 se observa de nuevo que la separación entre las dos clases de la variable objetivo es bastante clara, presentando incluso relaciones lineales como en el caso del subgrupo mean, incluso para sus mismas variables. Esto denota una fuerte alineación de los grupos mean y worst, lo que podría sugerir que el subgrupo worst es una redundancia del grupo mean, o viceversa.




Figura 6: Distribución de las características del subgrupo worst con respecto a la variable objetivo.

3. Preprocesamiento y tratamiento de datos

3.1. Normalización de los datos

Para el preprocesamiento de los datos, se ha dividido el dataset en tres conjuntos: entrenamiento, evaluación y test, con una proporción del 60 % para entrenamiento, 20 % para evaluación y 20 % para testeo. Todo el preprocesamiento que sigue se ha realizado sobre el conjunto de entrenamiento, y posteriormente se ha aplicado al conjunto de evaluación y test para que así la evaluación de los modelos no se vea influenciada por el preprocesamiento.

Tras la división de los subconjuntos, se ha optado por aplicar una normalización a las características del dataset. La normalización es un paso crucial en el análisis de datos, ya que permite que todas las características tengan la misma escala y rango, lo que facilita la convergencia de los algoritmos de aprendizaje automático. En este caso, se ha utilizado el método *StandardScaler* de la biblioteca *scikit-learn*, que transforma los datos para que tengan una media de 0 y una desviación estándar de 1. Aunque la normalización no es estrictamente necesaria para todos los algoritmos de aprendizaje automático,

es una práctica recomendada.

Por último, aunque no estrictamente necesario, se ha aplicado el método *SMOTE* (Synthetic Minority Oversampling Technique) para equilibrar el conjunto de datos. Este método genera nuevas instancias sintéticas de la clase minoritaria (en este caso, los tumores malignos) para equilibrar la distribución de clases en el conjunto de entrenamiento.

3.2. Selección de características

Debido a los análisis exploratorios de los datos realizados anteriormente, se presupone que no todas las variables van a ser relevantes para la clasificación. Es por ello que se ha decidido aplicar distintos métodos de selección de características para reducir la dimensionalidad del conjunto de datos y mejorar el rendimiento de los modelos. Los métodos aquí planteados se han dividido en dos secciones. En la primera, los algoritmos mostrados han sido estudiados en detalle en la segunda entrega del curso [1]. Por otro lado, en una segunda sección veremos métodos aplicados mediante algoritmos asociados a árboles de decisión, presentes en el libro base de la asignatura [2].

3.2.1. Métodos clásicos

Información mutua

Este método univariado evalúa la dependencia entre cada característica y la variable objetivo. Se calcula la información mutua entre cada característica y la variable objetivo, y se seleccionan las características con mayor información mutua.

Observamos en la Figura 7 que, a nivel individual de cada una de las características, observamos una predominancia en las primeras posiciones de variables pertenecientes a los subgrupos *worst* y *mean*, predominando la media tabla el subgrupo de error. Esto nos muestra de nuevo que las características de los subgrupos *worst* y *mean* presentan una relación más directa con la variable objetivo, predominando además las asociadas a *concave points* y *perimeter*.




Figura 7: Ranking de características mediante Información Mutua.

Test- F

El test- F es otro método estadístico univariante que evalúa la relación entre cada característica y la variable objetivo mediante la comparación de varianzas. Se calcula el valor del estadístico F para cada característica y se seleccionan las características con los valores más altos.

En la Figura 8 se observa que, al igual que en el caso de la información mutua, las características de los subgrupos worst y mean predominan en las primeras posiciones del ranking. Sin embargo, en este caso, el subgrupo error presenta una correlación más baja con la variable objetivo, destacando por presentar más de la mitad de ellas puntuaciones cercanas a cero.

Por otro lado, sigue destacando en relación univariada la variable *concave points* y *perimeter* tanto para el subgrupo de worst como de mean, que se encuentran en las primeras posiciones del ranking. Además, a nivel de Score obtenido, se pueden distinguir tres grupos claramente marcados, donde el tercer grupo (Scores menor que 200) contiene todas las variables del subgrupo error, lo que indica que en relación univariada no son el subgrupo que más información aporta a la variable objetivo.




Figura 8: Ranking de características mediante Test- F .

ReliefF

El algoritmo ReliefF es un método multivariado de selección de características que evalúa la importancia de cada característica en función de su capacidad para distinguir entre instancias cercanas. Este método nos proporcionará una perspectiva distinta a la de los métodos univariados, ya que tiene en cuenta la interacción entre las características.

En la Figura 9 se observa que, al igual que en los métodos univariados, las características de los subgrupos worst y mean predominan en las primeras




Figura 9: Ranking de características mediante ReliefF.

posiciones del ranking. Como en los test anteriores, de nuevo las primeras posiciones están ocupadas por las variables *concave points*, *perimeter* y *radius*, lo que refuerza la idea de que estas características son relevantes para la clasificación.

RFE-SVM

En este caso, se ha utilizado el algoritmo de eliminación recursiva de características con un clasificador SVM como modelo base.

Para este caso se observa que el algoritmo ha seleccionado las características de forma diferente a los métodos anteriores. En la Tabla 1 se observa que las variables *perimeter* y *radius* son las más relevantes, pero también se incluyen otras características asociadas al subgrupo error, como *perimeter error* y *radius error*, que no habían sido destacadas en los métodos univariados.

Este algoritmo ha encontrado unos patrones que difieren considerablemente de los métodos anteriores, lo que sugiere que la interacción entre las características es importante para la clasificación. Además, se observa que el algoritmo ha seleccionado características de todos los subgrupos, lo que indica que la combinación de características de diferentes grupos puede ser beneficiosa para el rendimiento del modelo.

feature	ranking
worst perimeter	1
worst radius	2
worst smoothness	3
perimeter error	4
worst area	5
mean concave points	6
worst texture	7
radius error	8
worst concavity	9
area error	10
compactness error	11
mean radius	12
mean perimeter	13
worst symmetry	14
smoothness error	15
mean fractal dimension	16
concave points error	17
fractal dimension error	18
symmetry error	19
mean concavity	20
mean compactness	21
mean area	22
worst concave points	23
mean texture	24
mean smoothness	25
worst compactness	26
mean symmetry	27
worst fractal dimension	28
texture error	29
concavity error	30

Cuadro 1: Ranking de Características por RFE-SVM.

3.2.2. Métodos de árboles de decisión

Para los dos siguientes métodos que se presentan a continuación de medición de importancia de las características, se han entrenado dos modelos basados en árboles de decisión: un clasificador *Random Forest* y un clasificador *Extra Trees*. Ambos modelos son algoritmos se han entrenado con 100 estimadores, y se han utilizado exclusivamente para calcular la importancia de las características mediante el método de Gini y el método de permutación de variables

Importancia Gini

La importancia de Gini es un método que evalúa la importancia de cada característica en función de su contribución a la reducción de la impureza del nodo en el árbol de decisión. Este método se basa en el índice de Gini, que mide la pureza de los nodos en un árbol de decisión.

En este caso se observa cierta consistencia (salvo pequeñas variaciones locales) en el orden aportado por ambos modelos para el cálculo de este método. En la Figura 10 se han ordenado los registros por la suma de la importancia en ambos modelos, y se observa que el orden es muy similar al de los métodos anteriores, destacando las variables *worst concave points* y *radius* como las más relevantes. Además, se observa que las variables del subgrupo error tienen una importancia menor en comparación con las variables de los subgrupos *worst* y *mean*, ratificando su escasa importancia en el análisis.




Figura 10: Ranking de características mediante la Importancia Gini.

Importancia de Permutación

La importancia de permutación es un método que evalúa la importancia de cada característica en función de su impacto en el rendimiento del modelo. Este método mide la disminución del rendimiento del modelo al permutar los valores de una característica específica.

Al igual que en el caso anterior, el orden mostrado es el asociado a la suma de los resultados obtenidos en ambos modelos. Sin embargo, se observa aquí en la Figura 11 una variabilidad mucho más alta en cuanto a los resultados obtenidos por los dos modelos. Por ejemplo, destaca que la primera posición la ocupe




Figura 11: Ranking mediante la Importancia por Permutación.

la variable *worst radius*, cuando para el modelo *Random Forest* ocupaba la posición 10. Otro caso muy visual es el de la variable *mean smoothness*, donde ambos modelos difieren por completo en su impacto en el rendimiento del modelo.

Además, esta inconsistencia entre ambos modelos ha producido que el orden obtenido con respecto a los métodos anteriores haya cambiado considerablemente. En este caso, las variables del subgrupo error han obtenido una puntuación más alta que en los métodos anteriores, lo que sugiere que la importancia de estas características puede depender del modelo utilizado.

3.2.3. Selección de características finales

Para la selección de características finales, se ha optado por un enfoque combinado que incluye tanto los métodos clásicos como los métodos basados en árboles de decisión. Se han seleccionado las 10 características más relevantes de cada método y se han combinado para formar un conjunto final de características. Esta combinación se ha realizado mediante la media de las puntuaciones obtenidas por cada característica en los diferentes métodos. El conjunto final de características seleccionadas incluye las siguientes variables:

- *worst concave points*
- *mean concave points*
- *worst area*
- *worst perimeter*
- *worst concavity*
- *worst radius*
- *mean concavity*
- *mean radius*
- *mean perimeter*
- *mean area*

Se realizarán a continuación comparaciones en la fase de modelado entre el rendimiento de los modelos con este conjunto de características y el rendimiento de los modelos con todas las características del dataset. Esto permitirá evaluar si la reducción de dimensionalidad mejora el rendimiento del modelo y si la selección de características realizada es efectiva.

4. Modelado

4.1. Resumen de Resultados

En esta fase, hemos entrenado y evaluado un conjunto diverso de algoritmos de clasificación³ utilizando validación cruzada para obtener una estimación robusta de su rendimiento predictivo. Se evaluaron dos escenarios: uno utilizando el conjunto completo de 30 características originales y otro utilizando el subconjunto calculado de 10 características. El objetivo es comparar el desempeño inicial de los modelos seleccionados e identificar los tres modelos más adecuados para una optimización de hiperparámetros posterior.

Los resultados promedio (media $\pm$ desviación estándar) obtenidos mediante validación cruzada para ambos escenarios se presentan a continuación.

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.96 $\pm$ 0.03	0.95 $\pm$ 0.05	0.94 $\pm$ 0.06	0.94 $\pm$ 0.04
G. Boosting	0.96 $\pm$ 0.03	0.96 $\pm$ 0.03	0.92 $\pm$ 0.07	0.94 $\pm$ 0.04
Bagging	0.95 $\pm$ 0.02	0.95 $\pm$ 0.02	0.92 $\pm$ 0.05	0.93 $\pm$ 0.04
k-NN	0.93 $\pm$ 0.03	0.93 $\pm$ 0.03	0.88 $\pm$ 0.08	0.90 $\pm$ 0.05
SVM	0.91 $\pm$ 0.02	0.96 $\pm$ 0.03	0.80 $\pm$ 0.03	0.87 $\pm$ 0.02
MLP	0.89 $\pm$ 0.01	0.83 $\pm$ 0.03	0.89 $\pm$ 0.06	0.86 $\pm$ 0.02

Cuadro 2: Resultados de validación cruzada por modelo (30 características)

Modelo	Accuracy	Precision	Recall	F1-Score
Random Forest	0.95 $\pm$ 0.03	0.95 $\pm$ 0.05	0.91 $\pm$ 0.04	0.93 $\pm$ 0.03
G. Boosting	0.94 $\pm$ 0.02	0.94 $\pm$ 0.04	0.91 $\pm$ 0.05	0.92 $\pm$ 0.03
Bagging	0.94 $\pm$ 0.03	0.94 $\pm$ 0.04	0.89 $\pm$ 0.04	0.92 $\pm$ 0.04
k-NN	0.93 $\pm$ 0.03	0.93 $\pm$ 0.03	0.88 $\pm$ 0.08	0.90 $\pm$ 0.05
SVM	0.91 $\pm$ 0.01	0.96 $\pm$ 0.03	0.81 $\pm$ 0.02	0.88 $\pm$ 0.02
MLP	0.90 $\pm$ 0.04	0.96 $\pm$ 0.02	0.78 $\pm$ 0.11	0.85 $\pm$ 0.06

Cuadro 3: Resultados de validación cruzada por modelo (10 características)

Al comparar los resultados de ambos escenarios observamos que, en general, los modelos basados en ensambles obtienen un rendimiento ligeramente superior cuando utilizan el conjunto completo de características. Aunque la reducción de dimensionalidad podría esperarse que simplificara el modelo o

³Cabe destacar que los seis algoritmos seleccionados han sido evaluados sobre instancias de clasificadores con los hiperparámetros por defecto proporcionados por la librería *scikit-learn*, los cuales son además valores típicos con los que se suelen entrenar estos clasificadores. El ajuste de estos hiperparámetros se realizará en la sección siguiente.

redujera el ruido, en este caso parece haber eliminado información relevante para estos algoritmos potentes, que intrínsecamente manejan bien un mayor número de variables debido al modo con el que manejan los datos en el aprendizaje. Para modelos como SVM o k-NN, la diferencia es mínima o inexistente, mientras que MLP muestra resultados mixtos.

Es cierto que la reducción de características ha permitido una reducción en el tiempo de entrenamiento y evaluación, lo que podría ser beneficioso en escenarios con conjuntos de datos más grandes o complejos. Sin embargo, en este caso específico, la reducción de dimensionalidad ha afectado negativamente el rendimiento de los modelos basados en ensambles, que son los más potentes y robustos para este tipo de tareas. Dado que los ensambles son el foco principal y muestran mejor rendimiento con todas las características, continuaremos el análisis y la selección basándonos en los resultados obtenidos con el total del espacio de características.

4.2. Modelos seleccionados

Considerando tanto el rendimiento cuantitativo como la estabilidad de la desviación estándar, los tres modelos seleccionados para pasar a la fase de optimización son:

1. **Random Forest:** Por obtener el mejor rendimiento general (Accuracy y F1-Score) y mostrar un buen equilibrio entre precisión y exhaustividad, además de una estabilidad razonable. Es el algoritmo central de esta práctica y su rendimiento justifica plenamente su inclusión.
2. **Gradient Boosting:** Por su rendimiento casi idéntico al de Random Forest, su excelente estabilidad (bajas desviaciones estándar) y por ser un representante clave de la familia de algoritmos de Boosting, lo que permite una comparación directa y profunda entre las dos principales estrategias de ensambles basados en árboles.
3. **Bagging Classifier:** Aunque ligeramente inferior a los dos anteriores, su rendimiento sigue siendo muy alto y superior al resto de modelos. Incluirlo permite analizar directamente el impacto de la modificación introducida por Random Forest (selección aleatoria de variables) y evaluar si la optimización de hiperparámetros puede acercar su rendimiento a los de *Random Forest* y *Gradient Boosting*.

5. Optimización de hiperparámetros

Para esta fase se empleó la técnica de Grid Search con validación cruzada de 5 divisiones para realizar la búsqueda óptima de hiperparámetros. Para cada uno de los tres modelos seleccionados, se definió un espacio de búsqueda de hiperparámetros clave asociado a cada modelo, y se utilizó el acierto de los modelos para guiar la búsqueda y seleccionar la mejor combinación de ellos.

Una vez identificados los mejores hiperparámetros para cada modelo según el acierto promedio en la evaluación de la validación cruzada, el modelo final se reentrenó con dichos parámetros utilizando la totalidad de los datos de entrenamiento. Finalmente, este modelo optimizado se evaluó sobre el conjunto de test, que no fue utilizado durante el proceso de selección de modelos ni de optimización, para obtener una estimación final del rendimiento generalizado.

5.1. Resultados de la Optimización

La búsqueda en cuadrícula arrojó los siguientes resultados, identificando la mejor combinación de hiperparámetros y el F1-score ponderado promedio correspondiente obtenido durante la validación cruzada:

- **Random Forest:**
 - Mejor Accuracy (CV): **0.9754**
 - Mejores Parámetros:
 - max_depth: None
 - max_features: sqrt
 - min_samples_leaf: 1
 - min_samples_split: 2
 - n_estimators: 200
- **Gradient Boosting:**
 - Mejor Accuracy (CV): **0.9772**
 - Mejores Parámetros:
 - learning_rate: 0.1
 - max_depth: 5
 - n_estimators: 200
 - subsample: 0.7

■ Bagging Classifier:


- Mejor Accuracy (CV): **0.9719**
- Mejores Parámetros:
 - estimator_max_depth: None
 - max_features: 0.85
 - max_samples: 0.7
 - n_estimators: 300

5.2. Evaluación sobre Test

Los modelos fueron reentrenados con los mejores hiperparámetros encontrados sobre el conjunto total de entrenamiento y evaluados en el conjunto de test. A continuación se presentan las métricas y las matrices de confusión para cada modelo optimizado.

Random Forest


Accuracy: **0.9304**
F1-score: **0.9298**



Gradient Boosting

Accuracy: **0.9392**


F1-score: **0.9386**



Bagging Classifier

Accuracy: **0.9392**

F1-score: **0.9386**



5.3. Análisis y Selección del Modelo Final

La evaluación final en el conjunto de test revela un rendimiento muy similar y alto para los tres modelos optimizados. Tanto *Gradient Boosting* como *Bagging Classifier* obtienen un F1-score idéntico de 0.9392, superando ligeramente a *Random Forest*.

Al examinar los informes de clasificación y las matrices de confusión, observamos que *Gradient Boosting* y *Bagging* no solo alcanzan el mismo F1-score global, sino que también presentan métricas idénticas por clase y la misma matriz de confusión. Ambos clasifican erróneamente 6 instancias benignas como malignas, y solo un falso negativo. Esto se traduce en una precisión muy alta para la clase benignas y un recall muy alto para la clase malignas.

Es interesante notar la discrepancia entre los altísimos scores obtenidos durante la validación cruzada y los scores finales en el conjunto de test. Esta

diferencia, aunque no drástica, sugiere que los scores de CV o bien sufrieron una leve sobreestimación de los modelos durante la búsqueda GridSearch, o simplemente ha sido el resultado de la elección en la división de los datos y las peculiaridades de los mismos.

También es relevante comparar estos resultados finales con los obtenidos en la fase de modelado antes de la optimización (utilizando las 30 características y los parámetros por defecto). En esa fase, *Random Forest* y *Gradient Boosting* obtuvieron un F1 de 0.94 en la validación cruzada, y *Bagging* un F1 de 0.93. Sorprendentemente, la optimización de hiperparámetros no ha resultado en una mejora considerable en la evaluación de las métricas mediante la validación cruzada. Podría indicar que los parámetros por defecto de Scikit-learn ya eran muy adecuados para este problema o que la cuadrícula explorada, aunque extensa, no contenía una combinación que generalizara marginalmente mejor en el test set final.

Dado el rendimiento idéntico y superior en el conjunto de test, tanto *Gradient Boosting* como *Bagging Classifier* se pueden considerar como los mejores modelos resultantes de este estudio. La elección final entre ambos podría basarse en otros criterios no evaluados aquí, como el tiempo de inferencia, la interpretabilidad o la robustez ante ligeras variaciones en los datos.

6. Conclusiones

La realización de este trabajo ha permitido no solo aplicar y evaluar diversas técnicas de modelado predictivo, sino también reflexionar sobre la dinámica y las particularidades del proceso completo de un proyecto de este tipo. La estructuración en fases bien definidas, aunque necesario en este tipo de proyectos, ha revelado una interconexión entre ellas, que ha requerido en varios casos hacer y deshacer las distintas fases en función de los resultados obtenidos.

Una de las observaciones más significativas surgió durante la etapa de tratamiento de datos, específicamente en la evaluación del impacto de la selección de características. A pesar de explorar múltiples enfoques y de construir un conjunto reducido de variables teóricamente más relevantes, la evaluación empírica posterior demostró que los modelos de ensamble más potentes alcanzaban un rendimiento bastante superior al operar sobre el espacio completo de características original. Este hecho entra en conflicto con lo que se esperaba de la reducción de dimensionalidad, con la que se esperaban beneficios en términos de simplificación o generalización. Sin embargo, la experimentación en esta práctica nos ha mostrado cómo algoritmos robustos pueden gestionar eficazmente una mayor dimensionalidad, extrayendo información útil incluso de variables que podrían parecer ruidosas.

Otro aspecto notable del flujo de trabajo se manifestó en la fase de optimización de hiperparámetros. La evaluación final de estos modelos optimizados sobre el conjunto de test nos mostró que la evaluación durante la validación cruzada nos puede anticipar un rendimiento muy distinto al que se podría esperar del modelo. Esta divergencia entre las métricas obtenidas en validación cruzada y el rendimiento real sobre datos nuevos, pone de relieve la importancia crítica del conjunto de test como el verdadero árbitro de la capacidad de generalización.

En definitiva, este trabajo práctico ha servido como un recordatorio tangible de que la construcción de modelos de aprendizaje automático es un ejercicio que va más allá de la simple consecución de métricas elevadas. Requiere una comprensión profunda de las herramientas, una aplicación crítica de la metodología y, sobre todo, una constante evaluación y reevaluación de las decisiones tomadas a lo largo de un proceso que es inherentemente exploratorio y adaptativo. La verdadera lección reside en la apreciación de la complejidad del flujo de trabajo y en el desarrollo de un criterio analítico para navegar sus desafíos, asegurando que los modelos resultantes no solo sean precisos, sino también robustos y verdaderamente generalizables.

El flujo completo, por lo tanto, se ha visto como un ejercicio iterativo de hipótesis, experimentación y validación crítica continua.

Referencias

- [1] David García Curbelo. Práctica 2 - minería de datos, 2024. Este trabajo presenta un análisis detallado de los métodos de selección de características estudiados en este curso.
- [2] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition, 2009. Chapter 7: Random Forests.
- [3] William Wolberg, Olvi Mangasarian, Nick Street, W. Street. Breast cancer wisconsin (diagnostic), 1993.