

Práctica 4

David García Curbelo

—

Minería de Datos

Universidad Nacional de Educación a Distancia

Curso 2024-2025

Índice

1. Introducción	2
2. Análisis exploratorio	2
2.1. Descripción del dataset	2
2.2. Análisis de los datos	3
2.2.1. Características	3
2.2.2. Variable objetivo	4
2.2.3. Análisis conjunto de características y variable objetivo	6
3. Preprocesamiento y tratamiento de datos	8
3.1. Normalización de los datos	8
3.2. Selección de características	9
3.2.1. Métodos clásicos	9
3.2.2. Métodos de árboles de decisión	11
3.2.3. Selección de características finales	13
4. Modelado	14
5. Conclusiones	15
Referencias	16

1. Introducción

En este trabajo se presenta una investigación profunda sobre el proceso de análisis de datos y su aplicación a selección de modelos dentro del grupo de árboles de decisión. Se ha usado el dataset *breast-cancer-wisconsin* de la UCI Machine Learning Repository, que contiene información sobre tumores de mama y su clasificación como benignos o malignos. El objetivo es aplicar diferentes algoritmos de árboles de decisión y evaluar su rendimiento en términos de precisión, sensibilidad y especificidad.

2. Análisis exploratorio

2.1. Descripción del dataset

El conjunto de datos *breast-cancer-wisconsin* es un recurso ampliamente empleado en tareas de clasificación y análisis biomédico. Este conjunto de datos, disponible en el UCI Machine Learning Repository, contiene información derivada de imágenes digitalizadas de aspirados con aguja fina de masas mamarias [3].

El objetivo principal del dataset es predecir si un tumor es benigno o maligno a partir de diversas características morfológicas extraídas de las imágenes microscópicas de las células. Cada instancia del conjunto de datos representa una muestra individual y está compuesta por un conjunto de variables numéricas que describen propiedades específicas de los núcleos celulares.

Las características principales del dataset son las siguientes:

- **Instancias:** 569 registros.
- **Características:** 30 variables numéricas continuas.
- **Variable objetivo:** Tipo de tumor (benigno o maligno).

Además, las características se dividen en tres grupos de 10 atributos cada uno, que representan diferentes aspectos de las medidas tomadas en las células. Los atributos son radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. Para cada una de ellas, se presentan las siguientes medidas:

- **mean:** Describen el valor promedio de los atributos.
- **error:** Reflejan la desviación estándar de las mismas propiedades.
- **worst:** Representan el valor máximo observado para cada atributo.

2.2. Análisis de los datos

2.2.1. Características

Tras un primer estudio de los datos, no se han observado valores nulos ni corruptos en el dataset. Todas las variables predictoras son numéricas continuas, lo que facilita el análisis estadístico y su posterior aplicación de los algoritmos de aprendizaje automático.




Figura 1: Distribución de los datos para cada una de las características.

Además, centrando nuestra atención en la distribución individual que presenta cada una de las características, podemos observar en la Figura 1 cómo todas ellas siguen una distribución que se aproxima a la normal, y en muchas de ellas con un marcado sesgo positivo en la curva.

También es muy importante la visualización de la correlación dos a dos que existe entre las variables, puesto que pueden surgir patrones como el que veremos a continuación. En la Figura 2 se ha dividido el gráfico según los tres subgrupos de variables mencionados anteriormente: mean, error y worst. Esto ha dado lugar, además de la matriz 30×30 resultante del conjunto total de variables, a una matriz 3×3 de la cual podemos extraer patrones muy interesantes.

Podemos observar que las variables asociadas a *radius*, *perimeter* y *area* están altamente correlacionadas entre sí, lo que indica que estas características están relacionadas y podrían contener información complementaria. Por otro lado, las variables asociadas a *texture*, *smoothness* y *fractal dimension* presentan una correlación considerablemente más baja con las demás, lo que podría sugerir que estas variables están aportando ruido a los datos, no siendo

variables relevantes para la predicción.¹




Figura 2: Correlación entre las características, con separación entre los tres subgrupos mean, error y worst.


Lo más relevante de esta matriz de correlación es que la relación entre esas variables (ya sean con datos de mean, error o worst) se mantiene más o menos estable en los 9 cuadrantes. A nivel de estos 3 subgrupos, vemos cómo estas correlaciones se ven incentivadas positivamente allá donde las variables de mean se vean implicadas, en especial entre ellas y con las del subgrupo de worst.

Sin embargo, se observa claramente que las variables de error son las que menos correlación presentan con el resto de variables, lo que podría sugerir que estas variables no aportan información relevante.

2.2.2. Variable objetivo

¹Veremos a posteriori si realmente estas variables aportan ruido o no cuando se estudie su relevancia en conjunto con la variable objetivo.

La variable objetivo del dataset es la clasificación de los tumores como benignos o malignos. En el conjunto de datos, esta variable se representa mediante un valor binario, donde 0 indica un tumor benigno y 1 indica un tumor maligno. La distribución de la variable objetivo no es excesivamente desequilibrada, con 357 instancias de tumores benignos y 212 instancias de tumores malignos.



Realizando un análisis pormenorizado de la distribución de la variable objetivo para cada una de las características, se observa en la Figura 3 un marcado solapamiento para la mayoría de características, lo que sugiere que la separación entre las dos clases no es tan clara como podría esperarse.




Figura 3: Distribución de la variable objetivo para cada una de las características.

Es por ello que es necesario realizar un análisis conjunto de las variables para tratar de encontrar una mejor separación entre las dos clases a clasificar.

2.2.3. Análisis conjunto de características y variable objetivo

Para analizar la relación entre las características y la variable objetivo, se han realizado gráficos de dispersión conjuntos cada una de las características, separadas por cada uno de los tres subgrupos para una mejor visualización.²




Figura 4: Distribución de las características del subgrupo mean con respecto a la variable objetivo.

Podemos observar en la Figura 4 de forma más acusada la relación lineal que existe entre las variables *radius*, *perimeter* y *area* dentro del subgrupo mean. Además, no sólo se observa una relación lineal entre estas variables, sino que también se puede apreciar cómo en general en este grupo la separación entre las dos clases de la variable objetivo es bastante clara. Esto sugiere que este subgrupo de características es bastante relevante para nuestro problema de clasificación.

En el caso de la Figura 5, se observa que la separación entre las dos clases de la variable objetivo no es tan clara como en el caso del subgrupo mean. Sin embargo, todavía hay una tendencia general en la que la implicación de

²Recalcar que no se ha realizado este estudio entre distintos subgrupos de características, ya que, debido a la cantidad de características, la visualización se haría muy complicada y no aportaría información relevante.




Figura 5: Distribución de las características del subgrupo error con respecto a la variable objetivo.

las variables *radius*, *perimeter* y *area* sugiere que algunas características de este subgrupo puedan ser útiles para la clasificación.

Por último, en la Figura 6 se observa de nuevo que la separación entre las dos clases de la variable objetivo es bastante clara, presentando incluso relaciones lineales como en el caso del subgrupo mean, incluso para sus mismas variables. Esto denota una fuerte alineación de los grupos mean y worst, lo que podría sugerir que el subgrupo worst es una redundancia del grupo mean, o viceversa.




Figura 6: Distribución de las características del subgrupo worst con respecto a la variable objetivo.

3. Preprocesamiento y tratamiento de datos

3.1. Normalización de los datos

Para el preprocesamiento de los datos, se ha dividido el dataset en tres conjuntos: entrenamiento, evaluación y test, con una proporción del 60 % para entrenamiento, 20 % para evaluación y 20 % para testeo. Todo el preprocesamiento que sigue se ha realizado sobre el conjunto de entrenamiento, y posteriormente se ha aplicado al conjunto de evaluación y test para que así la evaluación de los modelos no se vea influenciada por el preprocesamiento.

Tras la división de los subconjuntos, se ha optado por aplicar una normalización a las características del dataset. La normalización es un paso crucial en el análisis de datos, ya que permite que todas las características tengan la misma escala y rango, lo que facilita la convergencia de los algoritmos de aprendizaje automático. En este caso, se ha utilizado el método *StandardScaler* de la biblioteca *scikit-learn*, que transforma los datos para que tengan una media de 0 y una desviación estándar de 1. Aunque la normalización no es estrictamente necesaria para todos los algoritmos de aprendizaje automático,

es una práctica recomendada.

Por último, aunque no estrictamente necesario, se ha aplicado el método *SMOTE* (Synthetic Minority Oversampling Technique) para equilibrar el conjunto de datos. Este método genera nuevas instancias sintéticas de la clase minoritaria (en este caso, los tumores malignos) para equilibrar la distribución de clases en el conjunto de entrenamiento.

3.2. Selección de características

Debido a los análisis exploratorios de los datos realizados anteriormente, se presupone que no todas las variables van a ser relevantes para la clasificación. Es por ello que se ha decidido aplicar distintos métodos de selección de características para reducir la dimensionalidad del conjunto de datos y mejorar el rendimiento de los modelos. Los métodos aquí planteados se han dividido en dos secciones. En la primera, los algoritmos mostrados han sido estudiados en detalle en la segunda entrega del curso [1]. Por otro lado, en una segunda sección veremos métodos aplicados mediante algoritmos asociados a árboles de decisión, presentes en el libro base de la asignatura [2].

3.2.1. Métodos clásicos

Información mutua

Este método univariado evalúa la dependencia entre cada característica y la variable objetivo. Se calcula la información mutua entre cada característica y la variable objetivo, y se seleccionan las características con mayor información mutua.

Observamos en la Figura 7 que, a nivel individual de cada una de las características, observamos una predominancia en las primeras posiciones de variables pertenecientes a los subgrupos *worst* y *mean*, predominando la media tabla el subgrupo de error. Esto nos muestra de nuevo que las características de los subgrupos *worst* y *mean* presentan una relación más directa con la variable objetivo, predominando además las asociadas a *concave points* y *perimeter*.




Figura 7: Ranking de características mediante Información Mutua.

Test- F

El test- F es otro método estadístico univariante que evalúa la relación entre cada característica y la variable objetivo mediante la comparación de varianzas. Se calcula el valor del estadístico F para cada característica y se seleccionan las características con los valores más altos.

En la Figura 8 se observa que, al igual que en el caso de la información mutua, las características de los subgrupos worst y mean predominan en las primeras posiciones del ranking. Sin embargo, en este caso, el subgrupo error presenta una correlación más baja con la variable objetivo, destacando por presentar más de la mitad de ellas puntuaciones cercanas a cero.

Por otro lado, sigue destacando en relación univariada la variable *concave points* y *perimeter* tanto para el subgrupo de worst como de mean, que se encuentran en las primeras posiciones del ranking. Además, a nivel de Score obtenido, se pueden distinguir tres grupos claramente marcados, donde el tercer grupo (Scores menor que 200) contiene todas las variables del subgrupo error, lo que indica que en relación univariada no son el subgrupo que más información aporta a la variable objetivo.




Figura 8: Ranking de características mediante Test- F .

ReliefF

El algoritmo ReliefF es un método multivariado de selección de características que evalúa la importancia de cada característica en función de su capacidad para distinguir entre instancias cercanas. Este método nos proporcionará una perspectiva distinta a la de los métodos univariados, ya que tiene en cuenta la interacción entre las características.

En la Figura 9 se observa que, al igual que en los métodos univariados, las características de los subgrupos worst y mean predominan en las primeras




Figura 9: Ranking de características mediante ReliefF.

posiciones del ranking. Como en los test anteriores, de nuevo las primeras posiciones están ocupadas por las variables *concave points*, *perimeter* y *radius*, lo que refuerza la idea de que estas características son relevantes para la clasificación.

RFE-SVM

En este caso, se ha utilizado el algoritmo de eliminación recursiva de características con un clasificador SVM como modelo base.

Para este caso se observa que el algoritmo ha seleccionado las características de forma diferente a los métodos anteriores. En la Tabla 1 se observa que las variables *perimeter* y *radius* son las más relevantes, pero también se incluyen otras características asociadas al subgrupo error, como *perimeter error* y *radius error*, que no habían sido destacadas en los métodos univariados.

Este algoritmo ha encontrado unos patrones que difieren considerablemente de los métodos anteriores, lo que sugiere que la interacción entre las características es importante para la clasificación. Además, se observa que el algoritmo ha seleccionado características de todos los subgrupos, lo que indica que la combinación de características de diferentes grupos puede ser beneficiosa para el rendimiento del modelo.

feature	ranking
worst perimeter	1
worst radius	2
worst smoothness	3
perimeter error	4
worst area	5
mean concave points	6
worst texture	7
radius error	8
worst concavity	9
area error	10
compactness error	11
mean radius	12
mean perimeter	13
worst symmetry	14
smoothness error	15
mean fractal dimension	16
concave points error	17
fractal dimension error	18
symmetry error	19
mean concavity	20
mean compactness	21
mean area	22
worst concave points	23
mean texture	24
mean smoothness	25
worst compactness	26
mean symmetry	27
worst fractal dimension	28
texture error	29
concavity error	30

Cuadro 1: Ranking de Características por RFE-SVM.

3.2.2. Métodos de árboles de decisión

Para los dos siguientes métodos que se presentan a continuación de medición de importancia de las características, se han entrenado dos modelos basados en árboles de decisión: un clasificador *Random Forest* y un clasificador *Extra Trees*. Ambos modelos son algoritmos que se han entrenado con 100 estimadores, y se han utilizado exclusivamente para calcular la importancia de las características mediante el método de Gini y el método de permutación de variables.

Importancia Gini

La importancia de Gini es un método que evalúa la importancia de cada característica en función de su contribución a la reducción de la impureza del nodo en el árbol de decisión. Este método se basa en el índice de Gini, que mide la pureza de los nodos en un árbol de decisión.

En este caso se observa cierta consistencia (salvo pequeñas variaciones locales) en el orden aportado por ambos modelos para el cálculo de este método. En la Figura 10 se han ordenado los registros por la suma de la importancia en ambos modelos, y se observa que el orden es muy similar al de los métodos anteriores, destacando las variables *worst concave points* y *radius* como las más relevantes. Además, se observa que las variables del subgrupo error tienen una importancia menor en comparación con las variables de los subgrupos *worst* y *mean*, ratificando su escasa importancia en el análisis.




Figura 10: Ranking de características mediante la Importancia Gini.

Importancia de Permutación

La importancia de permutación es un método que evalúa la importancia de cada característica en función de su impacto en el rendimiento del modelo. Este método mide la disminución del rendimiento del modelo al permutar los valores de una característica específica.

Al igual que en el caso anterior, el orden mostrado es el asociado a la suma de los resultados obtenidos en ambos modelos. Sin embargo, se observa aquí en la Figura 11 una variabilidad mucho más alta en cuanto a los resultados obtenidos por los dos modelos. Por ejemplo, destaca que la primera posición la ocupe




Figura 11: Ranking mediante la Importancia por Permutación.

la variable *worst radius*, cuando para el modelo *Random Forest* ocupaba la posición 10. Otro caso muy visual es el de la variable *mean smoothness*, donde ambos modelos difieren por completo en su impacto en el rendimiento del modelo.

Además, esta inconsistencia entre ambos modelos ha producido que el orden obtenido con respecto a los métodos anteriores haya cambiado considerablemente. En este caso, las variables del subgrupo error han obtenido una puntuación más alta que en los métodos anteriores, lo que sugiere que la importancia de estas características puede depender del modelo utilizado.

3.2.3. Selección de características finales

Para la selección de características finales, se ha optado por un enfoque combinado que incluye tanto los métodos clásicos como los métodos basados en árboles de decisión. Se han seleccionado las 10 características más relevantes de cada método y se han combinado para formar un conjunto final de características. Esta combinación se ha realizado mediante la media de las puntuaciones obtenidas por cada característica en los diferentes métodos. El conjunto final de características seleccionadas incluye las siguientes variables:

- *worst concave points*
- *mean concave points*
- *worst area*
- *worst perimeter*
- *worst concavity*
- *worst radius*
- *mean concavity*
- *mean radius*
- *mean perimeter*
- *mean area*

Se realizarán comparaciones en la fase de modelado entre el rendimiento de los modelos con este conjunto de características y el rendimiento de los modelos con todas las características del dataset. Esto permitirá evaluar si la reducción de dimensionalidad mejora el rendimiento del modelo y si la selección de características realizada es efectiva.

4. Modelado

5. Conclusiones

Referencias

- [1] David García Curbelo. Práctica 2 - minería de datos, 2024. Este trabajo presenta un análisis detallado de los métodos de selección de características estudiados en este curso.
- [2] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition, 2009. Chapter 7: Random Forests.
- [3] William Wolberg, Olvi Mangasarian, Nick Street, W. Street. Breast cancer wisconsin (diagnostic), 1993.