

Minería de Datos

Práctica 3 - Deep Learning

Manuel Castillo-Cara / Luis Sarro
Curso académico: 2024/2025

Octubre 2024

Introducción

En este documento se propone la tercera actividad de la asignatura Minería de Datos, del Máster en Investigación en Inteligencia Artificial. Esta actividad corresponde a los temas 4 y 5 del contenido de la asignatura, y antes de su realización se asume que el alumnado ha leído el material propuesto en la guía, en concreto los epígrafes 11.1, 11.3 a 11.5 y 11.9.1 de [1] y el capítulo 9 de [6].

El objetivo de esta actividad es que el alumnado ponga en práctica los contenidos teóricos relativos a las redes neuronales y el aprendizaje profundo para asentar su conocimiento de estas técnicas. Es importante dejar claro que, como ocurre en el resto de las actividades evaluables de esta asignatura, lo importante no es tanto resolver un problema propuesto por el equipo docente como demostrar que se han comprendido e interiorizado los diversos aspectos clave de las técnicas que se ponen en juego, y su impacto en la implementación y resultados.

Aprendizaje profundo con Keras

Respecto al software usado para realizar la actividad, el equipo docente recomienda el uso de Keras [2] (sobre Python o R) por su facilidad de uso, aunque no es obligatorio y es posible elegir otras alternativas. Se recomienda encarecidamente realizar las prácticas de programación ya que suponen la comprensión de cómo implementar la práctica en Python.

Para quienes no tengan experiencia previa, se recomienda, como primer paso para el desarrollo de esta práctica, realizar las prácticas de programación referente al bloque de Deep Learning. Adicionalmente, se puede seguir el tutorial de clasificación básica con Keras (para python [4] o para R [5]) y repetir los pasos del mismo con los datos proporcionados por el equipo docente.

Es posible considerar la utilización de otro software alternativo de aprendizaje profundo. En tal caso, a fin de compartir experiencias, se sugiere al alumnado que abra un hilo en el foro y exponga los motivos de tal decisión y las posibles ventajas de esas alternativas.

Identificación de granos de polen

En palinología, la clasificación visual de granos de polen de distintas especies es una tarea difícil que es, hasta la fecha, abordada por personas expertas por medio de un microscopio. La automatización completa de esta tarea ahorraría una gran cantidad de recursos, especialmente horas de trabajo de estudiantes de doctorado, y provocaría grandes mejoras especialmente en los sistemas de información relacionados con las afecciones alérgicas, aunque también en otros campos como la reconstrucción paleoclimática, el control de calidad de productos basados en la miel, la identificación de evidencias forenses en investigaciones criminales o la datación y el trazado de tejidos.




Figura 1: Ejemplos de granos de polen de los dos tipos considerados.

El problema que se propone abordar en esta actividad consiste en la identificación de granos de polen de dos especies diferentes que provienen de Nueva Zelanda. Ambas especies producen granos de polen que son considerados indistinguibles: ambos son, según los palinólogos, monádicos, isopolares, angulaperturados, sincolpados, tectados y triangulares en vista polar. Existe una leve diferencia en su tamaño promedio, aunque hay mucho solape entre las distribuciones del tamaño de ambas especies, y también hay alguna pequeña diferencia en la forma de sus granos cuando son fotografiados en vista ecuatorial. Así pues, los humanos tienen grandes dificultades para distinguirlos.

En la Figura 1 pueden verse seis ejemplos, en blanco y negro, de cada uno de los dos tipos polínicos. Estas imágenes han sido obtenidas mediante un microscopio especial, comercializado por la empresa Veritaxa, llamado Classifynder. Este microscopio agrega de forma automática un conjunto de imágenes con enfoques verticales sucesivos para tratar de recomponer una imagen en la que el grano de polen aparezca entero enfocado. Aún así, la similaridad entre las dos especies es evidente.

Especificación de la tarea

A partir del conjunto de imágenes de polen proporcionado en el espacio virtual de la asignatura se propone la construcción de un sistema de clasificación automática de granos de polen para estas dos especies neozelandesas. La idea es realizar una serie de experimentos como los mostrados en la sección 11.7 de [1] (página 404), es decir: se trata de construir modelos cada vez más complejos y comparar su capacidad para resolver este problema.

Se pide construir los siguientes modelos y, sobre todo, analizar y discutir los resultados y conclusiones que pueden obtenerse:

1. El primero, en orden creciente de complejidad, estará compuesto por una red neuronal sin capa oculta (NET-1), equivalente a una regresión binomial logística, que reciba las imágenes y las clasifique.
2. El segundo modelo será igual al anterior, pero contendrá una o más capas ocultas.
3. El tercer modelo será una Red Neuronal convolucional como las explicadas en el capítulo 9 de [6].
4. De este último modelo convolucional, se pide realizar un cuarto y quinto modelo con 2 modificaciones diferentes, e.g., más capas, tipos de convolución, inicialización de pesos. . . , de manera que pueda justificarse la mejora.

Pesos y mapas de características

Para este apartado podemos utilizar la CNN entrenada más sencilla, e.g., que tenga 2 o 3 capas de convolución/pooling. En este sentido, los pesos de las capas de convolución nos permiten entender cómo la red está aprendiendo a extraer características de las imágenes. Los filtros en las primeras capas capturan características básicas, mientras que los filtros en las capas posteriores capturan características más complejas. Por otro lado, la visualización de los pesos también nos ayuda a identificar qué características son más importantes para la red. Los filtros con valores más altos en ciertas áreas indican que esas características son cruciales para la clasificación de las imágenes.

Para esta práctica vamos a analizar ambas cosas para nuestro dataset siguiendo este tutorial [3]. Así mismo, se deja la siguiente guía de los que hay que resolver:

1. Visualización de los pesos: (i) Utilizar `Matplotlib` para visualizar los pesos de las capas de convolución; y (ii) Mostrar los pesos en forma de imágenes para cada filtro de convolución.
2. Visualización de los mapas de características: (i) Extraer y visualizar los mapas de características generados por las capas de convolución para una o más imágenes de entrada; (ii) Utilizar `Matplotlib` para mostrar los mapas de características en forma de imágenes.
3. Análisis crítico: Este es el aspecto más relevante respecto a la tarea ya que se deberá analizar las imágenes extraídas:
 - Discusión crítica de los pesos visualizados: ¿Qué patrones se observan en los pesos de las capas de convolución? ¿Qué características parecen estar detectando los filtros?
 - Discusión crítica de los mapas de características: ¿Qué características destacan en los mapas de características? ¿Cómo evolucionan estas características a medida que se avanza a través de las capas de la red?
 - Interpretación de los resultados: ¿Qué conclusiones se pueden extraer sobre cómo la red aprende a extraer características de las imágenes? ¿Qué filtros parecen ser más importantes para la clasificación?

Entregable

Se entregará una memoria de 5 caras de folio como máximo, con tamaño de fuente 12pt, en la que se dé cuenta de los experimentos realizados y las conclusiones que pueden extraerse de los mismos. En estas 10 caras de folio deben de entrar las figuras clave, por lo tanto, centraros en los conceptos a debatir y justicar en la práctica y no introducir conceptos ampliamente sabido, e.g., qué es una convolución, su formulación matemáticas... Tened en cuenta que se pueden utilizar Anexos para el uso de Figuras o imágenes adicionales que puedan ser de interés.

Además, será necesario construir y analizar una gráfica como la mostrada en la Figura 11.11 de [1] (página 406), que muestre el proceso de aprendizaje para todos los modelos con el conjunto de validación.

Adicionalmente, se deberá entregar el Notebook con el código fuente. A fines de claridad este cuaderno deberá tener una descripción breve de lo que representan las celdas de código en cada parte.

IMPORTANTE: Para asegurar una evaluación justa y coherente, es crucial que los estudiantes sigan estrictamente el orden y los puntos expuestos en el Cuadro 1. Esto garantizará que todos los aspectos importantes del proyecto sean abordados de manera completa y sistemática. La estructura y el contenido de la memoria deben reflejar claramente cada uno de los puntos mencionados, proporcionando un análisis detallado y crítico en cada sección.

Cuadro 1: Rúbrica o distribución de puntos para la evaluación.

Concepto	Puntos
1. Técnicas de <i>Data Augmentation</i> y el impacto en el modelado	1
2. Descripción y obtención de resultados de los diferentes modelos	5
2.1. Modelos estándar 1 y 2	1
2.2. Modelos 3: CNN (tipos de convolución, pooling...)	2
2.3. Modelos 4 y 5: CNN con variantes/configuraciones	2
3. Análisis crítico de los resultados	3
3.1. Análisis general y gráfica	1
3.2. Análisis de los pesos	1
3.3. Análisis de los mapas de características	1
4. Conclusiones	1

Evaluación

La evaluación de esta práctica estará basada exclusivamente en la memoria entregada, y se hará teniendo en cuenta la distribución de puntos mostrada en el Cuadro 1. La nota final máxima será de 10 puntos, y será necesario obtener al menos 5 para aprobar.

Se valorará particularmente la capacidad de análisis crítico y la puesta en juego de los conceptos, antecedentes y limitaciones presentadas en la bibliografía. También se valorará el estilo y la corrección orto-tipográfica del texto.

Finalmente, no poner definiciones ni formalización matemática ampliamente ya conocida, lo que interesa es la discusión técnica de los resultados que se van obteniendo y como se enlazan estos resultados con la teoría. Incidimos en ceñirse en la discusión crítica de los resultados que se obtiene en la práctica y no en definiciones ampliamente conocidas. Lo más importante es que demostréis que habéis entendido los contenidos del tema y que los manejaís con soltura.

IMPORTANTE: Aunque se deberá exponer en la práctica el código, no se calificará el mismo, sino que se calificarán el análisis crítico de los resultados, la discusión en la salida del código y visualizaciones y, sobre todo, la discusión crítica y el hilo argumental que el alumnado proporcione.

Referencias

- [1] *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Series in Statistics. New York.
- [2] Home - Keras Documentation. <https://keras.io/>.
- [3] How to visualize filters and feature maps in convolutional neural networks. <https://machinelearningmastery.com/how-to-visualize-filters-and-feature-maps-in-convolutional-neural-networks/>.
- [4] Train your first neural network: basic classification | TensorFlow Core. https://www.tensorflow.org/tutorials/keras/basic_classification.
- [5] Tutorial: Basic Classification. https://keras.rstudio.com/articles/tutorial_basic_classification.html.
- [6] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. The MIT Press, Cambridge, Massachusetts, November 2016.